ChatGPT 说：

基于官能团的聚合物三维空间相互作用网络：文献基础、构建方法与研究方案

研究目标： 从聚合物的原子连接结构与三维分子动力学轨迹出发，自动识别官能团，将每个官能团实例作为图节点，通过几何判据和化学规则识别官能团间的非共价相互作用，建立具有化学解释性、空间意义和动力学信息的聚合物相互作用网络。

整个研究可划分为五个环节：



一、相关文献整理

研究方向	代表文献	核心内容与借鉴价值
官能团自动识别	Ertl (2017), *An algorithm to identify functional groups in organic molecules* Springer Natur...	根据原子连接、杂原子和化学规则识别官能团，不完全依赖预定义的官能团字典。
官能团提取实现	Colmenarejo (2025), *EFGs: A Complete and Accurate Implementation of Ertl's Functional Group Detection Algorithm in RDKit* ACS Publicatio...	提供官能团原子索引、结构表示与可视化结果，可建立官能团和三维原子的映射。

官能团图表示	Han 等 (2025), *Attention-based functional-group coarse-graining: a deep learning framework for molecular prediction and design* npj Computati...	构建原子—官能团层级图，并引入注意力机制；与官能团节点建模思路高度相关。
官能团非共价作用	Driver 等 (2020), *Functional group interaction profiles: a general treatment of solvent effects on non-covalent interactions* Chemical Scie...	研究溶剂如何影响官能团间作用自由能，可为溶剂竞争、氢键偏好提供物理化学依据。
聚合物空间接触网络	Siemons 等 (2023), *Controlling swelling in mixed transport polymers through alkyl side-chain physical cross-linking* PubMed	使用分子动力学与网络分析，解释侧链物理交联如何影响聚合物溶胀。
聚合物动态氢键与水桥	Chen 等 (2026), *Water-mediated hydrogen bonds and local side-chain interactions in the cooperative collapse and expansion of PNIPAM oligomers* Illinois Experts	通过 MD 研究水介导氢键、局部侧链相互作用与构象转变的关系。

其中第三篇值得优先精读。需要更新的是，该论文不仅有2025年的预印本，还已于 **2025年11月21日正式发表于 *npj Computational Materials***。

但要区分：其官能团图主要表达化学连接关系，注意力用于学习化学环境，并不直接提供真实空间接触概率或者非共价相互作用能。 npj Computati...

二、官能团自动提取与节点定义

2.1 官能团识别方法

方法	思路	适用场景
RDKit SMARTS	根据预先编写的子结构匹配规则提取	目标官能团明确、需要精确控制的聚合物
Ertl Algorithm	根据连接拓扑及化学规则自动发现官能团	大规模、结构多样的分子库
EFGs	Ertl 算法的 RDKit/Python 完整实现	需要官能团原子索引并与三维结构关联
EFGs + SMARTS	先自动识别，再按体系化学规则修正、归类	本研究推荐的实际方案

EFGs 能够输出原子索引集合、官能团 pseudo-SMILES、RDKit 分子对象和可视化信息，因此适合作为实现起点。 ACS Publicatio...

2.2 在聚合后的结构上识别

建议采用以下顺序：

聚合单体 → 聚合反应建模 → 重复单元/聚合物链 → 官能团识别 → 保存单体来源。

原因是聚合过程可能改变官能团。例如缩聚可能消耗羧酸和醇，生成新的酯键。如果直接采用未反应单体的官能团标签，就可能得到不正确的节点定义。

2.3 节点应当保存的信息

设第 i 个官能团实例为 FG_i。

属性	具体信息
节点 ID	`fg_id`，唯一标识一个官能团实例
官能团类型	羟基、酯基、酰胺基、醚基、芳环等
原子索引集合	`atom_indices`，用于映射到3D坐标
结构来源	聚合物链 ID、重复单元 ID、原始单体 ID
化学作用位点	氢键供体、氢键受体、带电中心、芳环
化学属性	电荷、芳香性、局部化学环境
空间属性	原子坐标、可选的质心与方向向量

同类型的官能团实例必须区分。例如，一条聚合物链上存在20个羟基，应建立20个节点，而不是用一个羟基节点代表所有羟基。

2.4 官能团划分尺度

推荐：

完整官能团作为节点，节点内部保留用于判断相互作用的原子位点。

例如酰胺基：

$$-\mathrm{C}(=\mathrm{O})-\mathrm{NH}-$$

将整个酰胺结构视为一个官能团节点，但必须保留羰基氧和 N–H 的具体原子索引，分别判断供体/受体作用。

初期使用互不重叠的主节点，避免同一原子同时属于多个不同主节点造成重复统计。普通烃链等未纳入官能团的原子也要通过骨架节点或残余片段保存，以保证结构完整。

三、构建两类官能团图

需要区分化学连接和空间相互作用。

3.1 官能团化学连接图

定义：

$$G_{\mathrm{FG}}^{\mathrm{chem}} = (V_{\mathrm{FG}}, E_{\mathrm{chem}})$$

- 节点：官能团实例。
- 边：官能团之间沿共价连接结构形成的连接关系。
- 边属性：键类型、连接位置、路径长度、是否属于同一重复单元。

该图反映聚合物的化学拓扑，但不能单独表示空间非共价相互作用。

3.2 官能团三维动态作用图

定义：

$$G_{\mathrm{FG}}^{\mathrm{space}}(t) = (V_{\mathrm{FG}}, E_{\mathrm{space}}(t))$$

- 节点：官能团实例。
- 边：在特定时间满足空间相互作用判据的官能团对。
- 边属性：相互作用类型、距离、角度、链内/链间身份等。

三维动态图可表达沿链相距较远、但由于折叠或链间聚集而在空间上接近的官能团。

这两类图应当保留为不同的边类型，避免将共价连接误认为非共价结合。

四、三维构象与空间作用识别

4.1 不同数据能够支持的分析

数据来源	可以研究的内容	主要限制
SMILES/二维连接图	官能团类型、数量、化学连接、潜在作用位点	无真实空间关系
单个三维构象	特定构象中的接触与几何关系	不能代表构象集合或动力学
多构象数据	构象依赖性、不同构象的接触差异	不一定有可靠时间信息
单链 MD	链内接触、构象变化、链内氢键	缺少链间作用
多链 MD	链内/链间接触、占有率、寿命、空间网络	依赖力场、采样及条件设定

实验表征	验证聚合物宏观响应或局部化学环境变化	通常无法唯一确定单个官能团对的作用

针对凝聚态聚合物，建议优先采用多链 MD 轨迹，并正确处理周期性边界条件（PBC）。

4.2 相互作用类型和判定依据

相互作用	判定方法	需要保留的物理量
氢键	供受体化学类型、距离与角度联合判断	D–A距离、D–H···A角
π–π堆积	芳环平面和相对位置	环心距离、法向夹角、横向偏移
离子配对	带电基团及其几何接近程度	电荷、作用位点距离、局部环境
一般范德华接触	原子间距离或与范德华半径相关的判据	最近原子距离、接触原子对
疏水接触	疏水基团空间接近及环境分析	接触距离、溶剂暴露、聚集程度
水桥	两个官能团通过同一水分子构成连接	两段氢键几何、水分子ID、持续时间

应当按体系选择合理阈值。一个距离阈值不能适用于所有官能团，也不能仅凭距离接近认定形成了氢键。

另外，同一聚合物链中共价相邻或拓扑距离很近的片段需要单独处理，避免把必然存在的局部接近误认为有意义的远程空间相互作用。

五、ProLIF：可借鉴的相互作用识别框架

ProLIF Protein–Ligand Interaction Fingerprints

ProLIF 官方文档：Interaction Fingerprint ↗

ProLIF 原本面向蛋白质—配体相互作用分析，但它已经实现了许多基于 SMARTS 和三维几何条件的相互作用识别器，包括氢键、疏水接触、π 堆积、离子作用、阳离子–π作用和范德华接触等，并支持通过 MDAnalysis 读取轨迹。 ProLIF docume...

5.1 可以直接借鉴的部分

ProLIF 功能	聚合物研究中的用途
SMARTS 化学识别	识别供体、受体、带电中心等
几何作用判据	判断氢键、芳环堆积、离子接触

相互作用参数配置	修改距离、角度等阈值
MD 逐帧分析	生成不同时间的接触信息
Interaction Fingerprint	建立逐帧的相互作用存在/不存在矩阵
原子级作用元数据	将相互作用映射回官能团节点

5.2 需要针对聚合物改造的部分

ProLIF 并不能直接等价于一个完整的聚合物官能团动态图构建工具。

关键的适配工作包括：

1. **更换分析对象。** 从默认的蛋白质残基—配体分组，改为官能团实例—官能团实例。
2. **建立原子映射。** 将检测到的原子相互作用转换为对应官能团对。
3. **保留聚合物拓扑信息。** 判断相互作用发生在同一链、不同链或相邻重复单元之间。
4. **适配周期性边界。** 确保轨迹距离计算和空间几何关系正确。
5. **处理作用重叠。** 同一组官能团可能同时存在不同类型的空间接触。
6. **增加动态图统计。** 计算占有率、连续寿命、伙伴交换和瞬时网络连通性。

推荐技术组合： RDKit / EFGs 负责官能团划分，MDAnalysis 负责轨迹与原子选择，ProLIF 的交互规则作为参考或可复用的判定模块，NetworkX 或类似工具分析官能团动态图。

六、官能团间相互作用的数学定义

6.1 逐帧相互作用判定

定义第 k 类作用在时间 t 的邻接矩阵：

$$A_{ij}^{(k)}(t) = \begin{cases} 1, & FG_i, FG_j \text{ 满足第 } k \text{ 类作用判据} \\ 0, & \text{否则} \end{cases}$$

其中：

- i, j：具体的官能团实例；
- k：氢键、π–π堆积、离子配对等；
- t：MD轨迹中的一个时间帧。

因此，不同时间下的边可以形成、消失或重新出现。

6.2 相互作用占有率

$$p_{ij}^{(k)} = \frac{1}{N_{\text{frames}}} \sum_{t=1}^{N_{\text{frames}}} A_{ij}^{(k)}(t)$$

$p_{ij}^{(k)}$ 表示这两个具体官能团在采样帧中形成第 k 类作用的比例。

例如某个羟基与某个羰基在1000帧中满足氢键判据600次，则其占有率为0.6。

占有率不是相互作用能，也不等于普适的热力学结合概率。 其可靠性取决于采样是否充分，以及相互作用判据是否合理。

6.3 建议重点分析的网络指标

指标	具体含义	科学问题
官能团配对偏好	不同官能团类型之间的接触倾向	哪些化学基团更容易相互接近?
链内/链间作用比例	同链与异链作用的相对比例	作用主要稳定单链构象还是链间网络?
相互作用占有率	某一官能团对有多少时间满足判据	作用是否稳定存在?
接触持续时间	连续形成某类作用的时间长度	作用属于短暂接触还是长期维持?
伙伴交换率	一个官能团更换相互作用对象的情况	网络是否具有快速重组能力?
团簇大小分布	每帧由相互作用边连接形成的团簇规模	是否形成局部聚集或大范围网络?
连通性及贯通性	网络是否形成跨链或跨空间区域的连通结构	是否存在有意义的物理交联网络?

统计时需注意：

- 配对偏好要考虑各类官能团的数量和可接近位点，避免数量较多的基团自然具有更高接触数。
- 连通性应优先逐帧计算，而不是简单合并整条轨迹中出现的所有边。
- 寿命分析需规定短暂断开后重连是否算作同一次作用。
- MD输出帧间隔必须足够小，否则短寿命接触可能被漏掉。

七、研究创新点应放在哪里?

现有文献已经覆盖官能团提取、官能团图表征和聚合物相互作用网络等方向。

因此，不宜将“把官能团作为图节点”本身作为核心创新。

更有价值的研究方向是：

构建具有真实空间几何条件、明确相互作用类型和时间演化信息的聚合物官能团动态网络，并验证它是否能够解释材料性质。

可分为三个逐步增强的表征方案：

表征方式	包含的信息	主要检验目标
Level 1：官能团组成	官能团种类、数量、比例	仅靠组成能解释多少性质差异?
Level 2：化学官能团图	Level 1 + 官能团共价连接拓扑	沿链分布和连接顺序是否有影响?
Level 3：三维动态官能团图	Level 2 + 空间接触、几何、占有率、寿命	空间与动力学信息能否解释更多性质变化?

这三个层级也可以作为未来开发图模型时的消融实验基础，但**第一阶段不必引入机器学习**，先检验网络描述本身的科学合理性和解释能力。

八、推荐的具体研究课题

建议课题名称

Dynamic Functional Group Interaction Networks in Polymers: Linking Chemical Architecture, Spatial Organization, and Material Properties

聚合物动态官能团相互作用网络：连接化学结构、空间组织与材料性能

核心科学假设

在官能团组成相近的条件下，官能团沿聚合物链的分布方式、空间可接近性和局部化学环境会影响链内/链间相互作用的形成概率、持续时间及空间网络结构，进而影响聚合物的宏观性质。

实验与模拟设计

研究环节	主要工作
体系选择	选择同一聚合物家族，控制总体官能团组成
结构变量	改变官能团间隔、沿链分布、序列或侧链布局
控制变量	尽量保持分子量、分散度、温度和环境一致
分子动力学	构建多链体系，获得平衡后的多组独立轨迹
网络构建	识别官能团接触，计算动态作用网络
机理分析	分析占有率、寿命、链间连接和团簇变化
性能关联	与溶胀、链段松弛、黏附或其他目标性质对照

实验验证	使用 FTIR、DSC、DMA、溶胀或流变等适合体系的手段

若后续研究对象是锂电池聚合物粘结剂，还可以把官能团—活性材料表面、官能团—电解质以及官能团—溶剂的相互作用作为扩展研究对象。不过，这需要引入相应界面模型和作用判据，不能简单套用聚合物链间接触规则。

九、建议的实施顺序

1. **第一阶段：验证官能团自动识别**

   从几个简单聚合物入手，使用 RDKit + EFGs，获得每个官能团的原子索引集合，人工核对聚合后的官能团分类。

2. **第二阶段：建立静态三维相互作用图**

   使用已有3D聚合物构象，将原子坐标映射到官能团，计算接触、氢键等几何关系，检查空间边的化学合理性。

3. **第三阶段：扩展到多链MD轨迹**

   处理周期性边界、逐帧构建官能团相互作用矩阵，并区分链内和链间作用。

4. **第四阶段：开展动态图和机制分析**

   提取占有率、寿命、配对倾向、网络连通性等指标，检验其对温度、官能团分布和环境条件的响应。

5. **第五阶段：与材料性质建立关联并验证**

   选择一个明确的物理性质作为终点，将结构变量、空间作用网络和实验结果关联起来，检验解释是否稳定、可重复。

十、重要结论与研究边界

这项研究需要区分三个概念：

化学连接 ≠ 空间接触 ≠ 相互作用能。

化学连接图反映共价拓扑，空间相互作用图反映满足特定几何和化学判据的局部关系，而真正的相互作用自由能还涉及溶剂化、构象熵和环境等因素。

ProLIF 可以帮助实现第二类关系中的相互作用识别，但并不意味着它计算出的接触就是结合能。类似地，使用 $\exp[-(r/r_0)^2]$ 进行距离加权，得到的是几何相似或接近程度，不应直接称为真实作用强度。

研究的价值不在于重新发明官能团提取算法，而在于完成以下连接：

化学结构 ⟶ 官能团空间作用 ⟶ 动态网络特征 ⟶ 材料性质

最优先阅读顺序建议为：Han等（2025）的官能团层级图论文 → Ertl（2017）与 EFGs（2025）→ ProLIF 官方文档 → Siemons等（2023）的聚合物网络研究 → Chen等（2026）的动态氢键研究 → Driver等（2020）的非共价作用热力学分析。

这样可以首先解决“如何识别与表示官能团”，再解决“如何赋予空间边物理意义”，最后验证网络描述与材料性能之间是否存在可靠联系。

你说：

想做聚合物表征，一部分是原子层级，repeat unit 层级，另一部分是官能团 pair 和unit pair，现在想知道官能团部分怎么做合理，怎么能提取到官能团在3d 空间中的相互作用?

思考了 3m 13s >

ChatGPT 说：

聚合物分层表征设计：如何构建具有3D空间相互作用的 Functional Group Pair?

你的模型可以设计为两条相互关联的表征路径：

1. **结构层级（Structural Hierarchy）**：Atom Level → Repeat Unit Level，学习聚合物的原子结构、局部化学环境和重复单元特征。
2. **相互作用层级（Interaction Hierarchy）**：Functional Group Pair → Repeat Unit Pair，学习官能团及重复单元之间的三维空间作用关系。

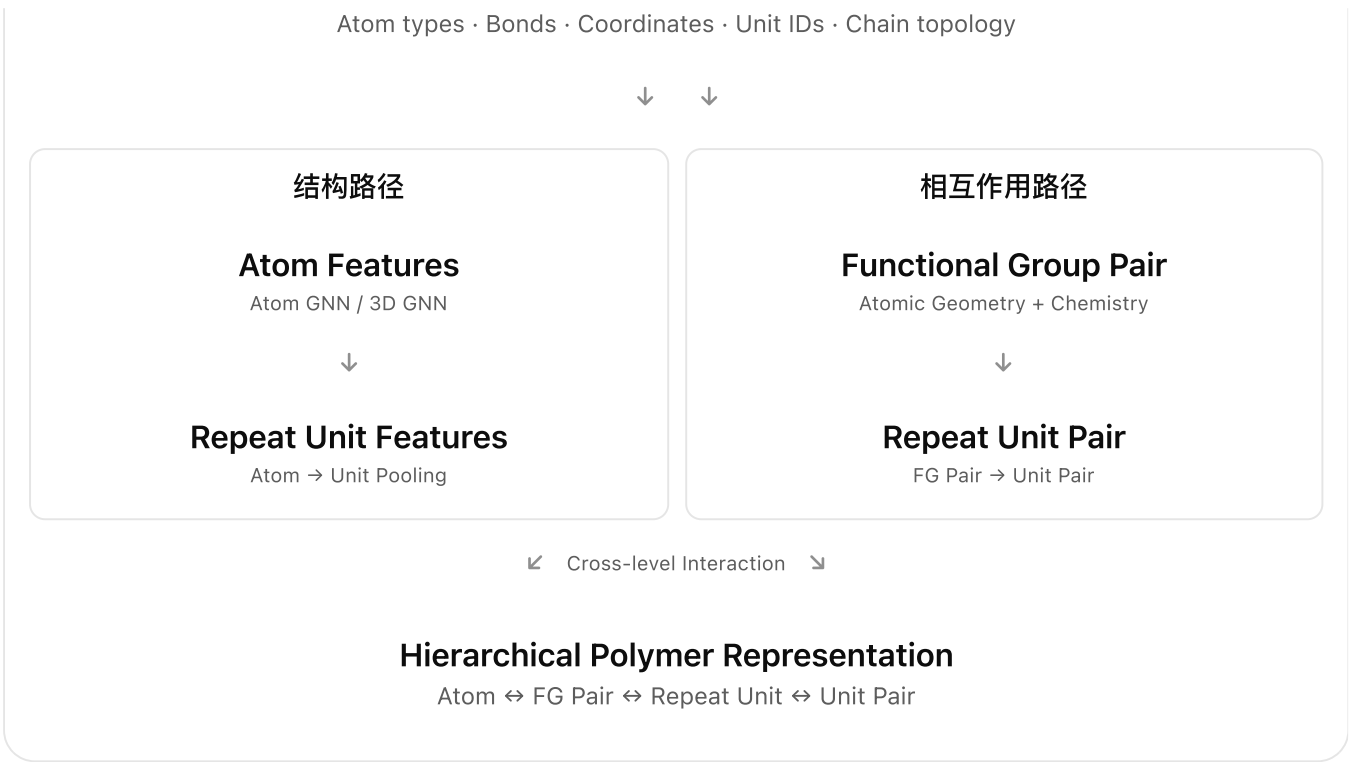
我建议采用一个核心思路：

以原子作为3D几何计算的基础，以官能团作为化学作用的基本单元，以Repeat Unit作为高阶结构单元。

其中，官能团Pair不是简单地判断“两个官能团之间的距离是否小于某个阈值”，而应该从组成它们的原子对出发，提取距离、方向、相对取向和化学作用位点，再形成官能团之间的3D Pair表征。

一、建议的整体模型架构

Input：Polymer 3D Structure



这里最关键的是：**Functional Group Pair应该是由原子几何关系聚合出来的关系表征，而不只是两种官能团类型的组合。**

例如，同样是羟基–羰基组合，其3D空间排列不同，可能形成氢键，也可能仅仅是普通的空间接近。

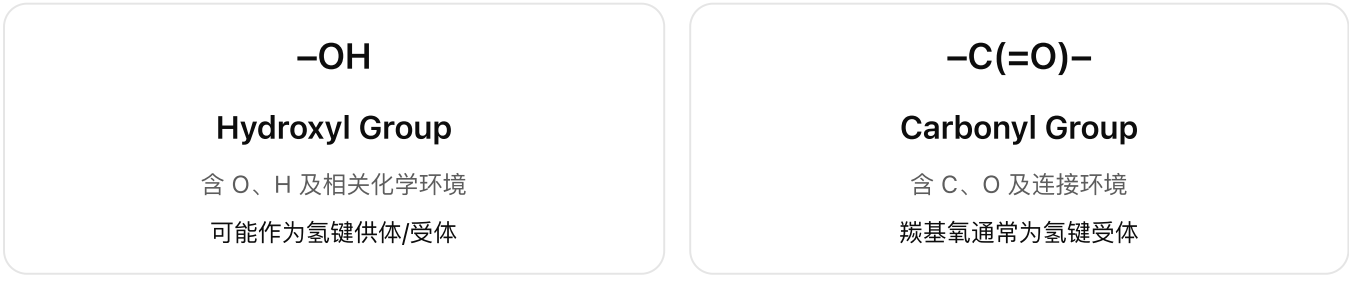
因此，模型需要同时保留：

- **Chemical Identity**：官能团由哪些原子组成，具有什么化学作用位点。
- **3D Geometry**：组成两个官能团的原子对如何在空间分布。
- **Interaction State**：是否具有形成氢键、偶极相互作用、芳环堆积等作用的几何条件。

二、官能团应该怎样定义？建议使用“FG节点 + 作用位点”双重表示

2.1 先识别官能团，再映射到3D原子

假设某个聚合物重复单元包含以下两种官能团：



在模型中，每次出现的官能团都拥有独立ID和原子集合：

$$FG_i = \{a_1, a_2, \ldots, a_m\}$$

$$FG_j = \{b_1, b_2, \ldots, b_n\}$$

官能团本身并不是一个真实的点，而是一组具有不同化学作用位点的原子。

建议预先定义一份规范化的官能团词典：

官能团	用于3D作用分析的关键原子	主要考虑的相互作用
–OH	O、H	氢键、局部偶极作用
–C=O	O、C	氢键受体、偶极相关作用
–COO–	两个O、羰基C	氢键受体、偶极作用
–CONH–	羰基O、N、H	氢键供体/受体
–O–	O	氢键受体、偶极作用
–CN	C、N	弱氢键受体、偶极作用
–SO_2–	S、两个O	氢键受体、偶极作用
芳香环	完整环原子集合	π–π、阳离子–π、空间堆积

这些是候选作用类型，不代表任意两个相应官能团都一定存在该相互作用。

2.2 官能团提取如何自动化?

推荐两个方法结合：

方法A：Ertl / EFGs 自动识别

Ertl算法基于杂原子、多重键及其连接关系提取官能团，适用于多样化结构。 Springer Natur...

方法B：RDKit SMARTS 定义目标官能团

针对聚合物，可以单独增加：

- 芳香环识别；
- 酯、酰胺、醚、腈等官能团分类；
- 聚合反应后产生的连接基团；
- 聚合物骨架片段；
- 特殊电池聚合物中的离子基团。

我更推荐用 **Ertl作为自动发现工具，用SMARTS建立统一的、可复现的官能团分类标准。**

尤其要注意，Ertl 并不天然等同于一个包含所有芳环、烷基片段的完整结构分区。若你的模型需要覆盖所有原子，应另外定义 backbone/scaffold 节点或保留原子层作为完整信息通道。

2.3 从2D官能团映射到3D坐标

假设RDKit识别出：

```
functional_groups = [
    {
        "fg_id": 0,
        "type": "hydroxyl",
        "atom_indices": [12, 13],
        "unit_id": 3
    },
    {
        "fg_id": 1,
        "type": "carbonyl",
        "atom_indices": [47, 48],
        "unit_id": 8
    }
]
```

而3D聚合物结构包含：

```
positions.shape = [N_atoms, 3]
```

就可以通过 `atom_indices` 读取对应原子坐标。

唯一需要特别保证的是：**2D结构和3D结构的原子编号必须经过映射与验证**。不能因为二者化学结构相同，就默认原子顺序相同。

另外，含氢键分析最好保存显式氢的坐标。如果原始结构没有氢原子，只能先生成并优化氢位置，或者使用不依赖显式氢的近似识别规则。

三、最关键：Functional Group Pair 的3D相互作用如何提取?

我建议使用三个层级的信息：

Level A：Atomic Geometry
从组成两个官能团的原子对提取几何关系

Level B：Chemical Interaction
判断潜在氢键、离子、芳环及一般接触

Level C：Learnable Pair Embedding
学习原子对如何组合为高阶官能团关系

3.1 Level A：原子对3D距离矩阵

两个官能团分别包含 m, n 个原子。

先计算跨官能团的原子距离矩阵：

$$D_{ij} = [d_{ab}]_{m \times n}$$

其中

$$d_{ab} = \|\mathbf{r}_a - \mathbf{r}_b\|_2$$

从中提取：

几何特征	定义或意义
最小原子距离 $d_{\min}$	判断两个官能团最近能接触到什么程度
平均距离 d_{mean}	描述原子对整体空间分布
质心距离 d_{center}	辅助衡量官能团总体相对位置
距离分布 $H(D)$	用RBF或直方图保留多个原子距离
接触原子对数量 N_{contact}	描述多点接触程度
相对方向与取向	判断氢键、π–π等有方向性的作用

例如，最小距离为：

$$d_{\min}(FG_i, FG_j) = \min_{a \in FG_i, b \in FG_j} d_{ab}$$

但只采用最小距离会损失很多信息。

两个官能团可能具有相同的 $d_{\min}$，却具有完全不同的取向。因此，我建议保留完整的局部原子对距离分布，再通过模型学习聚合。

3.2 Level B：识别潜在非共价相互作用

这一部分可以参考 ProLIF 的规则。

作用类型	最关键的特征	初期实现
氢键	D–A距离 + D–H···A角度	基于供受体原子识别与几何规则
π–π	环心距离、环面夹角、错位距离	芳香环原子拟合平面
静电相互作用	部分电荷、距离、电荷分布	以电荷和几何描述符表示
离子配对	正负电荷中心和距离	明确带电位点 + 几何判据
一般接触	原子间距离、范德华半径	原子接触检测
偶极相关作用	局部偶极方向与相对位置	需要合理电荷模型或偶极估计

以氢键为例，可以使用一个初始规则：

$$I_{\mathrm{HB}} = 1(d_{DA} < 3.5\ \text{Å}) \cdot 1(\theta_{DHA} > 130^\circ)$$

ProLIF 文档中的一种默认氢键规则正采用3.5 Å和130°–180°的几何范围。 ProLIF docume...

但这些阈值仅适合用作起始配置，应根据官能团化学、力场和研究体系重新验证。

如果只拥有单个3D构象，那么提取的应称为 **interaction geometry / potential interaction indicators**，不应直接称为经过验证的真实相互作用强度。

3.3 Level C：学习官能团Pair的Embedding

这里是我认为最值得重点设计的模型模块。

不要仅使用手工统计的距离，而要让模型从组成FG Pair的全部原子对中学习其空间作用模式。

设Atom Encoder已经得到原子表征：

$$\mathbf{h}_a, \quad \mathbf{h}_b \in \mathbb{R}^d$$

对两个官能团中的每个跨组原子对构建：

$$\mathbf{z}_{ab} = \mathrm{MLP}\left(\mathbf{h}_a \| \mathbf{h}_b \| \mathrm{RBF}(d_{ab}) \| \mathbf{c}_{ab}\right)$$

其中：

- $\mathbf{h}_a, \mathbf{h}_b$：原子化学环境特征；
- $\mathrm{RBF}(d_{ab})$：原子距离的径向基展开；
- $\mathbf{c}_{ab}$：供受体身份、键型相关属性或角度等辅助信息；
- $\|$：特征拼接。

然后使用一个 Atom-Pair Attention 模块：

$$\alpha_{ab} = \frac{\exp(s_{ab})}{\sum_{u \in FG_i, v \in FG_j} \exp(s_{uv})}$$

$$\mathbf{h}_{ij}^{FG-Pair} = \sum_{a \in FG_i} \sum_{b \in FG_j} \alpha_{ab} \mathbf{z}_{ab}$$

其中 s_{ab} 为一个可学习的原子对评分。

这意味着模型能够根据化学环境和空间几何，对官能团间不同原子对赋予不同的重要性。

例如羟基–羰基这一FG Pair中，O–H···O相关的原子对及其角度可能比其他C–C接触更重要。

但这些注意力权重只能说明模型所学习的相对重要性，不能直接当作相互作用能。

如果你的任务预测的是旋转不变的标量性质，那么以距离、角度余弦等不变量编码是一个适合的起点。如果需要学习方向性向量输出或力，则进一步考虑E(3)等变模块。

3.4 我更推荐双通道FG Pair表征

不要让模型完全依赖人工规则，也不要完全依赖黑箱Attention。

建议：

$$\boxed{\mathbf{h}_{ij}^{FG} = \mathrm{Fusion}\left(\mathbf{h}_{ij}^{\mathrm{learned}}, \mathbf{h}_{ij}^{\mathrm{physical}}\right)}$$

其中：

$$\mathbf{h}_{ij}^{\text{learned}} = \text{AtomPairAttention}\left(\{\mathbf{z}_{ab}\}\right)$$

$$\mathbf{h}_{ij}^{\text{physical}} = \text{MLP}\left(d_{\min}, H(D), I_{HB}, I_{\pi\pi}, I_{\text{ionic}}, \ldots\right)$$

这相当于将 **可学习的原子对几何关系** 和 **可解释的化学作用规则** 结合起来。

两条通道并不是重复的：第一条学习规则未明确覆盖的复杂局部关系，第二条提供化学先验和可解释性。

四、如何把FG Pair进一步映射到Repeat Unit Pair?

这一步非常重要，因为你既然已经设计了Repeat Unit Level，就不应该让FG Pair与Unit Pair成为两条完全独立的路径。

假设一个聚合物包含 $U_1, U_2, \ldots, U_L$ 个Repeat Units。

每个Unit包含一个或多个官能团：

$$U_i = \{FG_{i1}, FG_{i2}, \ldots, FG_{im}\}$$

对于两个Repeat Units U_i, U_j，它们之间可能存在多种官能团Pair相互作用。

因此可以定义：

$$\mathbf{h}_{ij}^{UnitPair} = \text{Aggregate}\left(\left\{\mathbf{h}_{pq}^{FGPair} \mid FG_p \in U_i, FG_q \in U_j\right\}\right)$$

建议使用Attention Pooling，并额外融合Unit本身的几何和拓扑关系：

$$\mathbf{h}_{ij}^{UnitPair} = \text{MLP}\left(\text{AttnPool}(\{\mathbf{h}_{pq}^{FGPair}\}) \| \mathbf{g}_{ij}^{Unit}\right)$$

其中 $\mathbf{g}_{ij}^{Unit}$ 可以包含Unit质心距离、最小原子距离、沿链间隔等特征。

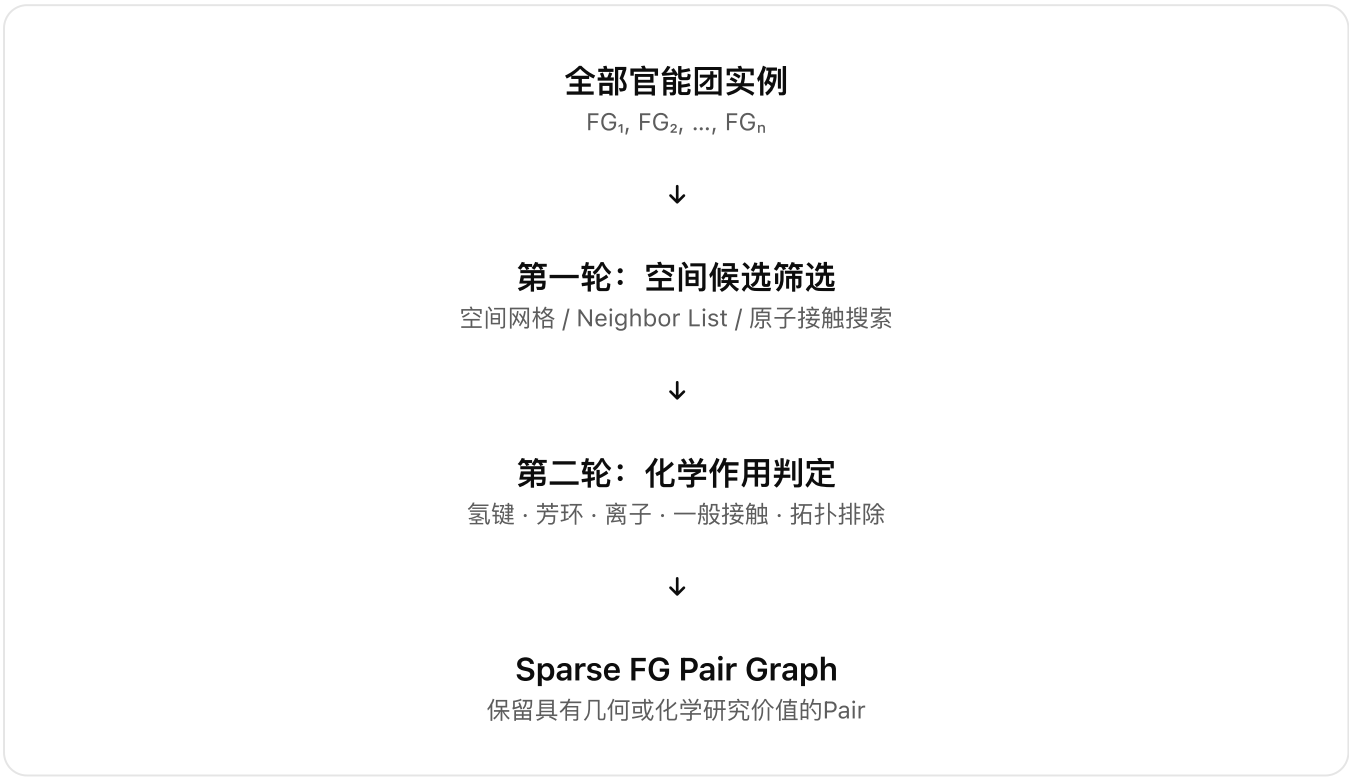
这里有两个值得注意的问题：

- 一个Unit可能不含被识别出的目标官能团，因此不能完全依赖FG Pair构建Unit Pair，应保留骨架原子提供的几何信息。
- 如果官能团跨越两个Unit的分界，应事先规定归属或采用明确的分数归属机制，避免在Pair聚合时重复计数。

五、聚合物很长时，怎样筛选FG Pair?

不建议计算所有官能团之间的完整Pair矩阵，因为复杂度会接近 $O(N_{FG}^2)$。

我建议采用你之前考虑过的贪心思想，但要改为 **两阶段稀疏Pair筛选（Geometry-guided Sparse Pair Selection）**。



具体可以这样实施：

第一步：生成空间候选对

使用空间网格或邻居搜索寻找距离处于指定范围内的原子对，再通过 `atom_to_fg` 映射聚合成官能团Pair。

这样比遍历所有官能团组合更加高效，也不会因为两个官能团质心较远而漏掉末端接触。

MDAnalysis的 `capped_distance` 支持按截断距离搜索原子对，并能够在提供模拟盒信息时使用周期性边界下的最小镜像距离。 MDAnalysis 2.1...

第二步：对候选FG Pair进行化学与拓扑判断

对每个候选Pair，记录：

- 属于同一Unit、同一链不同Unit，还是不同链；
- 两个官能团在共价图上的最短拓扑距离；
- 是否满足指定的相互作用规则；
- 距离与方向几何特征。

对于同链且共价连接很近的官能团，应根据任务将其标记或从非共价作用统计中排除，而不是一律把接近认定为有意义的空间作用。

第三步：按照Pair预算进行筛选

例如每个官能团保留至多 K 个主要空间邻居。初期可以测试 $K = 8, 16, 32$，但这些只是模型效率超参数，并不是通用物理常数。

不能单纯保留最近的K个邻居。我建议使用分类预算，避免氢键候选等重要化学作用被大量普通接触挤掉。还可以保留部分接近截断距离的候选，避免模型只学到最短距离。

六、你的3D数据属于哪种情况，会直接决定能提取什么

这一点尤其需要结合你现有的聚合物预训练数据。

数据情况	可以可靠提取的信息	不应该直接声称能够得到的内容
SMILES + 单个3D构象	官能团身份、距离、相对取向、几何接触、潜在作用类型	动态寿命、真实作用自由能
SMILES + 多个独立构象	构象相关的FG Pair分布、跨构象稳定性	没有时间轴时不能统计真实动力学寿命
单链MD轨迹	链内作用占有率、接触持续时间、伙伴交换	凝聚态链间作用
多链MD轨迹	链内与链间作用、动态图、网络连通性	无额外计算时不能直接得到精确结合自由能

如果你目前用于预训练的数据主要是**单链3D聚合物构象，且不同聚合物的DP不固定**，那么第一阶段完全可以不进行MD：

先提取3D几何关系，构建FG Pair Embedding，训练模型学习官能团的空间接近、取向与局部相互作用模式。

随后再采用少量多链MD轨迹，对模型是否识别出合理的氢键和链间接触趋势进行验证。

尤其要注意：如果原始数据只有一个构象，模型学习的是该构象中存在的几何关系，不能直接推断整个聚合物材料的稳定空间网络。

七、适合你的第一版模型实现方案

我建议先把整个模型拆为以下模块：

模块	输入	输出	推荐方法

Atom Encoder	原子、键、3D坐标	h_a	3D GNN
Functional Group Assignment	原子连接拓扑	FG原子集合	EFGs + SMARTS
FG Node Encoder	FG所属原子表征	h_{FG}	Attention Pooling
FG Pair Constructor	FG原子坐标和化学属性	稀疏FG Pair列表	Spatial Neighbor Search
FG Pair Encoder	原子对距离、角度、作用特征	h_{FGPair}	Atom-Pair Attention
Unit Encoder	重复单元所属原子及FG	h_U	Hierarchical Pooling
Unit Pair Encoder	FG Pair + Unit几何关系	$h_{UnitPair}$	Cross-Level Attention
Representation Fusion	各层Node/Pair特征	Polymer Embedding	Hierarchical Interaction

在训练阶段，可以考虑三组自监督任务：

1. **Masked FG-Pair Geometry Prediction**：遮蔽部分原子对距离或取向特征，让模型预测距离区间、RBF分布或角度区间，避免只记忆连续坐标的细小差异。
2. **Functional Interaction Classification**：以几何与化学规则生成弱标签，训练模型识别候选氢键、芳环接触、离子配对等；它衡量的是规则一致性，并不独立证明真实作用能。
3. **FG Pair–Unit Pair Consistency**：将FG Pair聚合出的Unit Pair表示，与Unit原子层独立提取的几何表示对齐，促进跨层级信息一致。

为了证明官能团层级确实提供增量价值，建议至少比较三组消融：仅Atom/Unit、加入纯距离FG Pair、加入距离+方向+化学规则的FG Pair。

八、一个非常关键的建模选择：物理规则还是端到端学习？

三种FG Pair建模策略对比

- 基于物理化学规则
- 纯3D原子对学习
- 规则 + 可学习几何融合（推荐）

Physics-informed FG Pair Learning

原子对Attention学习连续几何关系，化学规则提供供受体、芳香环和带电位点等结构化信息，最后进行融合。

优势是兼顾可学习性、化学解释性和对不同聚合物体系的适应性。建议先用这一方案做主模型。

最终建议

对于你的分层聚合物模型，我推荐将官能团模块设计成：

$$\begin{array}{|c|}\hline \text{Atom Features} + \text{3D Coordinates} \\ \downarrow \\ \text{Functional Group Assignment} \\ \downarrow \\ \text{Sparse Atom-Pair Geometry} \\ \downarrow \\ \text{Chemical Interaction Encoding} \\ \downarrow \\ \text{Learnable FG Pair Embedding} \\ \downarrow \\ \text{Repeat Unit Pair Aggregation} \\ \hline \end{array}$$

最值得投入研究的模块是 **3D Geometry-aware Functional Group Pair Encoder**。

它既利用Atom Level输出的原子特征，又通过物理几何信息形成新的官能团Pair关系，再进一步向Repeat Unit Pair汇总，而非独立重复进行一次3D GNN消息传递。

还有一个需要你重点决定的问题：FG Pair到底应该只学习官能团之间的非共价空间作用，还是同时学习官能团之间的化学连接和非共价空间作用?

我的建议是两者都保留，但构建成不同的边类型（Covalent/Topological Edge 与 Spatial/Noncovalent Edge），分别编码后再融合。这样既保留了聚合物的序列信息，也不会把沿链相邻的共价结构误认为空间相互作用。

参考实现：EFGs官能团提取代码 ↗（论文见 ACS Publicatio... ）、ProLIF相互作用检测文档 ↗。