你说：

Professor LIU Shengchao 香港中文大学，他们团队发表的论文分析，有没有好的insights

思考了 3m 8s >

ChatGPT 说：

香港中文大学刘圣超教授团队论文分析：对聚合物 3D 表征的启发



Professor Shengchao Liu（刘圣超）

香港中文大学（CUHK）计算机科学与工程学系助理教授，Wave Intelligence Lab 负责人。

研究方向：Geometric Representation Learning、Physics-inspired AI、Molecular Pretraining、Generative Modeling、AI for Chemistry / Materials / Biology。 CUHK CSE +1

完整论文列表 ↗ · 个人主页 ↗

一、总体判断

结合你目前正在设计的聚合物表征模型——**Atom Level + Functional Group Level + Repeat Unit Level + 3D GNN/Ewald MP + 跨层信息交互**——我认为刘圣超教授及其合作者的研究非常值得系统学习。

他们的工作不是直接针对聚合物性质预测，而是沿着几条相互关联的路线发展：

- **GraphMVP / GeoSSL：** 如何利用 3D 几何信息学习更好的分子表示。
- **MoleculeSDE / NeuralMD：** 如何利用对称性和动态信息理解分子。
- **RigidSSL：** 如何利用刚性结构、柔性运动与构象集合学习几何表示。
- **Geom3D：** 如何公平比较不同几何深度学习模型。
- **InertialAR / AssembleFlow：** 如何更高效地表示和生成 3D 结构。

其中，**RigidSSL（2026）、GeoSSL（2023）、NeuralMD（2025）和 GraphMVP（2022）**是我建议你优先研究的四项工作。

对你最有价值的启发不是直接复制他们的网络，而是将聚合物的物理结构特征转化为模型的归纳偏置：

把刚性/柔性、局部/长程作用、拓扑/空间关系和构象变化显式融入表示学习，而不只是增加 GNN 层级。

这里将同时分析刘教授在加入 CUHK 前参与的代表性工作，以及 CUHK 任职期间的新成果，不把所有论文都归为其现有实验室独立完成。

二、代表性论文及阅读优先级

以下按与你当前课题的相关程度排序，而不是按发表时间排序。

论文	核心方法	对聚合物研究的启发	优先级
RigidSSL ↗ (ICLR 2026)	刚性结构感知、构象预训练	刚柔片段、构象变化、物理约束	★★★★★
GeoSSL ↗ (ICLR 2023)	3D 距离去噪、自监督学习	Atom Pair / FG Pair 预训练	★★★★★
NeuralMD ↗ (Nature Communications 2025)	多粒度几何网络、动力学方程	多层级建模、跨尺度相互作用	★★★★★
GraphMVP ↗ (ICLR 2022)	2D–3D 多视图预训练	拓扑与 3D 空间表征对齐	★★★★★
DuetRNA ↗ (2026 预印本/Workshop)	双坐标框架、结构耦合	FG 与 Unit 的不同物理角色	★★★★☆
Geom3D ↗ (NeurIPS 2023)	3D 模型统一 benchmark	Baseline 选择与公平对比	★★★★☆
MoleculeSDE ↗ (ICML 2023)	对称性约束、2D↔3D 生成	结构跨模态预训练	★★★★☆
InertialAR ↗ (ICML 2026)	惯性坐标系、3D 自回归生成	长链结构标准化与生成	★★★☆☆
ChatBattery ↗ (2025 预印本)	专家知识引导的 AI 材料发现	聚合物设计、理论计算与实验闭环	★★★☆☆

论文及发表信息已对照作者主页与论文原文。 Shengchao … +2

三、最值得深入分析的四篇论文

1. RigidSSL：从原子级建模转向刚性结构感知

最值得借鉴 ICLR 2026

论文的出发点

很多几何模型在原子层级学习距离和方向，但对复杂大分子而言，并非所有局部原子运动都同样重要。

RigidSSL 以蛋白质残基为近似刚体，每个残基通过位置和平面外方向（即平移与旋转）描述。这样可以在减少自由度的同时保留整体几何特征。

其方法包含两个阶段：



作者采用双向刚体 Flow Matching，对平移与旋转的变化进行建模，报告蛋白质生成任务的设计成功指标最高改善 43%。这是蛋白质生成结果，并不意味着能够直接提升聚合物性质预测相同比例。 arXiv +1

对你的模型的 Insight

你的 FG Level 目前主要按化学规则提取官能团，再构建 FG–FG 空间关系。

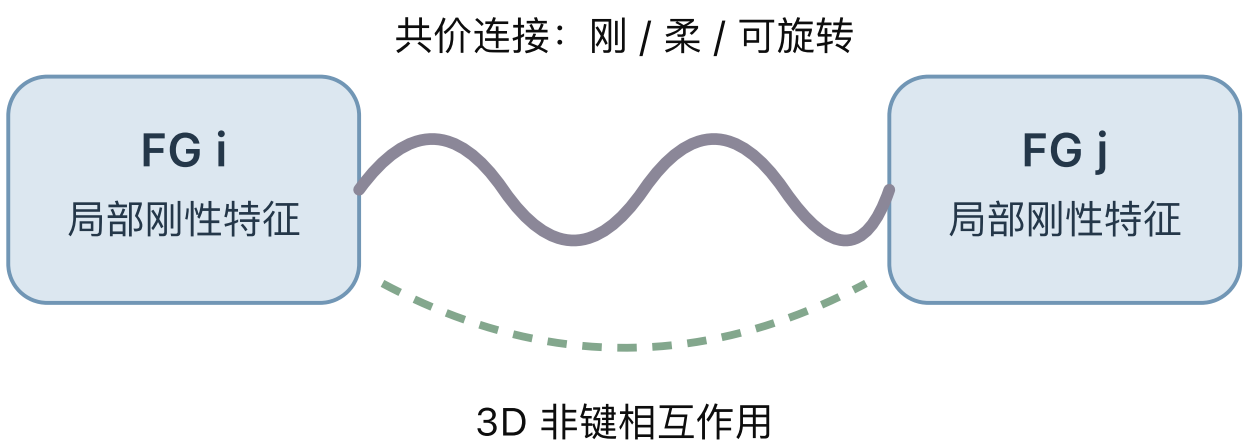
但是，**官能团不一定等于刚性片段。**

例如：

- 苯环：具有较明确的刚性几何结构。
- 羰基：局部具有平面特征。
- —CH_2—CH_2—：可绕单键旋转，属于典型柔性连接。
- —O—CH_2—CH_2—O—：包含多个可旋转键，空间构象变化更丰富。

因此，可以让原有 FG 图的节点和边具有刚柔属性，而不必新增独立的第四层级。

建议的 FG 表示方式



原图层级不变，只在 FG 节点引入局部刚性，在边上区分共价连接与空间接触。

可以采用：

$$h_{FG_i} = \mathrm{Pool}_{a \in FG_i}(h_a)$$

然后将局部几何刚性描述符拼接到 FG 表示中：

$$\widetilde{h}_{FG_i} = \mathrm{MLP}([h_{FG_i} \| r_i])$$

其中 r_i 可以表示环结构、平面性、局部可旋转键数量等。FG–FG 边进一步编码连接键类型、旋转自由度及空间距离。

需要特别注意： RigidSSL 对蛋白质残基采用刚体近似。聚合物中的醚链、酯链等并不能直接按同样方式整体视为刚体。需要先依据化学结构定义刚性片段，再处理柔性连接。

2. GeoSSL：让模型真正学习 3D 空间关系

核心问题： 如果只有聚合物 3D 坐标，没有足够的性质标签，能否先学习有物理意义的几何表示?

GeoSSL 的思路是对分子结构施加噪声，让模型学习恢复分子原有的空间关系。

相较于直接预测原子坐标，GeoSSL-DDM 将学习目标转化为**原子对距离的去噪**，使目标天然满足旋转和平移不变性。 arXiv +1

这是最容易移植到你现有 Atom Pair 和 FG Pair 设计中的预训练思想。

例如，对原子对距离：

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|_2$$

加入噪声：

$$\tilde{d}_{ij} = d_{ij} + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

训练网络学习其恢复目标：

$$\mathcal{L}_{\text{dist}} = \frac{1}{|\mathcal{P}|} \sum_{(i,j)\in\mathcal{P}} (\hat{d}_{ij} - d_{ij})^2$$

这是建议你实现的**简化距离重建损失**，而不是 GeoSSL-DDM 原论文完整的多噪声尺度 Score Matching 目标。

对你的模型还可以增加：

$$\mathcal{L}_{\text{FG-pair}} = \frac{1}{|\mathcal{P}_{FG}|} \sum_{(u,v)\in\mathcal{P}_{FG}} (\hat{d}_{uv} - d_{uv})^2$$

其中 d_{uv} 可以采用 FG 原子集合之间的最小距离、质心距离或其他定义清楚的几何描述符。

这能使你的 FG 模块不仅学习有哪些官能团，还学习它们在聚合物折叠时如何空间接近。

注意：若 FG Pair 表征包含方向性氢键或 π–π 相互作用，仅预测标量距离仍然不够，需要额外引入方向、夹角与法向量关系。

3. NeuralMD：多层级必须服务于特定的物理交互

核心创新

NeuralMD 并不是简单把蛋白质拆成几个层级后进行特征拼接。

它的 BindingNet 使用三种粒度的几何参考框架：配体原子、蛋白质骨架以及蛋白质–配体相互作用。然后将预测的作用力连接到二阶 ODE/SDE 中，学习随时间演化的坐标轨迹。 arXiv +1

对你的启发是：

不同的层级应该解决不同的物理问题，而不是每一层重复执行相同的 GNN。

你的层级	建议承担的职责
Atom Level	原子类型、局部键环境、短程几何
FG Level	化学作用位点、极性、氢键能力、刚柔特征
Repeat Unit Level	单元组成、序列位置、结构传播
FG Pair	非键接触、空间取向、局部相互作用
Unit Pair	链折叠带来的较大尺度空间组织
Inter-level	将原子局部信息与单元结构信息相互增强

这会让你的多层级设计具有更清晰的化学和物理解释。

而且可以借鉴 NeuralMD 的一个原则：**细粒度信息应当有选择地上送到更大尺度，不必在整个聚合物链上计算所有原子对。**

4. GraphMVP：把 2D 化学结构与 3D 构象关联起来

GraphMVP 的目标是通过 2D 分子拓扑与 3D 几何的多视图自监督学习，让 2D 编码器获得更丰富的空间信息。

它采用基于能量模型的对比学习以及变分表示重建等目标，实现两种视图间的信息对齐。

Shengchao Liu

对聚合物尤其值得考虑，因为 2D 和 3D 所表达的信息不同：

- 2D：重复单元的化学连接、官能团、序列和结构组成。
- 3D：同一条链在特定构象下的折叠、邻近关系和非键相互作用。

我建议将其发展为拓扑与几何的双分支：

$$h_{2D} = f_{\text{topology}}(G)$$

$$h_{3D} = f_{\text{geometry}}(G, X)$$

再在预训练阶段引入一个对齐目标：

$$\mathcal{L}_{\text{align}} = \text{InfoNCE}(h_{2D}, h_{3D})$$

这里不能盲目要求所有构象完全一致，因为相同化学拓扑下不同构象可能对应不同空间接触和性质。更合理的是保留稳定的化学信息，同时允许构象敏感的表示随 3D 结构改变。

四、2026 年的新论文还有两个特别值得注意的 Insight

5. DuetRNA：同一个结构单元，可能需要两种几何表征

DuetRNA（2026）研究 RNA 的序列和结构联合生成。

作者发现，用一个坐标参考框架难以同时准确描述 RNA 中碱基之间的相互作用，以及糖-磷酸骨架的几何结构。因此，他们提出两个相互耦合的局部参考框架，分别表征碱基和骨架。

GitHub +1

这与你目前的 FG Level 和 Unit Level 设计特别契合。

你可以从中提炼出一个观点：

> 聚合物中的化学作用位点和主链几何结构承担不同的物理功能，因此应当允许它们形成互补的几何表示。

例如，含羰基的聚合物重复单元：

FG 分支 重点理解 C=O 的局部取向、偶极特征以及与邻近 FG 的空间关系。

Unit 分支 重点理解重复单元在主链中的位置、连接方向和链的整体构象。

两条分支分别编码，然后在 Fusion 阶段结合。

这实际上支持了你目前计划采用的架构：



这里借鉴的是“按物理角色分解表征”的思想，不意味着你必须像 DuetRNA 一样引入两个 SE(3) 刚体坐标框架。

6. Geom3D：比直接选择一个 SOTA 更重要的是建立统一评测体系

Geom3D（NeurIPS 2023）将 3D 几何表示方法分为不变性模型、基于球谐基的等变性模型和基于向量参考框架的等变性模型，并提供统一实验平台，覆盖 16 个几何表征模型、14 种几何预训练方法和 46 个数据集。 arXiv

对你目前在 OMersBench 上开发模型，我建议借鉴它的研究方法，而不是把 Geom3D 当作某一个模型使用。

具体来说，在已有 RDKit-RF、PolyBERT、PCP、PPG 的基础上，选择 SchNet、PaiNN 以及一个角度感知的 3D 模型作为新增 baseline 候选。最终模型是否适合作为基线，仍取决于你是否拥有完整 3D 构象、输入结构大小和目标性质。

而 Ewald MP 的作用是补充长程消息传递。原论文已经在周期和非周期几何数据上验证了这一方向，但不能直接推断它对聚合物性质预测一定有增益。 Proceedings of...

五、我认为最有潜力的创新方向

比较完这些论文，我最看好的并不是构建更多层级，而是下面三个可以单独验证的研究假设。

Hypothesis 1 — Chemistry-aware Spatial Interaction

相比直接在所有原子对之间学习空间关系，利用官能团化学身份约束 FG–FG 空间相互作用，可能以更低的计算成本获取与聚合物性质更相关的特征。

这适合验证你目前的 FG Pair 设计是否真正带来了有效信息，而不是重复 Atom Level 的表示。

Hypothesis 2 — Rigidity/Flexibility-aware Representation

把聚合物的刚性化学片段和柔性连接纳入 FG Graph，可能更好地区分“化学结构相近但链构象不同”的聚合物。

不需要额外增加刚性片段层级。首先在 FG 节点或 FG–FG 边中融入刚柔信息，再通过消融实验判断其贡献。

Hypothesis 3 — Conformation-aware Self-supervised Learning

针对缺少性质标签、但有 3D 结构的聚合物数据，先通过 Atom Pair 与 FG Pair 的几何预训练学习空间特征，再进行性质预测微调。

如果同一种聚合物具有多个构象，可以进一步学习构象之间保持稳定的化学信息，以及随构象变化的空间接触信息。

六、怎么落实到你现在的实验?

我建议先不要直接照搬 RigidSSL 的 Flow Matching 或 NeuralMD 的动力学求解器。两者都比较复杂，而且它们原本解决的是蛋白质结构生成或动力学预测，并不是聚合物性质预测。

先通过小规模、可解释的消融实验逐步验证：

实验	模型变化	想回答的问题
E0	2D Baseline	不使用 3D 能达到什么水平?
E1	Atom 3D GNN	3D 几何是否真的有效?
E2	Atom + Unit + Inter-level	多层级交互是否有效?
E3	E2 + FG Level	加入官能团信息是否有效?
E4	E3 + FG Spatial Pair	空间非键关系有无贡献?
E5	E4 + Rigidity/Flexibility	刚柔特征是否有额外贡献?
E6	E5 + Geometric Pretraining	预训练能否缓解小数据问题?
E7	E6 + Ewald MP	长程消息传递是否提供独立增益?

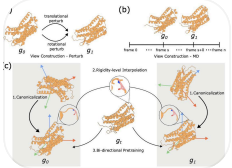
所有实验保持相同的数据划分、训练预算和评价指标。除 RMSE / MAE 外，建议同时记录模型参数量、训练耗时和推理成本。

另外，与你最近分析的 OMersBench 数据相关，还有一个重要问题：**如果目标性质来自多链 MD 体系，那么单条聚合物链的 3D 表示未必包含足够信息来预测该性质。**

因此，需要区分链内结构敏感的性质与依赖链间堆积、密度、温度或其他模拟条件的性质。对于后者，最终可能需要构象集合或多链体系表征，而不是单链的一个静态构象。

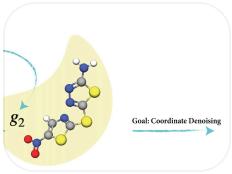
七、最终推荐

如果只选三篇论文做深入的代码级研究，我会选择：



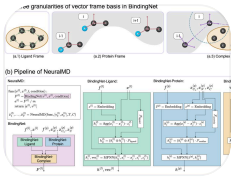
1. RigidSSL ↗

重点理解如何以物理结构为依据构建 3D 表征，以及如何组织静态与动态预训练数据。



2. GeoSSL ↗

重点研究 Pair Distance Denoising 的损失设计、3D 几何预训练与小数据迁移。



3. NeuralMD ↗

重点研究多粒度表示的物理依据，以及如何让不同层级的信息参与不同的相互作用建模。

我的整体判断是：你的模型目前不缺层级，最需要加强的是每个层级的物理含义、信息是否互补，以及几何信息如何通过训练目标真正进入表示。

刘圣超教授这条研究路线给你的最大启发就是：**从物理问题出发设计 Representation，再选择合适的网络和训练目标，而不是先设计复杂网络再寻找物理解释。**

下一步最值得深入的主题：

精读 RigidSSL 的方法与公式 ↗

设计聚合物模型改进方案 ↗

你说：

详细精读刘圣超团队的 RigidSSL 论文，分析完整算法、公式、输入输出、训练流程，以及如何迁移到聚合物刚柔片段表征。

思考了 4m 3s >

ChatGPT 说：

RigidSSL 论文精读：完整算法与聚合物刚柔片段表征迁移

论文：Rigidity-Aware Geometric Pretraining for Protein Design and Conformational Ensembles · ICLR 2026

作者： Zhanghan Ni、Yanjing Li、Zeju Qiu、Bernhard Schölkopf、Hongyu Guo、Weiyang Liu、Shengchao Liu

原始资料： 论文全文（2026年10月18日修订版） ↗ · 官方 GitHub ↗ · 项目主页 ↗

本文将严格区分两部分：**RigidSSL 原论文真正实现的算法**，以及**针对你目前 Atom–FG–Unit 聚合物 3D 表征模型提出的改进方案**。后者是研究设计建议，并非论文已有实验结果。

一、先明确 RigidSSL 究竟解决了什么问题

RigidSSL 的目标不是直接预测材料性质，而是先让模型学习蛋白质的几何结构和构象变化，再将预训练好的编码器用于蛋白质结构生成。

论文认为，现有方法存在三个问题：

1. 直接从头训练生成模型，需要同时学习基础几何知识和复杂的结构生成规律。
2. 原子级表示计算成本高，而且单纯依靠局部特征未必能充分描述大分子的整体几何。
3. 大规模静态结构数据虽然丰富，但无法完整表达分子真实的柔性和动态构象。

因此，作者提出了三个互相配合的核心设计：**刚体表示、双向几何 Flow Matching、静态到动态的两阶段预训练。** arXiv

1.1 一个重要概念：RigidSSL 不是在自动寻找刚性片段

这是理解该论文时最容易误解的地方。

RigidSSL 直接利用蛋白质已有的化学层级，将每个氨基酸残基的主链部分近似表示为一个刚体。

它并没有提出一种通用的算法，自动识别任意有机分子或聚合物中的刚性片段和柔性连接。

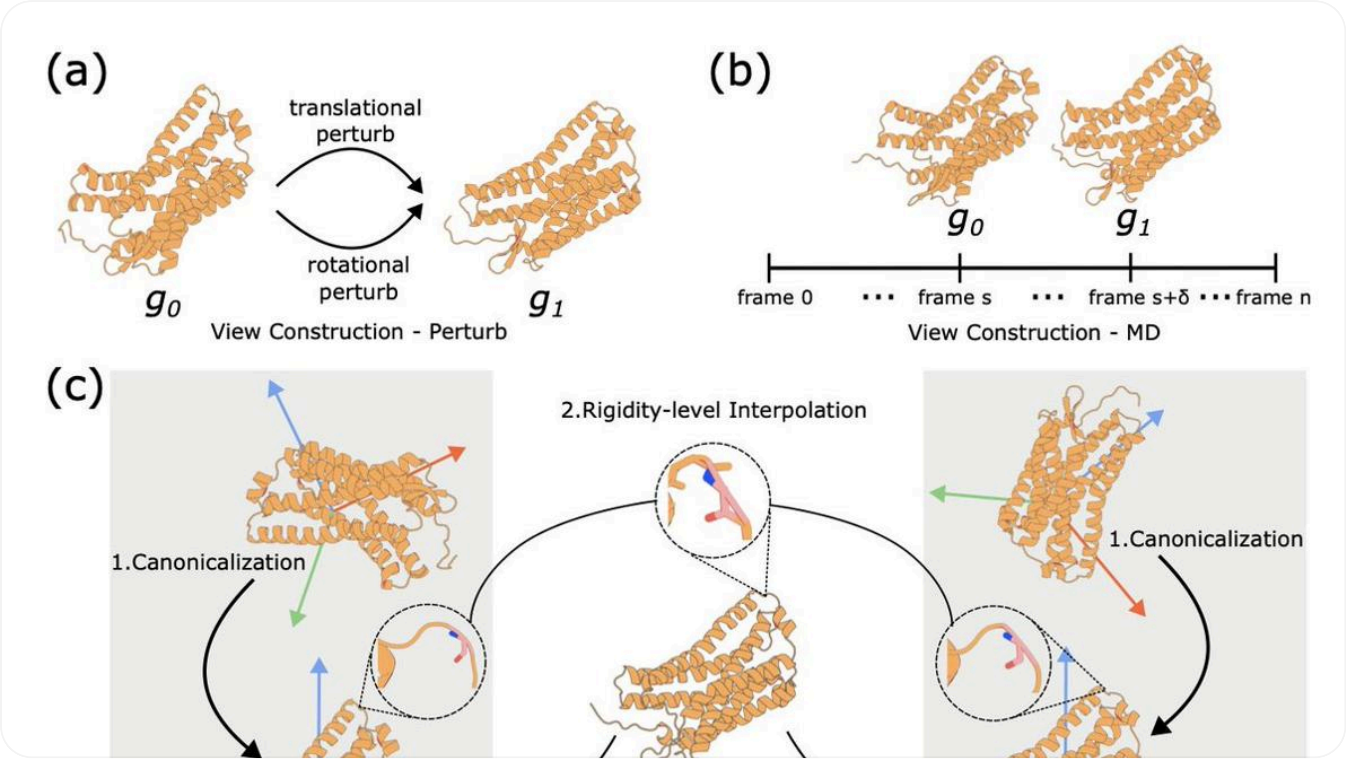
需要区分的概念	RigidSSL 实际做法
刚体划分	采用蛋白质残基的已知结构
刚体描述	一个平移向量 + 一个旋转矩阵
柔性表达	不同残基刚体之间的相对位置和取向变化
几何学习	学习刚体之间的平移与旋转运动
预训练目标	双向刚体 Flow Matching
下游任务	蛋白质结构生成与构象集合生成

因此，对你的聚合物模型而言，真正值得迁移的是：

先根据化学知识识别适合刚体近似的结构区域，再利用 3D 几何建模这些区域之间的空间组织和柔性运动。

并不意味着把所有官能团都当作刚体。

二、RigidSSL 的总体架构



论文 Figure 1 主要展示两种视图构造方法和共享的刚体几何预训练流程。

原论文的训练流程可以整理为：

Phase I — Perturb

432,194 个静态蛋白质结构

人工平移、旋转扰动

Phase II — MD

约 1,390 条蛋白质 MD 轨迹

采样有时间间隔的构象对

↓

Rigid Body Representation

每个残基：位置 t + 取向 R

↓

Canonicalization

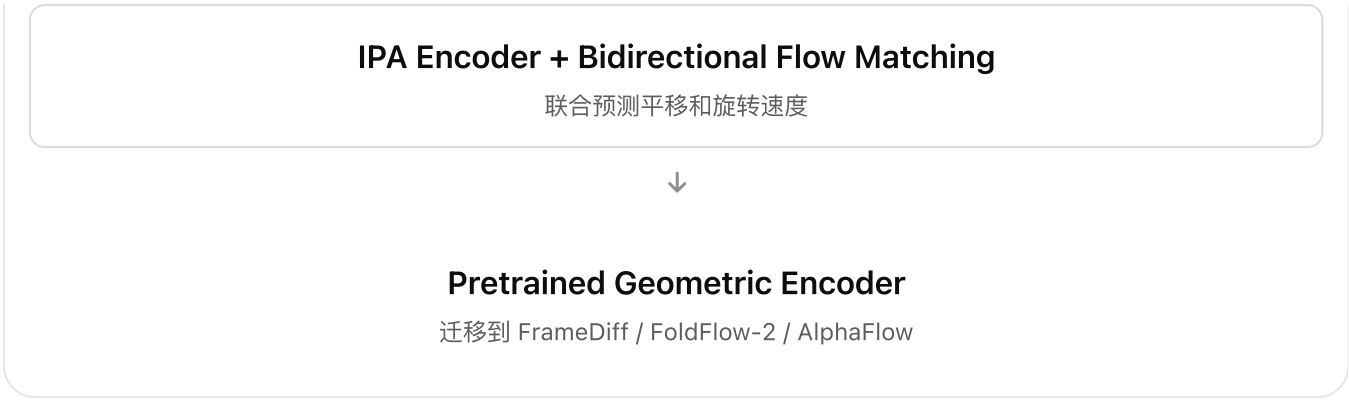
中心平移 + 惯性主轴对齐

↓

Rigid Interpolation

Translation：LERP / Rotation：SLERP

↓



有一个顺序需要说明：在完整训练中，**Phase II 使用 Phase I 学到的参数继续预训练**。上图的两个数据分支表达的是两种构造训练样本的方法，并不是两个完全独立、最后才融合的网络。

论文的核心是预训练 IPA（Invariant Point Attention）几何编码模块，而不是发明一种全新的 3D GNN。 arXiv +1

三、核心算法精读：从原子坐标到刚体表示

3.1 为什么要从 Atom Coordinates 转为 Rigid Frames?

普通的 3D GNN 直接使用所有原子的三维坐标：

$$X = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}, \qquad X \in \mathbb{R}^{N\times 3}$$

但对于蛋白质，主链的局部键长和键角通常变化较小，大量构象差异来自主链二面角变化。

因此 RigidSSL 采用一个近似：把每个残基的主链视为刚体。

对于 L 个残基：

$$g = \{T_i\}_{i=1}^{L}$$

每个刚体由平移和旋转组成：

$$\boxed{T_i = (\mathbf{t}_i, R_i)}$$

其中：

- $\mathbf{t}_i \in \mathbb{R}^3$：刚体的位置。
- $R_i \in SO(3)$：刚体的空间取向。
- $SO(3)$：三维旋转矩阵组成的特殊正交群。

一个旋转矩阵必须满足：

$$R_i^\top R_i = I, \qquad \det(R_i) = 1$$

这里刚体表示的自由度是 6，即 3 个平移自由度和 3 个旋转自由度；虽然旋转矩阵用 9 个数字保存，但它只有 3 个独立自由度。

3.2 如何构建一个刚体的局部坐标系?

原论文 Appendix C.1 使用每个残基主链的三个原子：

$$N, \quad C_\alpha, \quad C$$

取三个原子的坐标：

$$\mathbf{x}_1 = \mathbf{x}_N, \quad \mathbf{x}_2 = \mathbf{x}_{C_\alpha}, \quad \mathbf{x}_3 = \mathbf{x}_C$$

首先将 C_α 作为中心：

$$\mathbf{t} = \mathbf{x}_2$$

再构建正交坐标轴。

第一根轴：

$$\mathbf{e}_1 = \frac{\mathbf{x}_3 - \mathbf{x}_2}{\|\mathbf{x}_3 - \mathbf{x}_2\|}$$

第二根轴通过 Gram–Schmidt 正交化：

$$\mathbf{v}_2 = \mathbf{x}_1 - \mathbf{x}_2$$

$$\mathbf{u}_2 = \mathbf{v}_2 - (\mathbf{v}_2 \cdot \mathbf{e}_1)\mathbf{e}_1$$

$$\mathbf{e}_2 = \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|}$$

第三根轴：

$$\mathbf{e}_3 = \mathbf{e}_1 \times \mathbf{e}_2$$

最终：

$$\boxed{R = [\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3]}$$

由此，三个原子的位置就足以确定残基局部的刚体参考框架。 arXiv

为什么这个操作很重要?

假设同一个刚性片段在三维空间中旋转了 90°，仅使用中心坐标无法知道它的朝向发生了什么变化。

但使用 $(\mathbf{t}, R)$，模型可以同时知道它在哪里、朝向哪里。

这为你之后构建 FG–FG 相互作用中的方向特征提供了参考：两个官能团即便质心距离相同，其相对取向也可能不同。

不过这里有一个限制：当三个原子接近共线时，这种局部坐标系会不稳定，需要额外处理。

3.3 Canonicalization：为什么还要把整个蛋白质对齐?

对同一个蛋白质整体做旋转或平移，不应该改变其内部几何性质。

为消除数据库坐标系的任意性，RigidSSL 采用惯性主轴对齐。

第一步：平移到中心

论文定义：

$$\bar{\mathbf{x}} = \frac{1}{L} \sum_{i=1}^{L} \mathbf{x}_i$$

$$\mathbf{x}_i' = \mathbf{x}_i - \bar{\mathbf{x}}$$

注意这里是残基参考点的算术平均，并非严格按各原子质量加权的质心。

第二步：计算惯性张量

$$\boxed{I = \sum_{i=1}^{L} \left(\|\mathbf{x}'_i\|^2 I_3 - \mathbf{x}'_i \mathbf{x}'^{\top}_i \right)}$$

再特征分解：

$$I = V \Lambda V^{\top}$$

矩阵 V 的特征向量用于确定三个主轴，随后对坐标和局部刚体框架进行全局对齐。

附录还采用特征值排序、右手坐标系约束等操作。 arXiv

需要指出一个技术细节：仅依赖特征向量排序与行列式校正，仍可能存在特征向量符号不唯一的问题；而对于惯性特征值相近的构象，主轴也可能不稳定。

聚合物迁移时不建议无条件照搬这一操作。 长柔性链的构象变化可能导致整体主轴明显转动，甚至翻转，反而给学习引入噪声。可以优先使用 SE(3) 不变/等变特征，或者对构象对采用一致的 Kabsch 对齐。

四、两阶段预训练的数据如何构造?

这部分是 RigidSSL 的主要创新之一。

Phase I：RigidSSL-Perturb

目标：从大量静态结构中学习几何先验。

输入一条蛋白质的刚体序列：

$$g^0 = \{(\mathbf{t}_i^0, R_i^0)\}_{i=1}^{L}$$

然后人为生成另一个扰动视图 g^1。

1. 平移扰动

论文 Equation (3)：

$$\boxed{\mathbf{t}_i^1 = \mathbf{t}_i^0 + \sigma \boldsymbol{\epsilon}_i}$$

$$\boldsymbol{\epsilon}_i \sim \mathcal{N}(0, I_3)$$

每个残基独立采样位移噪声。

2. 旋转扰动

不能直接向旋转矩阵的 9 个元素加高斯噪声，因为那样可能得到不满足 $R^\top R = I$ 的矩阵。

因此作者在 $SO(3)$ 上采样旋转扰动：

$$\Delta R_i \sim \mathcal{IG}_{SO(3)}(I, \varepsilon^2)$$

$$\boxed{R_i^1 = R_i^0 \Delta R_i}$$

这里 $\mathcal{IG}_{SO(3)}$ 表示定义在旋转群上的各向同性高斯型分布。

附录的具体采样过程是：采样随机旋转轴、从相应角度分布采样旋转角，再通过指数映射或 Rodrigues 公式构建旋转矩阵。

所以，每条静态结构就构成了一对几何视图：

$$(g^0, g^1)$$

这对数据不需要性质标签。

Phase II：RigidSSL-MD

目标：用真实的分子动力学轨迹学习结构变化。

对于一条轨迹：

$$\mathcal{T} = \{F^0, F^1, \ldots, F^T\}$$

选择两个间隔固定时间的构象：

$$\boxed{g^0 = F^s, \qquad g^1 = F^{s+\delta}}$$

论文采用：

$$\delta = 2\ \mathrm{ns}$$

这两种视图的区别非常重要：

对比	Phase I	Phase II
数据来源	静态蛋白质结构	MD 轨迹
第二个视图	人工扰动生成	真实模拟采样
保留的主要信息	基础几何规律	物理构象变化
数据规模	432,194 个结构	1,390 条轨迹
可能局限	扰动未必满足所有物理约束	受力场、采样时间、体系条件影响

这也是为什么 Phase II 并不必然比 Phase I 更适合所有下游任务。 arXiv +1

五、最重要的算法：Bidirectional Rigid Flow Matching

下面是论文真正的训练目标。

5.1 为什么使用 Flow Matching?

模型拿到两个刚体构象：

$$g^0, \quad g^1$$

希望能够学习它们之间的变化规律，而不只是学习两个结构的静态相似度。

Flow Matching 的基本思路是：

在两个构象之间构造一条连续路径，再让网络预测这条路径上的运动方向或速度。

注意：论文这里的 Flow Matching 是预训练目标。它并不表示模型直接求解真实的牛顿动力学方程。

5.2 平移插值：LERP

对于刚体 i：

$$\boxed{\mathbf{t}_i^\tau = (1-\tau)\mathbf{t}_i^0 + \tau \mathbf{t}_i^1}$$

其中 $\tau \in [0,1]$。

因此目标平移速度为：

$$\boxed{\mathbf{u}_{i,\text{trans}} = \frac{d\mathbf{t}_i^\tau}{d\tau} = \mathbf{t}_i^1 - \mathbf{t}_i^0}$$

这是线性插值，速度不随 τ 改变。

5.3 旋转插值：SLERP

旋转位于非欧几里得空间中，因此作者使用球面线性插值。

先将两个旋转矩阵转成单位四元数：

$$R_i^0 \to q_i^0, \qquad R_i^1 \to q_i^1$$

然后：

$$\boxed{q_i^\tau = \frac{\sin((1-\tau)\phi)}{\sin\phi} q_i^0 + \frac{\sin(\tau\phi)}{\sin\phi} q_i^1}$$

其中 ϕ 是两个四元数在单位球面上的夹角。

为获得最短旋转路径，实现时通常还要处理 q 与 $-q$ 的等价性。

旋转的目标速度是：

$$\boxed{\mathbf{u}_{i,\text{rot}} = \frac{d}{d\tau}\,\text{SLERP}(q_i^0, q_i^1, \tau)}$$

它描述的是插值四元数沿路径的变化，而不是直接预测一个任意的三维角速度向量。

5.4 网络学习什么?

对一组中间刚体:

$$g^{\tau} = \{(\mathbf{t}_i^{\tau}, q_i^{\tau})\}_{i=1}^{L}$$

编码器接收中间状态和时间参数:

$$f_\theta(g^{\tau}, \tau) = (\hat{\mathbf{u}}_{\text{trans}}, \hat{\mathbf{u}}_{\text{rot}})$$

针对正向路径:

$$\boxed{\mathcal{L}_{0\to1} = \left\|\mathbf{u}_{\text{trans}} - \hat{\mathbf{u}}_{\text{trans}}\right\|^2 + \left\|\mathbf{u}_{\text{rot}} - \hat{\mathbf{u}}_{\text{rot}}\right\|^2}$$

上式与原论文 Equation (11) 一致，省略了作者的部分下标。

反向再训练:

$$g^1 \to g^0$$

得到:

$$\mathcal{L}_{1\to0}$$

最终损失:

$$\boxed{\mathcal{L}_{\text{RigidSSL}} = \mathcal{L}_{0\to1} + \mathcal{L}_{1\to0}}$$

作者从最大化两个构象之间的互信息出发，采用双向条件似然的代理目标，再使用 Flow Matching 实现训练。因此，严格来说，这个损失是互信息学习的**代理目标**，不是直接计算互信息本身。 arXiv

5.5 用一个简单例子理解

假设两个刚体片段 A、B:

- A 的位置从 $(0,0,0)$ 变到 $(0.2,0,0)$。

- B 的位置从 $(3,0,0)$ 变到 $(3,0.3,0)$。
- B 还绕某个轴发生 30° 的旋转。

模型随机选择 $\tau = 0.5$，得到插值状态：

$$\mathbf{t}_A^{0.5} = (0.1, 0, 0)$$

$$\mathbf{t}_B^{0.5} = (3, 0.15, 0)$$

相应旋转采用 SLERP 得到中间取向。

模型输入这些中间刚体，学习预测 A 和 B 应当沿什么方向继续运动，才能从 g^0 变到 g^1。

因为同时进行了反向训练，它也学习从 g^1 返回 g^0 的变化规律。

这个过程要求模型理解各个刚体之间的几何约束，而不是仅记忆它们在某个构象中的绝对坐标。

六、模型内部架构：为什么作者选择 IPA?

RigidSSL 使用的是 AlphaFold2 引入的 Invariant Point Attention（IPA）模块。

6.1 与普通 Attention 的区别

普通 Attention：

$$a_{ij} = \mathrm{Softmax}_j\left(\frac{Q_i K_j^\top}{\sqrt{d}}\right)$$

主要根据特征向量决定节点间的注意力。

但 RigidSSL 处理的是 3D 空间中的刚体，因此必须显式考虑两个刚体之间的空间关系。

IPA 不仅有标量 Query、Key、Value，还构建局部坐标系中的三维点 Query、Key、Value。

对于刚体 i，一个局部点 $\mathbf{p}_i$ 转换到全局坐标：

$$T_i \circ \mathbf{p}_i = R_i \mathbf{p}_i + \mathbf{t}_i$$

然后比较两个刚体的点特征在全局坐标系中的距离。

6.2 关键的 IPA Attention 公式

对注意力头 h，可以将论文 Equation (25) 整理为：

$$a_{ij}^{h}=\mathrm{Softmax}_j\left[w_L\left(\frac{Q_i^h\cdot K_j^h}{\sqrt{d}}+b_{ij}^h-\frac{\gamma^h w_C}{2}\sum_{p=1}^{P}\left\|T_i\circ Q_{ip}^h-T_j\circ K_{jp}^h\right\|^2\right)\right]$$

这个公式包含三部分：

部分	含义
$Q_i\cdot K_j$	节点特征相似性
b_{ij}	Pair / Edge 特征
三维参考点距离项	两个刚体的空间几何关系

论文使用 Distogram 初始化 Pair Embedding：将残基间距离划分为 22 个区间，范围覆盖约 0 到 20 Å，并设置一个更大距离的末端区间。 arXiv

这个设计与你的 FG Pair 尤其相关：**空间作用不必仅依赖质心距离，还可以通过多个带方向的参考点来比较。**

例如两个羰基，即使质心距离接近，因取向不同，其相互作用也可能不同。IPA 的方向感知机制提供了一种可学习的空间几何比较方式。

6.3 输入、内部 Tensor 和输出

以下是从论文算法推导的概念性张量形状。论文没有在正文中统一指定每一层的全部隐藏维度，因此使用符号表示，不把推导维度误称为官方固定配置。

数据	形状	含义
Residue identity	`[L]`	每个残基的类别
Translation	`[L, 3]`	每个刚体的位置
Rotation	`[L, 3, 3]`	每个刚体的旋转矩阵
Quaternion	`[L, 4]`	旋转的另一种参数化
Distogram	`[L, L, 22]`	刚体间距离分箱
Node embedding	`[L, d]`	刚体的隐表示

Point Q/K/V	`[L, H, P, 3]`	多头空间参考点
Attention	`[H, L, L]`	刚体之间的注意力
Predicted translation	`[L, 3]`	平移输出
Predicted rotation	`[L, 4]`	四元数形式的旋转输出

注意：预训练优化的是平移和四元数插值的速度匹配，不能简单地将输出理解成最终预测的蛋白质坐标。

模型最终迁移的是 **IPA 的几何编码参数**，下游生成网络仍需要按照原本的任务目标进行微调。

七、论文训练流程、实验配置与结果分析

7.1 原论文的实际训练配置

根据 Appendix F：

配置	Phase I：Perturb	Phase II：MD
数据集	AFDB v4	ATLAS
样本规模	432,194 个结构	1,390 条轨迹
蛋白质长度	60–512 residues	60–512 residues
View 构造	SE(3) 随机扰动	2 ns 构象间隔
平移噪声 σ	0.03	不使用人工平移噪声
旋转噪声 ε	0.5	不使用人工旋转噪声
优化器	Adam	Adam
学习率	10^{-4}	10^{-4}
Batch size	1	1
GPU	1 × NVIDIA H100	1 × NVIDIA H100
训练时间	2.75 天	1.88 天

这些是原论文的配置，不建议直接当作聚合物的最优超参数。尤其是扰动幅度，必须重新根据聚合物结构、长度单位和化学约束确定。 arXiv

7.2 完整训练算法

```
# RigidSSL 原论文算法的简化伪代码
# 说明：不是官方源码的逐行复现

encoder = IPAEncoder()
flow_head = RigidFlowHead()

# Phase I: perturbation pretraining
for protein in static_protein_dataset:
    g0 = build_residue_frames(protein)
    g0 = canonicalize(g0)

    g1 = perturb_SE3(
        g0,
        translation_sigma=0.03,
        rotation_epsilon=0.5
    )

    tau = sample_uniform_time()

    # Forward: g0 -> g1
    gt_forward = interpolate_SE3(g0, g1, tau)
    target_forward = target_velocity(g0, g1, tau)
    pred_forward = model(gt_forward, tau)
    loss_forward = velocity_loss(
        pred_forward, target_forward
    )

    # Reverse: g1 -> g0
    gt_reverse = interpolate_SE3(g1, g0, tau)
    target_reverse = target_velocity(g1, g0, tau)
    pred_reverse = model(gt_reverse, tau)
    loss_reverse = velocity_loss(
        pred_reverse, target_reverse
    )

    loss = loss_forward + loss_reverse
    optimizer_step(loss)

save_checkpoint(encoder)

# Phase II: MD pretraining
```

```
load_checkpoint(encoder)

for trajectory in md_dataset:
    g0, g1 = sample_frame_pair(
        trajectory, delta_ns=2
    )

    g0, g1 = canonicalize_pair(g0, g1)

    # 使用相同的双向 Flow Matching 目标
    loss = bidirectional_rigid_flow_loss(g0, g1)
    optimizer_step(loss)

save_checkpoint(encoder)

# Downstream
generator = ProteinGenerator()
generator.load_encoder_weights(encoder)
finetune_generator_on_protein_design()
```

这里的 perturb_SE3 、 interpolate_SE3 等是为了讲清流程而定义的伪代码函数，不对应官方仓库中已经核实的同名函数。

7.3 结果：两阶段并不是越训练越好

FoldFlow-2 的蛋白质可设计性（Designability）

指标为生成蛋白质满足scRMSD阈值的比例，越高越好。

从原论文 Table 1 可以看出：

- 未预训练：32.9%
- Perturb 预训练：75.8%
- MD 预训练：58.4%

Perturb 相对未预训练提高了 **42.9 个百分点**，而不是相对提高 42.9%。

特别值得关注的是，**Phase II 在这个指标上反而低于 Phase I**。但 MD 预训练在某些结构多样性和高阶构象集合统计上更有优势。 arXiv +1

这说明：几何稳定性和构象多样性不是完全相同的学习目标。

对于你的聚合物课题，这一点值得重视：

如果下游预测是某个静态单链构象相关的性质，过度强调动态变化未必有效。

但如果下游预测的是链柔性、构象集合相关性质或链间接触统计，MD 预训练可能更有价值。

不能单纯根据 RigidSSL 的结果认为“加入 MD 必然提高所有性能”。

八、如何迁移到你的聚合物多层级表征模型?

这是我认为最重要的部分。

你现在的基本框架是：

$$\text{Atom Level} \longleftrightarrow \text{Repeat Unit Level}$$

并行设置：

$$\text{FG Level} + \text{FG Pair}$$

最后将三个层级增强后的表示融合。

我建议保留这个结构，不要因为 RigidSSL 就新增一个完全独立的 Rigid Fragment Level。

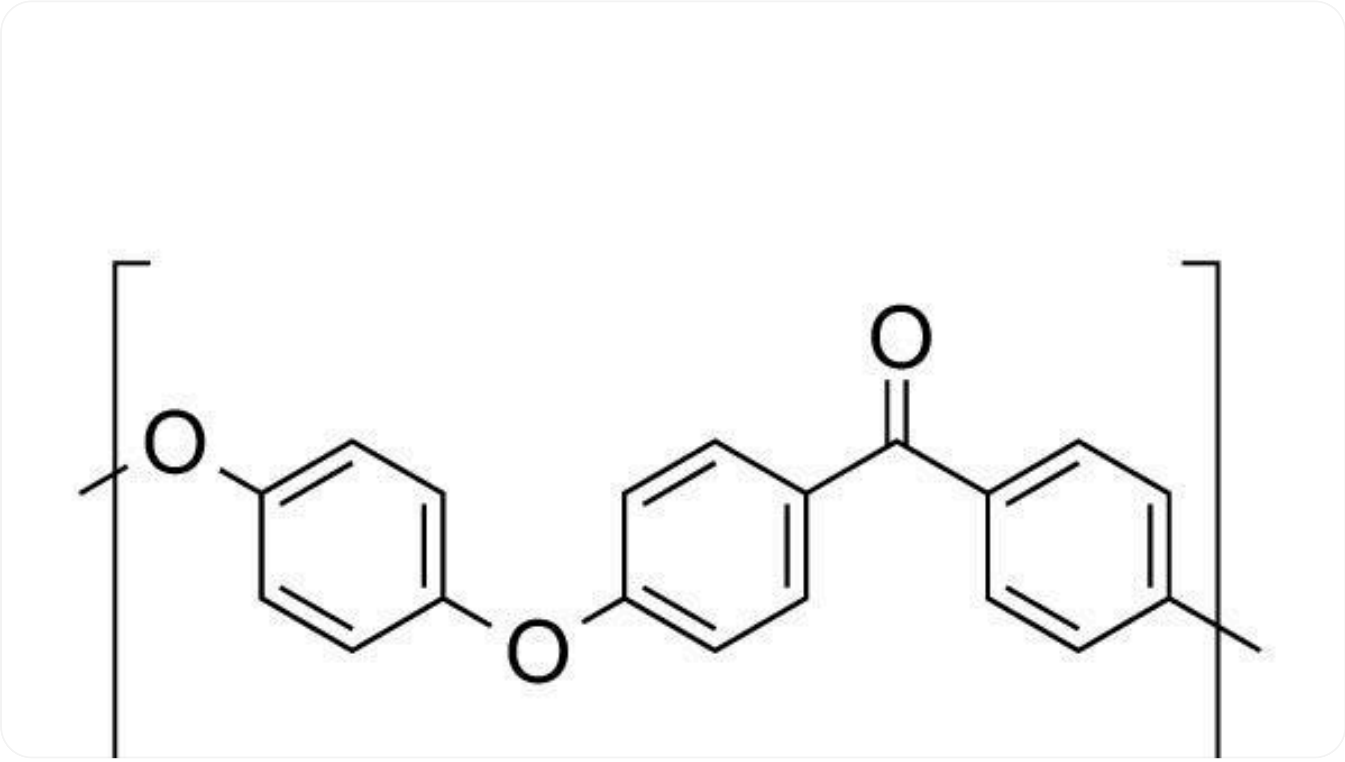
真正可以改进的是 FG 模块的物理表征和几何预训练方式。

8.1 首先分清三个概念

概念	划分依据	主要物理意义
Functional Group	化学官能团规则	化学身份、相互作用能力
Rigid Fragment	局部结构与旋转约束	局部构型、取向、形状
Flexible Linker	共价连接与可旋转自由度	链段运动、构象变化

三者不是一一对应的。

例如：



以 PEEK 聚合物为例：

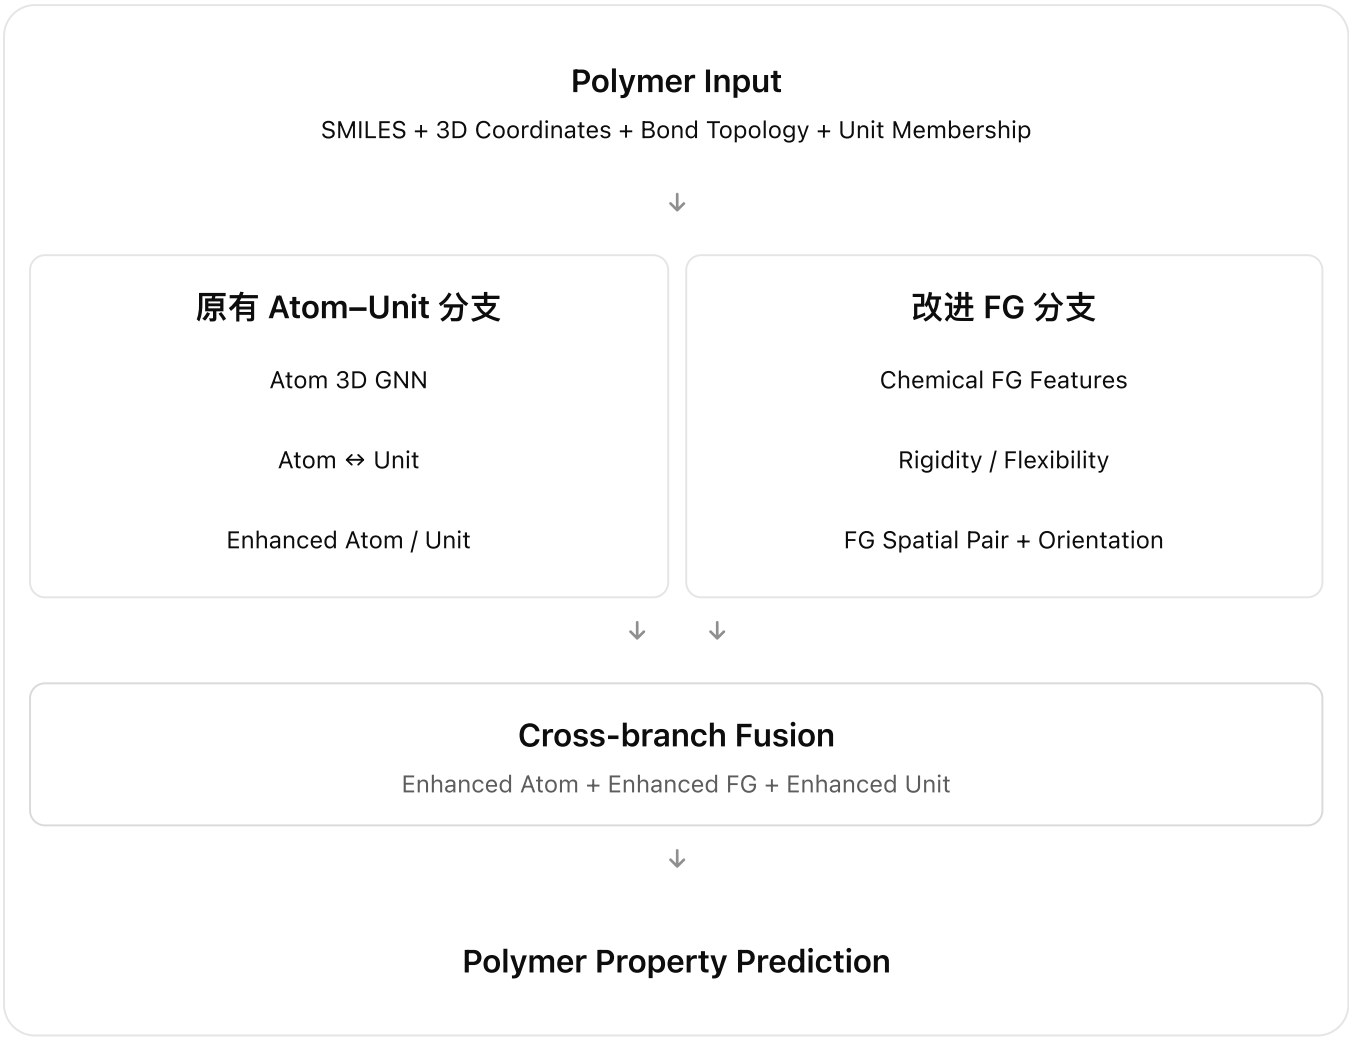
- 苯环可以视为局部刚性片段。
- 醚键连接处可以允许部分扭转运动。
- 羰基提供极性及局部平面性特征。
- 整条链的构象还取决于这些结构单元之间的相对角度。

在模型中，苯环既可以具有化学结构描述，又可以具有刚体参考框架。

醚连接处则重点保留扭转自由度和连接关系。

但**并不是每一个 FG 节点都必须拥有一个旋转矩阵**。例如只有两个原子定义的片段，若缺少额外参考原子，就无法唯一确定完整三维局部坐标系。

8.2 推荐的模型结构



相较于你之前的结构，主要变化只有两个：

第一，FG Node 增加刚性/柔性特征。

第二，FG Pair 增加相对取向和连接自由度信息。

原来的 Atom–Unit Inter-level 无须因此改变。

九、具体应该如何提取刚柔片段?

9.1 将化学规则和三维信息分开处理

我建议先使用 RDKit 从共价拓扑中提取可旋转连接及近似刚性区域，再利用 3D 构象计算几何特征。

基本步骤：

1. 根据 RDKit 识别环、共轭结构、双键、酰胺等局部受限旋转区域。

2. 识别允许扭转的单键，同时排除不应自由旋转的键。
3. 根据适当的连接规则构造近似刚性区域及其之间的连接。
4. 从 3D 坐标计算局部参考框架、片段间距离和相对取向。
5. 将刚柔信息映射回现有 FG 节点与 FG–FG 边，不强制改变原有层级。

这里需要一个额外区分：

刚体划分算法和**官能团识别算法**可以独立运行。

官能团可以通过 Ertl 等化学规则识别。

刚体区域则可以通过非旋转键连通性及化学规则近似获得，再将两者的信息对应起来。

如果一个刚性区域跨越多个 FG 或多个 repeat unit，可以保存一个独立的 `rigid_segment_id` 作为结构元信息，而不需要将它创建为一个新的网络层级。

9.2 FG Node 应该增加什么特征?

原来：

$$h_{FG_i} = \mathrm{Pool}_{a \in FG_i}(h_a)$$

现在增加局部刚柔描述符：

$$\boxed{\widetilde{h}_{FG_i} = \mathrm{MLP}([h_{FG_i} \| r_i])}$$

推荐的 r_i：

特征	物理含义
Is aromatic	是否属于芳香体系
Ring membership	是否位于环中
Local planarity	局部平面程度
Rotatable bonds	相关可旋转连接数量
Conjugation	是否参与共轭
Rigid segment membership	所属近似刚性区域
Backbone / side chain	主链或侧链位置

这些特征应区分静态拓扑描述和需要构象集合估计的动态柔性指标。比如单个静态构象并不能直接给出真实的旋转势垒或动力学柔性。

十、FG Pair 应该怎样从 RigidSSL 中获得启发?

这可能是最适合你当前模型的创新切入点。

10.1 不仅看空间距离，还看相对取向

假设两个具有局部刚体框架的 FG:

$$T_i = (\mathbf{t}_i, R_i)$$

$$T_j = (\mathbf{t}_j, R_j)$$

距离特征:

$$d_{ij} = \|\mathbf{t}_j - \mathbf{t}_i\|$$

相对位移（在 FG i 的局部坐标系中）:

$$\boxed{\mathbf{d}_{ij}^{local} = R_i^\top (\mathbf{t}_j - \mathbf{t}_i)}$$

相对旋转:

$$\boxed{R_{ij} = R_i^\top R_j}$$

这三个特征的作用不同:

特征	提供的信息
d_{ij}	两个 FG 相距多远
$\mathbf{d}_{ij}^{local}$	FG j 位于 FG i 的什么方向
R_{ij}	两个 FG 之间如何相对转动

这些相对几何特征在两个局部框架随全局旋转正确变换时，不受整个聚合物链的整体旋转和平移影响。

对于氢键、偶极作用、芳香环堆积等方向敏感的相互作用，这是单纯 FG 质心距离不能完整提供的信息。

但这些特征本身并不能直接证明存在氢键或其他具体作用；仍需要考虑相关原子距离、供体/受体身份、几何角度等条件。

10.2 FG Pair 可分成两个关系通道

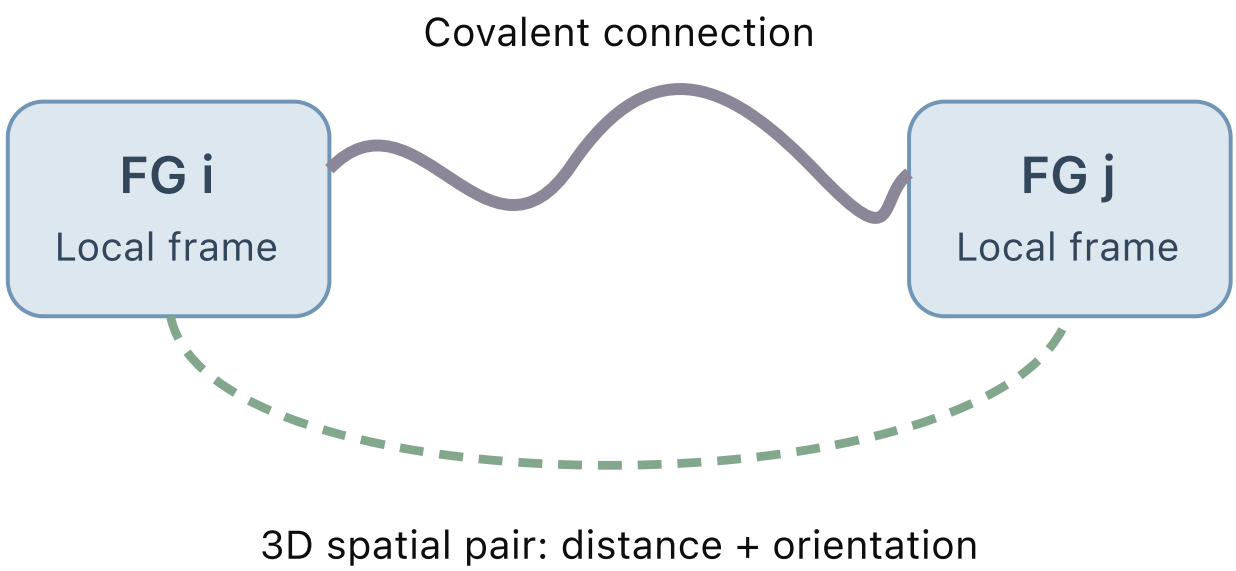
我建议你的 FG 模块采用两类关系，但不强制建立两个完全独立的网络。

Covalent FG Edge： 表示两个 FG 通过聚合物的共价拓扑相连。

建议包含连接键类型、可旋转性、连接位置、最短拓扑距离等。

Spatial FG Pair： 表示两个 FG 在空间上的相对位置，即使它们在共价拓扑中相隔很远。

建议包含距离、相对方向、相对取向、局部接触特征等。



概念示意：同一对 FG 可以同时具有共价连接关系和空间几何关系，也可以只有空间关系。

10.3 最终 Pair Feature

对于拥有有效局部框架的 FG，可以定义：

$$\boxed{e_{ij}^{FG} = \mathrm{Embed}\left(d_{ij}, \mathbf{d}_{ij}^{local}, R_{ij}, b_{ij}, c_{ij}\right)}$$

其中：

- b_{ij}：共价拓扑或连接柔性特征。
- c_{ij}：FG 化学身份及可能的接触类型特征。

对于无法稳定构建局部框架的 FG，则通过 `frame_mask` 关闭方向特征，保留距离、相关原子夹角以及化学特征。

这是你可以借鉴 IPA 的地方，但**不需要把整个 FG 网络都替换成 IPA**。可以先将相对几何作为 edge feature，再用已有的 Edge-aware GNN 或 Attention 消融验证。

十一、真正的关键：怎样将 RigidSSL 预训练迁移到聚合物?

我建议分两个难度等级实施。

方案 A：Rigid-aware Geometry Denoising

建议先实现

这是对你现有 3D GNN 改动最少的方案。

将原来的聚合物结构输入保留，并增加刚柔特征，以及与局部几何有关的预训练损失。

例如，选择有效的 FG Pair，预测其距离：

$$\mathcal{L}_{\text{dist}} = \frac{1}{|\mathcal{P}|} \sum_{(i,j)\in\mathcal{P}} (\hat{d}_{ij} - d_{ij})^2$$

针对有局部参考框架的片段，可以加入相对取向预测：

$$\mathcal{L}_{\text{orient}} = \frac{1}{|\mathcal{P}_R|} \sum_{(i,j)\in\mathcal{P}_R} d_{SO(3)}(\hat{R}_{ij}, R_{ij})^2$$

其中旋转测地距离可以定义为：

$$d_{SO(3)}(R_1, R_2) = \left\| \operatorname{Log}(R_1^\top R_2)^\vee \right\|_2$$

再添加性质预测目标：

$$\boxed{\mathcal{L} = \mathcal{L}_{\text{property}} + \lambda_d \mathcal{L}_{\text{dist}} + \lambda_r \mathcal{L}_{\text{orient}}}$$

为了让去噪具有意义，预训练时应对输入几何进行合理扰动或掩蔽，而目标仍来自原始有效构象；不能让网络直接从未经改变的距离输入复制相同距离作为预测结果。

为什么推荐这个方案?

它可以先验证两个最基础的科学问题：

1. 刚柔特征是否对聚合物性质有用?
2. FG 的空间方向信息是否比仅使用距离更有用?

这个方案借鉴了 RigidSSL 的物理表示思想，但不是对原论文 Flow Matching 的完整复现。

方案 B：Polymer Rigid-aware Flow Pretraining

适合后续研究构象学习或聚合物生成时探索

这个方案更接近 RigidSSL 原方法。

但有一个重要限制：

不能像 RigidSSL 的 Phase I 那样，直接独立移动每一个聚合物刚性片段。

因为聚合物的刚性片段通过共价键连在一起。

独立平移和旋转可能导致键断裂、键长不合理或严重空间重叠。

对于聚合物，建议采用**受化学拓扑约束的扭转扰动**。

假设两段刚性片段通过一个可旋转单键相连，定义该键的二面角：

$$\phi_k$$

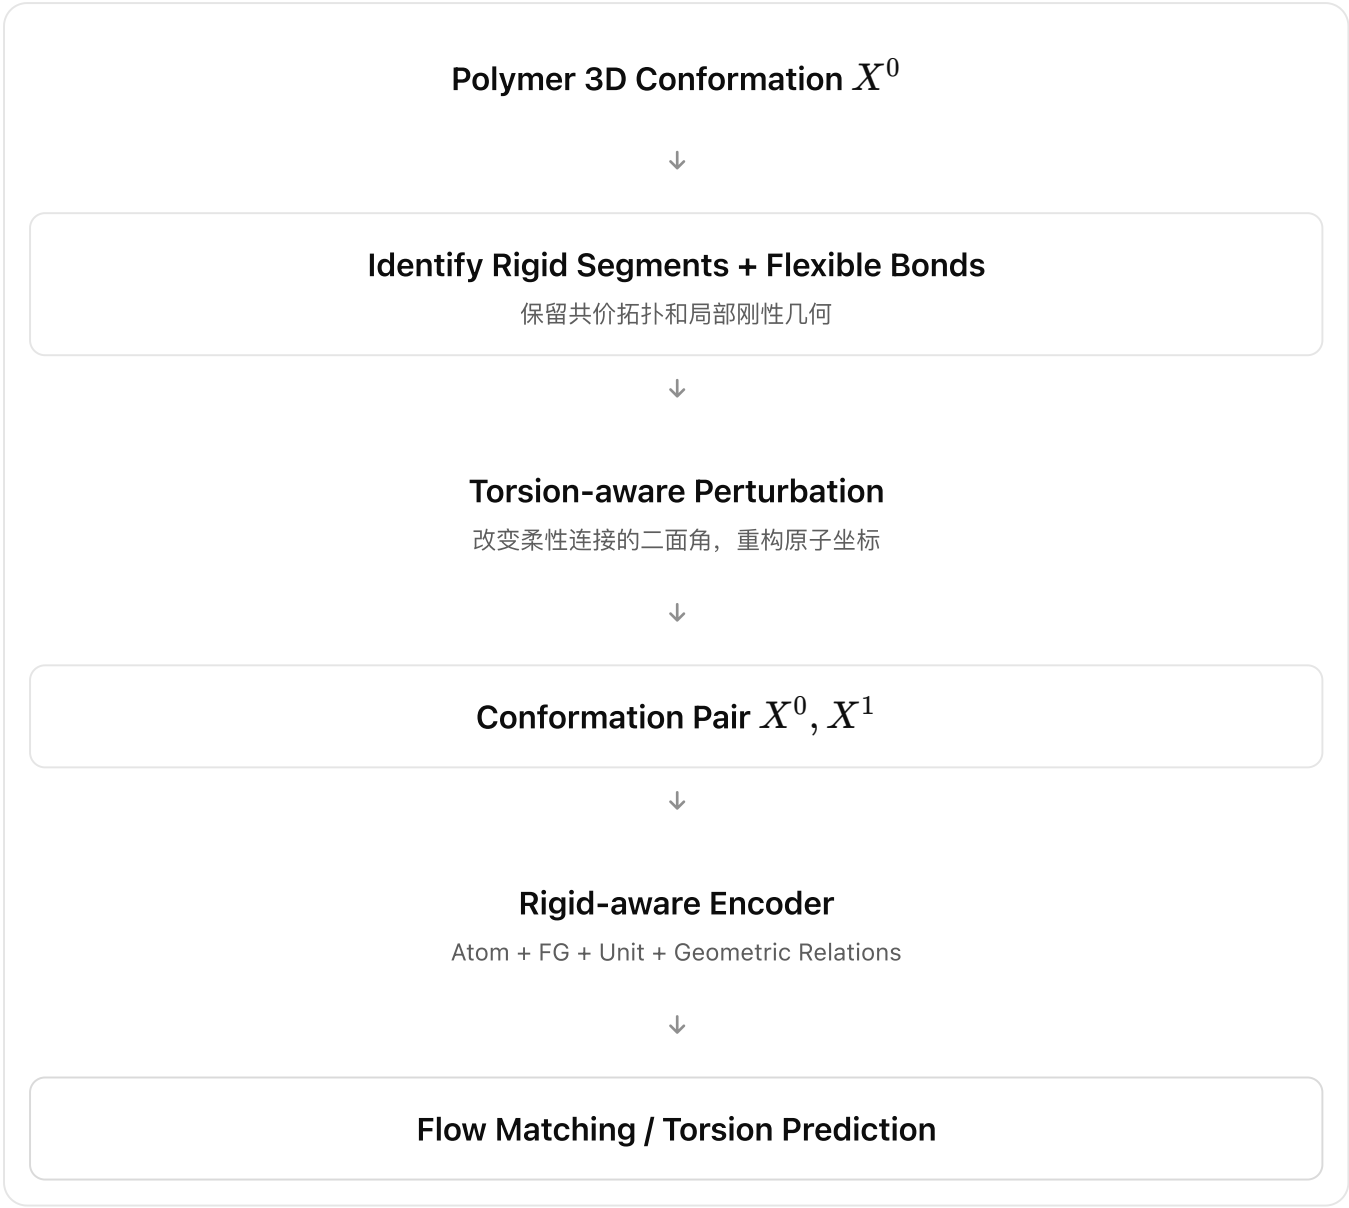
构造另一个构象：

$$\boxed{\phi_k^1 = \phi_k^0 + \Delta\phi_k}$$

然后围绕真实的键轴旋转下游相关原子，得到新的原子坐标。

这样可以在不改变被旋转刚性区域内部几何的前提下，构造新的链构象。

当然，这仍然需要碰撞检测、环闭合约束，以及必要的几何优化，才能避免不合理结构。



在具体实现上，你可以选择两种输出：

选择 1：预测柔性连接的扭转变化

$$\hat{\Delta\phi}_k = f_\theta(X^\tau, \tau)_k$$

对于周期性二面角，可以用圆周距离而不是普通角度 MSE。

选择 2：预测刚性区域的相对运动

$$(\hat{\mathbf{u}}_t, \hat{\mathbf{u}}_R) = f_\theta(g^\tau, \tau)$$

但必须保证输出的运动与聚合物共价连接约束兼容。

如果采用第二种方案，网络会更接近 RigidSSL，不过实现难度也明显更高。

十二、与你现有代码的输入输出如何对接?

你现有研究已经考虑不同 DP 的聚合物 3D 结构，因此设计时最好支持可变长度输入。

以下是我建议的单条聚合物链数据结构：

输入字段	建议形状	用途
`atom_features`	`[N, d_a]`	元素、价态、杂化、芳香性等
`positions`	`[N, 3]`	原子 3D 坐标
`bond_index`	`[2, E_b]`	化学键拓扑
`unit_id`	`[N]`	Atom → Unit 映射
`fg_membership`	稀疏索引	Atom → FG 映射
`fg_features`	`[M, d_f]`	FG 身份、刚柔属性
`fg_pair_index`	`[2, E_f]`	FG 空间相互作用
`fg_pair_features`	`[E_f, d_e]`	距离、方向、相对取向
`rigid_segment_id`	`[N]`	刚性区域归属，非新层级
`local_frames`	`[K, 3, 3]`	有效刚性区域的取向
`frame_mask`	`[K]`	标记有效参考框架
`rotatable_bonds`	`[E_r, 2]`	柔性连接
`dp`	标量	聚合度
`conditions`	可选	温度、密度、模拟条件等

这里 N 是原子数，M 是 FG 数量，K 是有效刚性区域数量。

对于一条聚合物链， `rigid_segment_id` 和 `fg_membership` 不需要完全一致，因为二者对应不同的化学划分逻辑。

模型输出可以是：

$$H_A \in \mathbb{R}^{N \times d}$$

$$H_{FG} \in \mathbb{R}^{M \times d}$$

$$H_U \in \mathbb{R}^{DP \times d}$$

经过 Pooling 和 Fusion：

$$h_{\text{poly}} = \text{Fusion}\left(\text{Pool}(H_A), \text{Pool}(H_{FG}), \text{Pool}(H_U)\right)$$

最终性质预测：

$$\boxed{\hat{y} = \text{MLP}(h_{\text{poly}})}$$

这可以保持与你之前模型一致的三个层级。

如果拥有 MD 轨迹，则增加时间维度 `[T, N, 3]`，但需要先处理周期性边界、分子 unwrap、原子索引对应和构象对齐。

十三、具体的实验应该如何安排?

我建议先把 RigidSSL 的思想作为 **FG 模块的一组增量创新** 来验证，而不是立即把整个模型改成 Flow Matching 框架。

实验	增加的内容	核心验证目标
E0	原 Atom–Unit 模型	基础性能
E1	+ FG Chemical Features	官能团信息是否有效
E2	+ FG Spatial Distance	3D 空间接触是否有效
E3	+ Rigidity / Flexibility Features	刚柔信息是否有效
E4	+ FG Relative Orientation	局部取向是否有效
E5	+ Geometry Denoising Pretraining	几何预训练是否有贡献
E6	+ MD Conformational Pretraining	真实构象变化是否有贡献
E7	+ Torsion / Rigid Flow Objective	更复杂的物理运动建模是否值得

建议同时做 E2、E3、E4 的组合消融，区分刚柔信息与方向信息各自的贡献。

评价不应只看 MAE 和 RMSE，还可以增加：

- **结构有效性：** 键长、键角是否合理，是否出现空间冲突。
- **几何鲁棒性：** 随机旋转和平移后预测是否保持一致。
- **DP 泛化：** 训练较短链，测试较长链。
- **构象泛化：** 同一种聚合物的不同构象之间是否稳定。
- **数据效率：** 训练样本减少时，预训练是否仍带来收益。

最后一点对你尤其重要，因为如果你想在 OMersBench、VIPEA、PolyVERSE 等数据上验证模型，必须先统一结构表示，并区分哪些数据具备真实 3D 构象、哪些只有 repeat-unit SMILES。没有 3D 坐标的数据不能未经处理就直接运行依赖 Rigid Frame 的完整模型。

同一个聚合物的不同 DP 或不同构象也应避免同时泄漏到训练集和测试集；否则很容易高估泛化性能。

十四、对 RigidSSL 的批判性分析

我认为有四个局限值得你在自己的研究设计中避免。

1. 刚体划分依赖已有的生物化学层级。 蛋白质残基天然提供了相对规则的表示单位，而一般聚合物没有统一、适用于所有化学体系的刚体划分规则。这恰恰是你可以研究的部分，但不必一开始就尝试解决所有聚合物类型。

2. 独立刚体扰动不严格保持共价几何。 原论文通过噪声规模消融发现过大扰动会导致更多空间冲突、降低键的有效性。对聚合物，按可旋转键进行受约束扰动会是更合理的起点。 arXiv

3. 动态预训练可能产生负迁移。 论文已观察到 MD 预训练在某些生成评价指标上不如 Perturb；动态数据带来的物理先验可能与下游目标不完全一致。 arXiv

4. 从单链学习的结构不能完全代表聚合物材料。 许多材料性质受链间相互作用、堆积、分子量分布和环境条件影响。单链 3D 表征可以作为基础，但不能把缺失的多链信息解释为模型已经学到的物理知识。

十五、我对你当前模型的最终建议

按研究价值和实现成本来看，我建议采用以下顺序。

1. **先实现刚柔化学特征（低成本）**

保留三层架构，只在 FG 节点和 FG Covalent Edge 中增加刚柔信息。验证其是否比单纯的 FG 化学身份更有预测价值。

2 **再加入 FG Relative Geometry（优先创新点）**

在现有 FG Pair 中引入局部坐标方向、相对取向及空间接触特征，验证是否能够捕捉与聚合物链折叠有关的作用。

3 **最后研究刚柔约束的自监督学习（较高创新潜力）**

在静态和 MD 构象数据上学习局部几何、柔性连接和构象变化。若有明确的构象生成研究目标，再考虑完整的 Rigid Flow Matching。

我认为最值得形成独立论文贡献的方向可以概括为：

Chemistry-Guided Rigidity–Flexibility-Aware Hierarchical 3D Representation Learning for Polymers

其核心研究假设是：

聚合物的结构–性质关系不仅取决于原子组成和官能团身份，还与刚性化学区域通过柔性连接形成的三维空间组织密切相关。因此，可以利用化学拓扑识别局部刚柔约束，再将其与官能团空间相互作用、多层级表示学习相结合。

这不是简单地把 RigidSSL 用在聚合物上，而是将它提出的 **Rigid-aware Geometric Pretraining** 思路发展为更适合聚合物化学结构的表征方法。

对于目前要在 OMersBench 上训练新模型的阶段，我最建议先完成 E0–E4。 只有当你确认 FG 刚柔与取向特征确实有增益后，再投入计算资源实现更加复杂的构象预训练和 Flow Matching。