你说：

https://github.com/rlearsch/PolymerBenchmark2026/blob/main/scaling_results/all/scaling_results_aggregate.csv 和 https://github.com/rlearsch/PolymerBenchmark2026/blob/main/published_results/full_dataset_5fold_cv_rmse.csv 中的数据结果整理并且可视化

思考了 10m 41s >

ChatGPT 说：

PolymerBenchmark2026 数据整理与可视化分析

这两个文件分别回答不同的问题：

数据文件	数据规模	核心研究问题
`scaling_results_aggregate.csv`	232 条记录	训练样本量从 300 增加到 1,000、3,000、10,000 时，不同模型的预测精度如何变化?
`full_dataset_5fold_cv_rmse.csv`	64 条记录	使用完整数据集进行五折交叉验证时，哪种模型在不同聚合物性质上表现最好?

两组结果都以 **RMSE（均方根误差，越低越好）** 为主要指标，并提供跨折标准差。

需要特别注意：**不同性质的 RMSE 不能直接比较大小**。例如，Tg、密度、IP、EA 的量纲和数值范围不同，因此应分别比较每种性质上的模型表现。

项目使用的四类模型包括 RDKit + Random Forest、polyBERT、Polymer Chemprop（PCP）和 Polymer Periodic Graph（PPG）。 raw.githubu... +2

一、完整数据集：模型性能对比

在 14 个四种模型均有结果、可直接比较的任务中：

PCP 最优任务数
8 / 14
Polymer Chemprop

PPG 最优任务数
6 / 14
Polymer Periodic Graph

完整数据集：14 个可比任务的最优模型数量

RMSE 越低越好；仅统计四种模型都有结果的任务

与模型最优误差的相对差距

对每个任务先计算 **模型 RMSE / 该任务最低 RMSE**，再跨 14 个任务取均值，消除不同预测性质的量纲差异。

模型	平均相对 RMSE	相比各任务最优值
PCP	1.028×	+2.8%
PPG	1.048×	+4.8%
RDKit-RF	2.131×	+113.1%
polyBERT	2.517×	+151.7%

因此，在这组基准测试中，**PCP 与 PPG 整体明显优于 RDKit-RF 和 polyBERT，且 PCP 与 PPG 之间的差距相对较小**。

这些是描述性结果，不能仅据此推断所有任务上的统计显著性，也不能直接推断三维结构信息是否有效。

二、Scaling 实验：训练数据量的影响

在训练样本量增加时，PCP 和 PPG 通常保持较低的预测误差，但不同任务的改善幅度差异较大。

以下展示几个代表性任务中，**四种模型里的最佳 Test RMSE**：

预测性质与类型	N=300	N=1,000	N=3,000	N=10,000

Cp · 交替共聚物	96.340	73.297	69.395	68.181
Rg · 交替共聚物	3.933	2.421	1.704	1.305
密度 · 交替共聚物	0.03074	0.01766	0.01367	0.01144
折射率 · 交替共聚物	0.11167	0.10812	0.09057	0.06735

每个数据点分别选取当时 RMSE 最低的模型，因此不代表同一个模型的连续学习曲线。完整的四模型学习曲线见下方生成的图表。

例如，对于交替共聚物的 Rg 预测，PCP 的 Test RMSE 从 3.933 降至 1.305，下降约 **66.8%**；而对于折射率，PPG 从 0.11265 降至 0.06735，下降约 **40.2%**。

这说明仅有较强的分子表示还不够，训练数据覆盖度同样重要。对聚合物性质预测模型的开发，建议同时关注低数据量性能和随样本量增加的改善趋势。

三、IP 与 EA：电子结构性质预测结果

这部分数据只存在于完整数据集文件中，尤其适合单独查看。

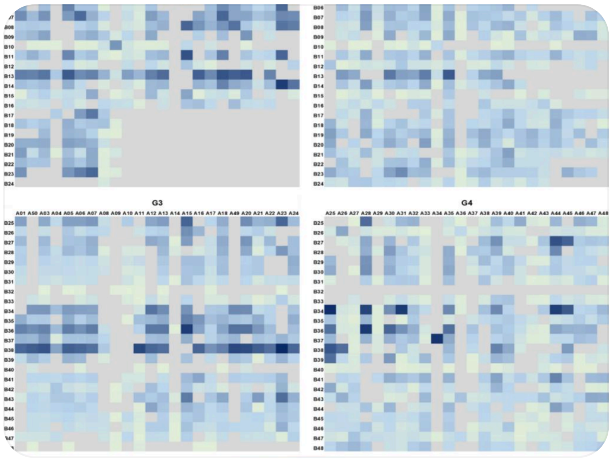
性质	聚合物类型	RDKit-RF	polyBERT	PCP	PPG
IP	交替共聚物	0.142	0.157	**0.040**	0.048
IP	均聚物	0.473	0.608	0.426	**0.425**
EA	交替共聚物	0.155	0.115	**0.048**	0.056
EA	均聚物	0.429	0.385	**0.285**	0.291

从结果看，PCP 在交替共聚物的 IP、EA 预测上均优于另外三种模型。均聚物的数据规模只有约 370 条，PCP 与 PPG 表现接近，且五折标准差相对更大。

这里的 IP（电离电位）和 EA（电子亲和能）可以作为电子结构学习任务，但 **IP 的预测精度并不等价于聚合物在真实电池正极环境中的抗氧化稳定性预测精度**，还需考虑聚合物结构、构象、界面和反应条件。

四、可视化图表与文件下载

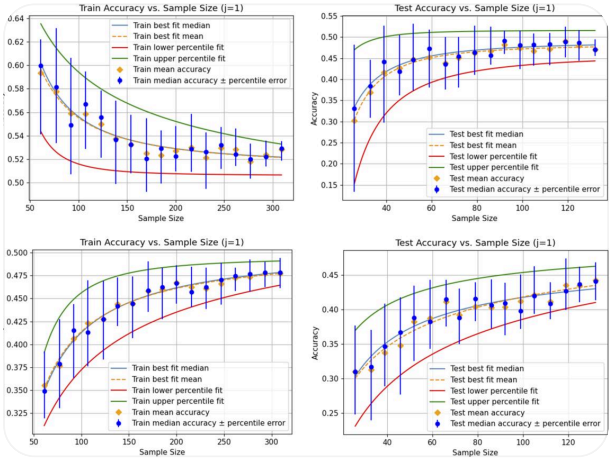
已经生成 5 组学术风格图表，分别提供高清 PNG 和可编辑的 SVG 格式。



完整 CV 相对 RMSE 热力图

14 个可比任务、4 种模型，突出不同性质上的性能差异。

查看实际热力图 ↗



10 个任务的 Scaling 学习曲线

每个任务分别画出四种模型的测试 RMSE 与五折标准差。

查看实际学习曲线 ↗

另外还生成了样本量增加后的 RMSE 降幅热力图、IP/EA 四模型比较图以及归一化模型表现图。

下载全部分析资料 ZIP ↗

包含 Excel、原始 CSV、数据汇总、5 组 PNG/SVG 图表及中文解读说明

下载 Excel 数据分析工作簿 ↗

6 个工作表，包含完整原始数据、模型对比、Scaling 测试结果和样本增益公式

单独下载全部高清图表 ↗

5 张 PNG + 5 张 SVG，适合论文和 PPT 汇报

后续研究建议： 如果希望基于这个 Benchmark 设计更强的聚合物表征模型，建议把 **IP、EA、Rg、Tg** 分为独立实验任务，分别比较数据效率、模型泛化和结构信息的贡献，而不是只比较平均 RMSE。

01_full_cv_relative_rmse_heatmap.png
图像

02_scaling_learning_curves_10_tasks.png
图像

PolyBench26_结果整理与可视化.xlsx
Excel

你说：

https://github.com/rlearsch/PolymerBenchmark2026/blob/main/scaling_results/all/scaling_results_aggregate.csv 数据集中涉及到多少组对比试验，如果去可视化该结果，如何全部可视化

思考了 5m 6s

ChatGPT 说：

PolymerBenchmark2026 Scaling 实验：完整统计与可视化方案

我核对了 `scaling_results_aggregate.csv` 的全部 232 条记录。**这份数据实际上包含 10 组独立预测任务、29 组训练规模配置、116 组模型测试结果。**

一、究竟有多少组对比实验?

独立预测任务	训练规模配置
10	29
性质 × 聚合物类型	10 组任务的不同训练样本量

模型测试组合	汇总记录
116	232
29 组配置 × 4 种模型	包含 Test、Train、Validation

1. 十组独立预测任务

预测性质	交替共聚物 (Alternating)	均聚物 (Homopolymer)
Cp — 定压热容	4 个规模	2 个规模
Cv — 定容热容	—	2 个规模
Rg — 回转半径	4 个规模	2 个规模
Density — 密度	4 个规模	2 个规模

Refractive index — 折射率	4 个规模	2 个规模
Tg — 玻璃化转变温度	—	3 个规模

训练规模具体为：

- 交替共聚物：300、1,000、3,000、10,000 条。
- MD 均聚物：300、1,000 条。
- Tg 均聚物：300、1,000、3,000 条。

所以，总共是：

$$4 \times 4 + 5 \times 2 + 1 \times 3 = \boxed{29}$$

这 29 个配置分别使用四种模型：RDKit-RF、polyBERT、Polymer Chemprop（PCP）、Polymer Periodic Graph（PPG）。

2. 为什么是 232 条，而不是 348 条?

不同模型保存的数据划分不完全相同。

模型	Train	Validation	Test	合计
RDKit-RF	29	29	29	87
polyBERT	29	29	29	87
PCP	—	—	29	29
PPG	—	—	29	29
合计	**58**	**58**	**116**	**232**

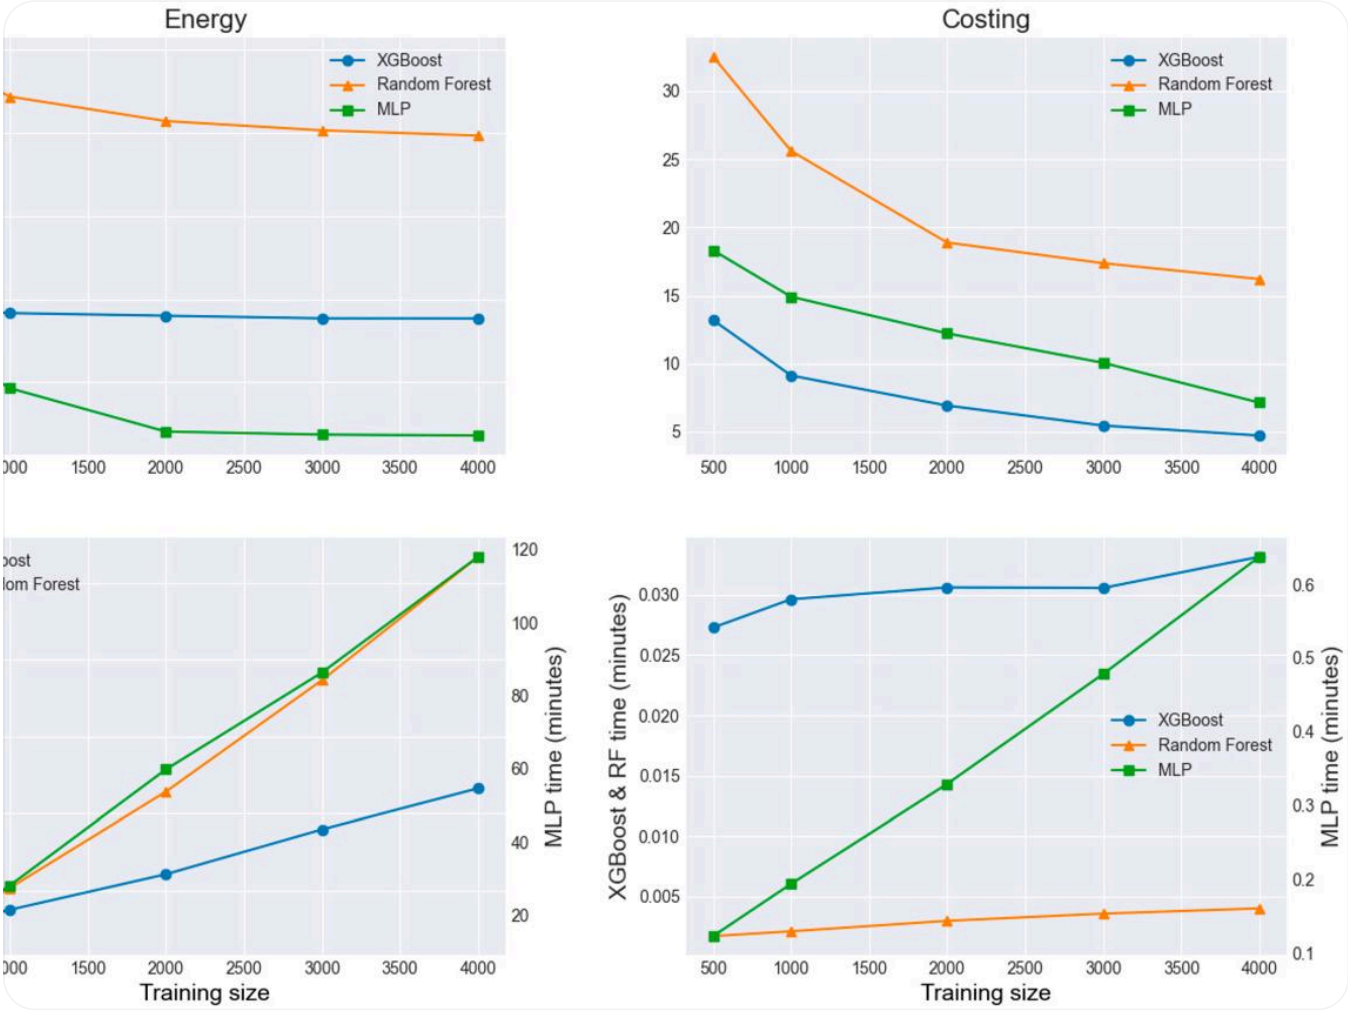
PCP、PPG 在此汇总文件中只有 Test RMSE，并不意味着训练时没有验证集。

每条记录都是五折结果的汇总，包含 RMSE 均值和标准差。因此，**232 条不是 232 次独立训练，更不是 232 个聚合物样本**。该项目使用固定划分、嵌套训练集的实验设计，确保同一个任务内模型比较具有可比性。 GitHub

二、如何将所有数据可视化?

建议使用 **9 组图表 + 1 个交互式仪表板**。我已经根据原始 CSV 实际生成了这套完整图表。

图 1：10 组任务的完整 Learning Curves

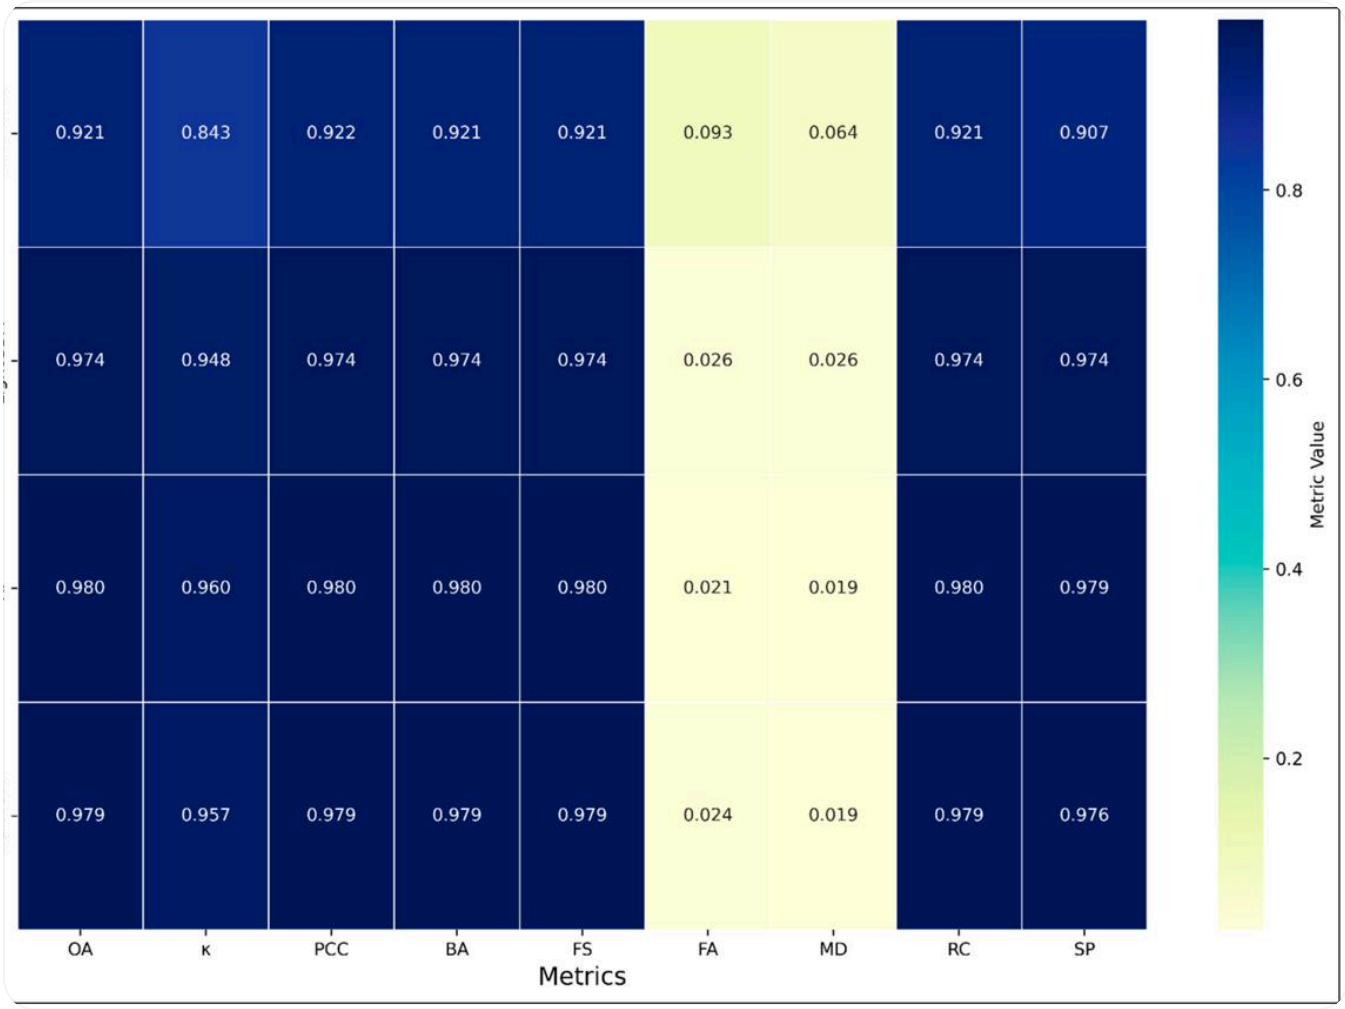


建议图形：每个预测任务一个子图，横轴 Train size，纵轴 Test RMSE，四条模型曲线，带五折标准差误差棒。

这是最重要的一张图，完整覆盖 **116 个 Test RMSE 数据点**，能够同时回答三个问题：哪种模型最好、数据增加后精度如何变化、模型之间的差距是否随数据量改变。

查看生成的真实 10 任务学习曲线（PNG）↗

图 2：29 组配置 × 4 模型的 RMSE 热力图



为了把所有性质放进同一张图，使用归一化：

$$R_{i,m} = \frac{\mathrm{RMSE}_{i,m}}{\min_m \left(\mathrm{RMSE}_{i,m}\right)}$$

其中 i 表示某个任务和训练样本量的组合，m 表示模型。最优值始终为 1.00×。

查看生成的真实 29×4 热力图（PNG）↗

这张图能直接识别所有 29 个配置中的最优模型：

29 个训练规模配置中的最优模型次数

也就是说，PCP 在 29 组配置中有 18 组 Test RMSE 最低，PPG 有 9 组，RDKit-RF 有 2 组。

图 3–9：补齐其他实验维度

图表	数据范围	主要分析目的
实验覆盖矩阵	10 任务 × 4 个候选训练规模	哪些实验规模实际存在
RMSE Train/Val/Test 曲线	174 条记录	模型是否过拟合
MAE Train/Val/Test 曲线	174 条记录	与 RMSE 是否呈现相同趋势
MSE Train/Val/Test 曲线	174 条记录	大误差样本的影响
五折相对标准差热力图	116 条 Test 记录	模型表现的跨折稳定性
样本量增益热力图	40 条模型学习曲线	训练数据增加带来多少改善
Test/Train 误差比热力图	58 组结果	泛化差距分析

Train/Val/Test、MAE 和 MSE 的完整对比仅适用于 RDKit-RF 与 polyBERT，因为另外两个模型的相应结果没有记录在这份 CSV 中。

三、完整可视化文件下载

打开完整交互式可视化仪表板 ↗

推荐优先使用。支持选择性质、模型、训练规模相关结果、RMSE/MAE/MSE，以及 Train/Val/Test。包含 232 条原始结果检索，HTML 离线可用。

下载全部可视化资料 ZIP ↗

9 组 PNG/SVG 图表、交互式仪表板、29 组最佳模型结果、174 组两两模型比较和相关数据表。

四、如果用于论文或研究汇报，建议怎么安排?

我建议分成三页：

1. **第一页：Benchmark 数据与实验设计。** 展示 10 组任务、29 个训练规模配置、四类模型和统一数据划分方式。
2. **第二页：完整学习曲线。** 使用 10 个子图比较四种模型在不同数据规模下的预测精度，这是主要实验结果。
3. **第三页：模型优势和泛化能力。** 使用 29×4 相对 RMSE 热力图，并结合样本增益与 Train/Test 差距解释模型表现。

特别需要注意，**这份 Scaling 文件不包含 IP 和 EA**。如果后续希望突出电子结构性质（例如聚合物氧化稳定性相关的 IP），需要另行使用完整数据集的五折交叉验证结果，不能把不存在的 Scaling 结果补入学习曲线。

最终建议： 以 10 组 Learning Curves 作为主图、29×4 热力图作为总结图，再用交互式仪表板保留全部 232 条记录。这样既能完整展示实验，又不会让正式汇报中的图过于拥挤。

- 01_test_rmse_all_10_tasks.png
  图像
- 02_relative_rmse_29x4_heatmap.png
  图像
- PolyBench26_Scaling_全量交互仪表板.html
  HTML

你说：

\[
4\times4+5\times2+1\times3=\boxed{29}
\] 是啥意思

ChatGPT 说：

这个公式是用来计算 **Scaling 实验中共有多少组“预测任务 × 训练数据规模”的组合。**

$$\underbrace{4\times4}_{16}+\underbrace{5\times2}_{10}+\underbrace{1\times3}_{3}=\boxed{29}$$

具体解释如下：

聚合物类型	预测性质	性质数量	训练样本量	实验组合数
交替共聚物	Cp、Rg、Density、Refractive index	4	300、1,000、3,000、10,000	4×4=16
均聚物	Cp、Cv、Rg、Density、Refractive index	5	300、1,000	5×2=10
均聚物	Tg	1	300、1,000、3,000	1×3=3
合计	**10 组预测任务**			29

29 组与 116 组有什么区别?

以交替共聚物的 Cp 为例：

- 300 条训练数据 → 4 种模型对比
- 1,000 条训练数据 → 4 种模型对比
- 3,000 条训练数据 → 4 种模型对比
- 10,000 条训练数据 → 4 种模型对比

这一个预测任务就包含 **4 组训练规模配置、16 个模型测试结果。**

因此：

$$29\text{组训练规模配置} \times 4\text{种模型} = \boxed{116\text{个模型测试结果}}$$

一句话总结：

- **10 组任务**：预测什么性质、哪种聚合物?
- **29 组配置**：每个任务分别使用多少训练数据?
- **116 个测试结果**：每种配置用四个模型进行对比。
- **232 条 CSV 记录**：除了 116 条 Test 结果，还包含 RDKit-RF 与 polyBERT 的 Train、Validation 结果。

也就是说，**29 不是模型训练次数，而是不同的"预测任务 + 训练样本量"组合数量。**

你说：

是不是应该每个模型的结果做可视化对比后，再将不同模型之间的结果进行可视化对比

ChatGPT 说：

是的。对于 `PolymerBenchmark2026` 的 Scaling 实验，**我更推荐先分析每个模型自身的表现（Intra-model Analysis），再比较不同模型之间的表现（Inter-model Comparison）**。

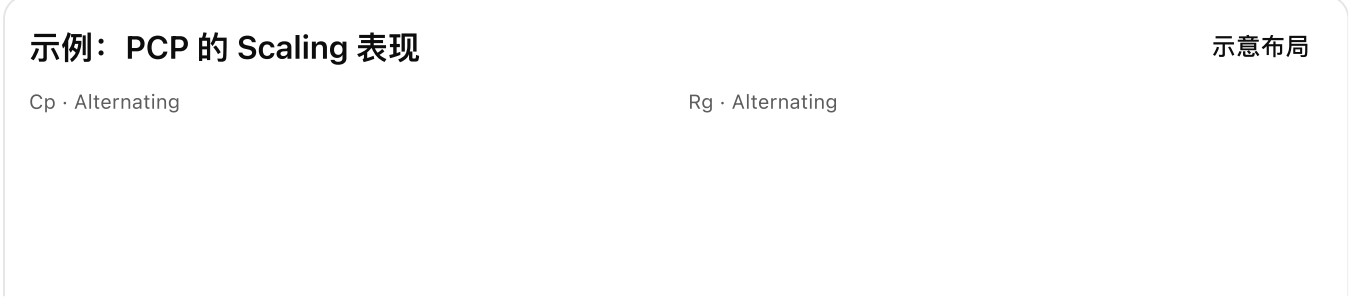
这样更符合科研论文的结果分析逻辑：先回答每个模型自身的性能如何随数据量变化，再回答不同模型谁更优、优势出现在哪些任务和数据规模下。

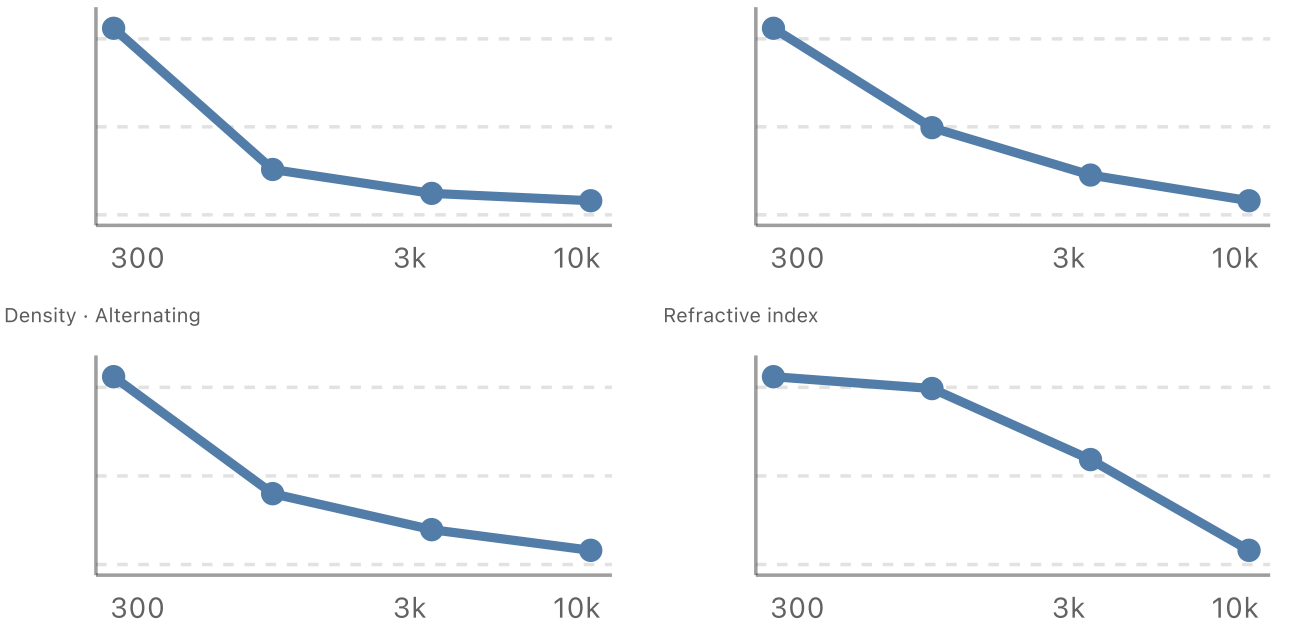
一、推荐的两阶段可视化框架



二、第一阶段：每个模型单独可视化

建议分别为四种模型绘制学习曲线，每种模型一张图，包含 10 个任务子图。





示意图仅用于说明布局；正式图应读取 CSV 真实值，并加入五折标准差。上图没有展示完整的 10 个任务。

对于每一种模型，建议分析三个方面：

1. **数据规模敏感性**：从 300 增加至 1,000、3,000、10,000 条时，RMSE 下降多少？是否出现平台期？
2. **不同性质的学习难度**：哪些任务在较少数据时就能达到较低误差？哪些任务需要更多数据？注意不同性质应分别绘图。
3. **模型稳定性与泛化能力**：五折标准差如何变化？Train、Validation、Test 是否存在较大差距？

其中 RDKit-RF、polyBERT 可以分析 Train/Validation/Test，PCP 和 PPG 在这份 CSV 中只能分析 Test。

三、第二阶段：四种模型之间的性能对比

这一阶段建议围绕同一个预测任务，绘制四种模型的曲线，而不是将不同性质的原始 RMSE 放在同一张坐标图中。

示例：交替共聚物 Rg 的模型比较

仅用于展示四模型对比的图形形式，非原始 CSV 完整数值

以上仅为布局说明，不能作为实际实验数据引用。

建议重点制作以下四类图：

图表	比较内容	解决的问题
四模型 Learning Curves	相同任务下，4 个模型的 RMSE	哪个模型预测精度更好?
相对 RMSE 热力图	29 组配置 × 4 种模型	哪种模型在各项任务上占优?
数据效率比较	不同训练量下相对最佳模型的误差	哪个模型在小样本下更有优势?
稳定性比较	五折 RMSE 标准差	哪个模型结果更稳定?

四、最终建议生成多少张图?

分析层次	图表类型	数量
模型内部	RDKit-RF：10 任务学习曲线	1
模型内部	polyBERT：10 任务学习曲线	1
模型内部	PCP：10 任务学习曲线	1
模型内部	PPG：10 任务学习曲线	1
模型之间	四模型比较：10 任务学习曲线	1
模型之间	相对 RMSE 热力图	1
模型之间	数据效率对比	1
模型之间	五折稳定性对比	1
总计		**8 张主图**

每张学习曲线主图可包含 10 个子图，而不需要把每个预测任务都拆成独立图片。

我的建议是将这 8 张主图作为完整结果分析的核心。 第一阶段先研究各模型自身的 Scaling 行为，第二阶段进行严格的横向比较，最终讨论：传统分子描述符、预训练表示与图神经网络在不同数据规模和聚合物性质上各有什么优势。

这样不仅是可视化结果，还能形成一套逻辑完整、适合论文 Results & Discussion 部分的分析框架。

你说：

该结果都是在哪个数据集上跑出来的结果

思考了 47s >

ChatGPT 说：

我查看了 `PolymerBenchmark2026` 项目的 `SCALING_EXPERIMENTS_METHODS.md`、`DATA_PROVENANCE.md` 和数据生成脚本。

结论：你之前分析的 232 条 Scaling 实验结果，实际上只使用了两个数据集：`MD_5000` 和 `PolyMetriX`。

并不是所有 PolymerBenchmark2026 收录的数据集都参与了 Scaling 实验。

一、两个数据集的来源

1. MD_5000 — 分子动力学模拟数据集

来源于 OMersBench / OPoly26 体系，经 PolyBench26 整理和加工形成。

- 数据类型：分子动力学（MD）模拟性质
- 聚合物类型：均聚物、交替共聚物
- 预测性质：Cp、Cv、Rg、Density、Refractive index
- 共包含 **9 组 Scaling 预测任务**

数据来源说明 ↗

2. PolyMetriX — 实验聚合物 Tg 数据集

来源于 Kunchapu 与 Jablonka 的 Curated Glass Transition Temperature for Polymers（2025）。

- 数据类型：实验测量数据
- 聚合物类型：均聚物
- 预测性质：Tg（玻璃化转变温度）
- 共包含 **1 组 Scaling 预测任务**
- 原始输入包含 7,367 条记录

PolyMetriX 数据集下载页面 ↗

以上来源可以在仓库的数据溯源文档及 Scaling 实验方法中核实。 GitHub +1

二、10 组任务具体使用了哪些数据?

数据集	预测性质	聚合物类型	总数据量	Scaling 训练规模
MD_5000	Cp	交替共聚物	27,802	300/1k/3k/10k
MD_5000	Rg	交替共聚物	27,802	300/1k/3k/10k
MD_5000	Density	交替共聚物	27,802	300/1k/3k/10k
MD_5000	Refractive index	交替共聚物	26,509	300/1k/3k/10k
MD_5000	Cp	均聚物	1,800	300/1k
MD_5000	Cv	均聚物	1,788	300/1k
MD_5000	Rg	均聚物	1,800	300/1k
MD_5000	Density	均聚物	1,800	300/1k
MD_5000	Refractive index	均聚物	1,715	300/1k
PolyMetriX	Tg	均聚物	7,367	300/1k/3k

注意:

- **总数据量不等于训练样本量**。例如 27,802 条数据中，实验固定划出约 10% 作为验证集、10% 作为测试集，再从训练池里抽取 300、1,000、3,000 或 10,000 条。
- `MD_5000` 的 5000 指模拟体系约 5,000 个原子，不是数据集只有 5,000 条样本。
- 不同性质可能来源于重叠的聚合物结构，因此不能把每行的数据量简单相加，视为独立聚合物总数。

三、四个模型是不是在同一批数据上训练的?

是的，同一个预测任务内，四种模型使用一致的数据划分，但输入表示方式不同。

模型	输入表示	数据集
RDKit-RF	RDKit 分子描述符	MD_5000 / PolyMetriX
polyBERT	600 维预训练 Embedding	同上
PCP	wPSMILES 聚合物图表示	同上

PPG	PSMILES 周期图表示	同上

项目使用五组固定数据划分（seed 42），在同一个 fold 中，不同模型共享相同的训练、验证和测试结构集合。这保证了比较的公平性。 GitHub

四、PolymerBenchmark2026 还有哪些数据集没有用于这次 Scaling 实验?

这也是需要区分的一点。

数据集	性质	是否用于当前 Scaling
OMersBench / OPoly26（MD_5000）	Cp、Cv、Rg、Density、Refractive index	✓ 是
PolyMetriX	Tg	✓ 是
VIPEA / Polymer Chemprop	IP、EA	✗ 否
polyVERSE	IP、EA	✗ 否
PolyInfo	多种实验性质	✗ 否

因此，之前另一份 `full_dataset_5fold_cv_rmse.csv` 中虽然有 IP、EA 的性能结果，但**当前 Scaling 实验并没有测试模型在不同训练样本量下预测 IP 和 EA 的表现**。

这对于你后续研究聚合物电子结构性质很重要：如果希望分析模型对于 IP、EA 的小样本学习能力，需要基于 VIPEA 等数据重新设计 Scaling 实验。

另外一个关键区别： 目前这份 Benchmark 主要比较的是基于聚合物化学结构表示的性质预测模型，并没有针对同一组任务直接评估以聚合物单链三维坐标为输入的 3D GNN。因此，它适合作为你后续多层级 3D 聚合物表征方法的二维结构基线，但不能直接得出二维和三维模型谁更优的结论。

你说：

train_size	split
300	test
300	train
300	val

是什么意思

ChatGPT 说：

这三行表示：**使用 300 条训练样本训练同一个模型，然后分别计算模型在训练集（Train）、验证集（Val）和测试集（Test）上的预测误差。**

train_size	split	含义	作用
300	train	使用 300 条训练样本，计算训练集上的误差	判断模型对训练数据的拟合能力
300	val	使用同一个模型，在验证集上计算误差	用于模型选择、超参数调整
300	test	使用同一个模型，在测试集上计算误差	评估模型对未见数据的泛化能力

1. train_size = 300 是什么意思?

它表示**模型实际使用 300 条样本进行训练**，并不是整个数据集只有 300 条，也不是 Train、Val、Test 各有 300 条。

例如，假设某个聚合物性质的数据集共有 10,000 条记录，划分为：

- 训练池：8,000 条
- 验证集：1,000 条
- 测试集：1,000 条

当 `train_size = 300` 时，从训练池中选出 300 条用于训练，验证集和测试集仍保持原来的规模。

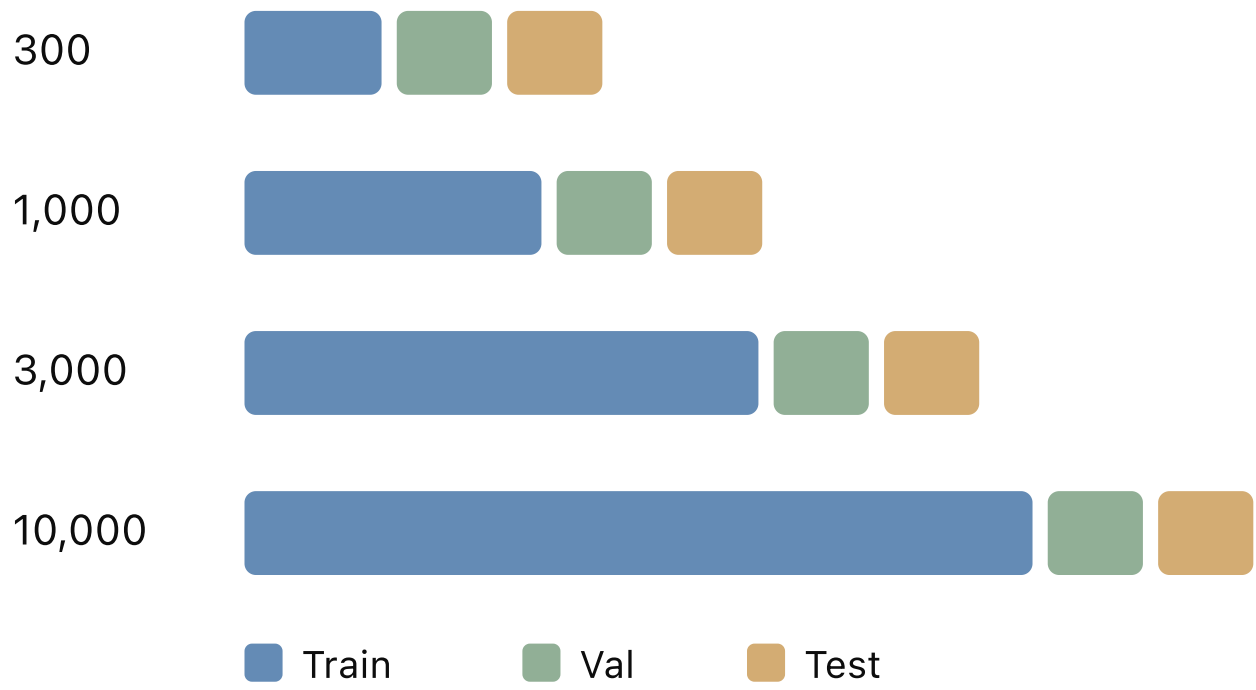
2. 为什么要记录三个 split?

假设某个模型得到以下结果（仅为示例）：

train_size	split	RMSE
300	train	0.08
300	val	0.15
300	test	0.16

说明模型在训练数据上的误差较低，但在未见数据上的误差较高，可能存在一定程度的过拟合。

3. Scaling 实验如何变化?



示意：蓝色训练样本量逐渐增加；绿色验证集和黄色测试集保持固定。彩色块宽度不代表实际样本比例。

对于同一个预测任务，模型分别使用 300、1,000、3,000、10,000 条训练样本重复实验，观察 Test RMSE 是否随训练数据增加而下降。

最重要的一点： 在 `scaling_results_aggregate.csv` 中，如果你的目标是**比较四种模型的预测性能**，应该优先筛选：

```
split == "test"
```

如果希望分析模型是否过拟合，则需要同时观察 Train、Val、Test。但是这份 CSV 中，PCP 和 PPG 只提供 Test 结果，因此不能直接进行四模型完整的 Train/Val/Test 对比。

你说：

上述四个模型，RDKit-RF，polyBERT，PCP，PPG是代表性模型吗？为什么选这四个

思考了 22s >

ChatGPT 说：

是的，RDKit-RF、polyBERT、PCP 和 PPG 都是具有代表性的聚合物性质预测模型，但它们并不代表目前所有最先进的模型（SOTA）。

PolymerBenchmark2026 选择它们的核心原因，是希望比较**四种不同的聚合物结构表征与机器学习建模路线**，而不是简单比较四个神经网络的预测精度。

一、四种模型分别代表什么?

模型	代表性方法	输入表示	核心特点
RDKit-RF	传统机器学习	RDKit 分子描述符	人工计算分子特征，Random Forest 预测
polyBERT	预训练表征学习	600 维 polyBERT Embedding	利用预训练化学语言模型提取聚合物表示
PCP	聚合物图神经网络	wPSMILES	通过带权图消息传递，学习单体及共聚连接信息
PPG	周期性聚合物图网络	PSMILES	显式处理聚合物重复单元的周期连接关系

以上分类与项目官方模型说明一致。 GitHub +1

二、为什么选这四个?



这四种方法可以构成一条从传统分子特征到聚合物专用图表示的比较路线。

1. RDKit-RF：传统机器学习基线

选择理由是，它简单、训练速度快，能衡量传统化学描述符已经可以解释多少性质变化。

如果复杂 GNN 不能优于 RDKit-RF，那么新增模型复杂度的价值就需要重新评估。

2. polyBERT：预训练模型基线

代表通过大规模预训练获得聚合物结构 Embedding，再迁移到具体性质预测任务的路线。

这里需要注意，PolyBench26 的实现是**预先计算 polyBERT Embedding，再训练前馈神经网络（FFN）**，而不是端到端重新训练完整 BERT。

因此它主要用于评价固定预训练表示的迁移价值。 GitHub

3. PCP：聚合物专用 GNN

PCP（Polymer Chemprop）源于 A graph representation of molecular ensembles for polymer property prediction 提出的聚合物图表示思想。

与一般小分子 GNN 相比，它能够处理共聚物的组成权重与连接关系，因此适合分析聚合物特有的结构信息。

4. PPG：周期性聚合物图表示

PPG 将聚合物重复单元的跨边界连接纳入图结构，让模型能够感知链的连续重复关系。

不过，这里的 Periodic 指的是**分子拓扑的周期连接**，不是三维分子动力学模拟中的周期边界条件，也不等价于 Ewald 长程相互作用。

三、为什么 PCP 和 PPG 都是 GNN，却同时选择?

因为它们重点解决的问题不同。

比较维度	PCP	PPG
重点	聚合物组成与连接权重	重复单元的周期拓扑
输入	wPSMILES	PSMILES
图结构	带权连接图	周期连接图
擅长探索	共聚组成、连接概率等	重复链结构的连接关系
共同局限	未显式使用真实单链 3D 构象	未显式使用真实单链 3D 构象

所以选择这两个 GNN，是为了回答：

聚合物性质预测的提升，究竟更依赖组成和连接权重，还是周期重复结构的图表示?

但还需强调：PCP 与 PPG 的网络实现和输入表示都不相同，因此两者的性能差距并不能完全归因于表示方式，需要额外的消融实验。

四、这四个模型足够代表目前的聚合物 AI 研究吗?

对于一个覆盖传统 ML、预训练模型、聚合物 GNN 的 Benchmark，这四个模型是合理的；对于全面评估当前先进聚合物表征方法，则还不够。

例如，其他聚合物基准研究也使用 XGBoost、GCN、GAT、UniMol2、SphereNet、TabPFN 等模型。 cjps.org

尤其是涉及三维聚合物结构时，这四个模型有共同的局限：它们主要从化学连接结构学习，没有显式利用单链原子坐标、空间非键相互作用及构象变化。

五、如果用于你设计的多层级 3D 聚合物模型，应该怎么选择 Baseline?

我建议：

Baseline	是否推荐	目的
RDKit-RF	必选	传统描述符基线
polyBERT	必选	预训练表示基线
PCP	必选	聚合物图消息传递基线
PPG	必选	周期拓扑表示基线
基础 3D GNN（如 SchNet/PaiNN）	**强烈推荐**	证明三维结构信息的贡献
3D GNN + Ewald MP	**强烈推荐**	验证长程相互作用机制
你的多层级 3D 模型	Proposed	验证原子、官能团、重复单元融合的优势

尤其是最后三个模型，建议采用逐步消融：

$$\text{3D GNN} \rightarrow \text{3D GNN} + \text{Ewald MP} \rightarrow \text{Multi-level 3D Model}$$

这样可以分别证明：

- 引入三维构象信息是否有价值；
- 引入长程相互作用是否进一步提高性能；
- 原子、官能团和重复单元的多层级表征是否带来额外提升。

需要保证这些模型使用相同的样本划分，且 3D 构象可用性、构象生成成本和输入信息差异得到明确说明。

总结： PolymerBenchmark2026 选择这四个模型，是因为它们覆盖了传统描述符、预训练 Embedding、带权聚合物图和周期拓扑图四种有代表性的路线。对于你的研究，可以直接保留这四个模型作为 **2D 结构表征 Baselines**，再增加基础 3D GNN 和长程交互模型，才能更有说服力地展示新模型的创新贡献。

你说：

比较了OmersBench数据集的实验结果后，后面需不需要将这些模型跑其他数据，比如VIPEA, PolyVERSE, Polymetrix 数据，解释一下

思考了 1m 20s >

ChatGPT 说：

OMersBench 实验之后，还需要做 VIPEA、polyVERSE 和 PolyMetriX 吗?

建议做，而且对于开发新的聚合物表征模型，这一步很有必要。 但不是简单地让四个模型重复训练，而是通过不同数据集，验证模型是否真正具有跨性质、跨数据来源的泛化能力。

目前，你分析的 PolymerBenchmark2026 Scaling 实验主要覆盖：

- **OMersBench（MD_5000）**：模拟得到的热学、结构和物理性质。
- **PolyMetriX**：实验测量的玻璃化转变温度 Tg。

而 VIPEA、polyVERSE 主要提供 DFT 计算的电子结构性质。把它们加入后，实验就能从物理性质预测扩展到电子结构性质预测。 GitHub +1

一、为什么需要增加其他数据集?

数据集	主要性质	标签来源	可以验证什么?	建议优先级
OMersBench	Cp、Cv、Rg、密度、折射率	MD 模拟及相关计算流程	模型对聚合物结构和物理性质的学习能力	必选
VIPEA	IP、EA	DFT	模型对电子结构性质的预测能力	必选
polyVERSE	电离能、电子亲和能	DFT	模型在另一电子结构数据来源上的表现	推荐
PolyMetriX	Tg	实验测量	模型对真实实验性质数据的适用性	必选

这四个数据源具有互补性，尤其是数据标签的物理来源不同。

例如，在 OMersBench 上表现较好的模型，不一定能在 VIPEA 的 IP 预测中取得同样优势，因为两类性质依赖的结构信息不同。

需要注意：**在多个数据集上取得好结果，证明的是跨数据集的适用范围更广，并不自动证明跨数据集迁移或零样本泛化。** 如果每个数据集都重新训练，那本质上仍然是多个独立的监督学习任务。

二、实际上，PolymerBenchmark2026 已经跑过这些数据集

这是需要重点注意的地方。

你之前分析了两个结果文件：

结果文件	已覆盖数据集	是否已包含四模型结果
`scaling_results_aggregate.csv`	OMersBench、PolyMetriX	是，属于统一划分的 Scaling 实验
`full_dataset_5fold_cv_rmse.csv`	OMersBench、VIPEA、polyVERSE、PolyMetriX 对应任务	是，属于历史完整数据集五折结果

第二个文件实际上已经包含了 IP、EA、Tg 等性质的模型结果。

我进一步核对了仓库里的原始数据：

数据集	原始记录数	性质	当前情况
VIPEA	42,966	IP、EA	有完整数据集的历史模型结果
polyVERSE	EA：368；IP：370	EA、IP	有完整数据集的历史模型结果
PolyMetriX	7,367	Tg	已用于 Scaling 和历史完整数据集实验

不过，仓库明确说明：`full_dataset_5fold_cv_rmse.csv` 是历史汇总结果，缺少逐折样本划分、预测结果等信息，**不能直接与统一划分的 Scaling 实验视为相同协议下的结果**。

GitHub +1

因此：

- 如果只是**介绍、复现作者的 Benchmark 结论**，可以先整理已有结果，不必立即重新跑四个模型。
- 如果是**开发自己的新模型并发表论文**，建议在一致的数据划分下，重新运行所需 Baselines 与新模型，建立可靠的比较。

还有一个细节需要修正：VIPEA 的原始 IP、EA 并非全部直接由常规 DFT 逐项计算，而是使用 **xTB 计算八聚体的电子性质，再通过 DFT 结果进行线性校准**，并对序列和构象取平均。这一点在解释模型预测对象时非常重要。 PMC

三、如果是为了验证你设计的多层级 3D 聚合物表征模型，建议按四个阶段开展

阶段 1：OMersBench 优先

研究空间结构、长程相互作用与物理性质预测

四种原始 Baselines + 基础 3D GNN + 新模型

↓

阶段 2：VIPEA

研究 IP、EA 与共聚物组成、序列和架构的关联

重点做小样本实验、随机划分与结构分组划分

↓

阶段 3：PolyMetriX

验证实验 Tg 性质及模型对数据噪声的适应性

关注局部链刚性、柔性连接和官能团作用

↓

阶段 4：polyVERSE

补充独立电子结构数据来源，检验数据效率与跨来源表现

重点关注小样本稳定性和标签计算方法差异

为什么建议这个顺序?

首先是 OMersBench。 你希望研究的 3D GNN、Ewald MP、原子—官能团—重复单元层级表示，都需要通过合理实验来验证。OMersBench 对聚合物链结构的相关信息较丰富，适合作为最初的方法开发平台。

其次是 VIPEA。 其价值不仅是预测 IP 和 EA，还在于存在不同共聚物组成和架构。可以检验新模型是否学习到了重复单元以外的聚合物信息。不过要避免同一单体组合的不同架构同时进入训练和测试集，从而高估泛化能力。

然后是 PolyMetriX。 Tg 是与链柔性、局部运动和分子间相互作用有关的性质，适合讨论你新增的官能团层级和刚柔连接特征是否有用。但仅凭重复单元表示，不能完整涵盖分子量、结晶度和实验条件的影响。

最后是 polyVERSE。 数据量较小，特别适合作为补充测试。但虽然它和 VIPEA 都有 IP/EA，计算协议、目标定义和标签分布未必一致，因此不能不加处理就直接合并训练。

四、一个关键问题：这些数据并不都能直接用于 3D 模型

这一点会直接决定你后续的工作量。

目前 PolymerBenchmark2026 为 VIPEA、PolyMetriX、polyVERSE 提供的主要是 PSMILES、wPSMILES 等结构表示和性质标签，而不是统一、可直接输入你模型的完整三维聚合物单链坐标。

如果要在这些数据集上运行 3D GNN，需要额外考虑：

1. 从重复单元或共聚组成构建具体的聚合物链，确定 DP 和序列。
2. 生成三维构象并进行几何优化。
3. 对于一个性质标签对应多种链序列或构象的情况，使用合理的构象聚合策略。
4. 确保测试时不使用由标签或测试集信息泄漏得到的结构特征。

特别是 VIPEA，原始标签是对多个序列和构象进行平均的结果。如果模型只输入一条随机构建的短链，其输入与标签所代表的物理对象并不完全匹配。

五、最终推荐的实验安排

实验	目的	是否建议
OMersBench：四模型对比	建立二维基线	必须
OMersBench：3D GNN 与新模型	验证新架构	必须
VIPEA：IP、EA	扩展电子结构任务	必须
PolyMetriX：Tg	扩展实验性质任务	必须
polyVERSE：IP、EA	补充独立小样本测试	推荐
各任务的 Scaling 实验	分析数据效率	推荐
3D / Ewald / FG / Unit 消融	证明各模块贡献	必须

因此，不建议只在 OMersBench 上证明新模型有效后就结束实验。 但也不需要一开始就在所有数据集上完整复现四种模型。

更有效的顺序是：先在 OMersBench 完成架构开发和消融，再使用 VIPEA、PolyMetriX 检验新模型能否适用于电子结构和实验性质，最后使用 polyVERSE 做额外的稳健性验证。

这样最终可以形成三个明确的研究结论：**结构表征是否有效、不同性质是否普适、小样本情况下是否仍有优势。**

你说：

目前在聚合物 性质预测 3D SOTA模型 是什么？适合用来跑baseline

思考了 1m 58s >

ChatGPT 说：

2026 年聚合物性质预测：3D SOTA 模型与 Baseline 推荐

截至 2026 年 11 月，聚合物 3D 性质预测还没有一个公认、在所有数据集和性质上都最优的 SOTA 模型。 不过，目前有几类模型非常值得对比：

- **聚合物专用 3D 模型**：PolyConFM，以及最新的几何片段多尺度表示方法。
- **通用高性能 3D 几何模型**：PaiNN、SphereNet、Uni-Mol2、MACE、EquiformerV3。
- **长程相互作用模型**：PaiNN + Ewald MP 等。

对于你目前设计的 **3D GNN + Ewald MP + 原子/官能团/重复单元多层级表征模型**，我更建议选择能分别验证几何信息、方向信息、长程作用和多层级表征贡献的 Baselines，而不是单纯挑参数量最大的模型。

一、最值得考虑的 3D 模型

模型	主要特点	聚合物研究适配性	Baseline 推荐度
SchNet	基于原子间距离的连续滤波 3D GNN	简单、稳定、适合基础对照	★★★★★
PaiNN	E(3) 等变网络，处理标量及方向向量特征	适合单链三维构象、局部空间相互作用	★★★★★
SphereNet	使用距离、键角和二面角的几何 GNN	对链构象和局部几何特征有价值	★★★★★
Uni-Mol2	预训练 Atom–Pair 三维表征	适合检验预训练表示的贡献	★★★★☆
PolyConFM	聚合物构象中心的生成式基础模型	聚合物专用，竞争性强	★★★★★
MACE / MACE-MP	高阶等变原子表示、多体相互作用	适合用作几何编码器	★★★★☆

EquiformerV3	高阶 SE(3) 等变图注意力 Transformer	强通用架构，但计算和适配成本高	★★★☆☆
PaiNN + Ewald MP	等变短程几何模型加傅里叶空间长程消息传递	与你的长程交互研究直接相关	★★★★★

这里的星级表示**对你的研究的推荐程度**，不是论文性能排名。

其中：

- OpenPoly: A Polymer Database Empowering Benchmarking and Multi-property Predictions 已将 SphereNet 和 Uni-Mol2 用于聚合物性质预测基准。 cjps.org +1
- Unifying Polymer Modeling and Design via a Conformation-Centric Generative Foundation Model 是聚合物专用模型，在作者报告的构象生成、性质预测等任务中取得了有竞争力的结果。 arxiv.org +1
- EquiformerV3: Scaling Efficient, Expressive, and General SE(3)-Equivariant Graph Attention Transformers 在多个原子模拟、材料发现基准上报告了先进结果，但这些结果不等同于聚合物性质预测 SOTA。 arxiv.org +1

二、最值得关注的聚合物专用 SOTA：PolyConFM

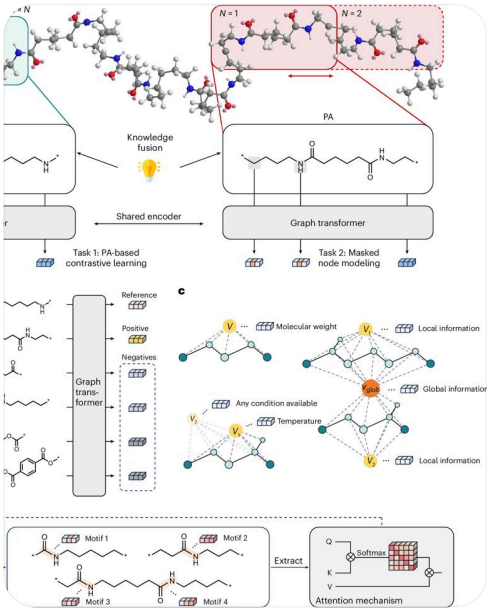
Unifying Polymer Modeling and Design via a Conformation-Centric Generative Foundation Model

这是我建议你重点阅读、并尽可能加入实验对照的聚合物专用模型。

PolyConFM 的核心思想是：聚合物不仅由重复单元化学结构决定，还受到整条链构象的影响。

它通过构象中心的预训练，让模型学习局部重复单元构象、构象之间的空间变换，以及整条聚合物链的三维结构。论文报告了在构象生成和若干性质预测任务中的优势。

arxiv.org +1



与其他模型相比，PolyConFM 最大的优势是**专门针对聚合物单链进行建模**，而不是直接将小分子模型迁移到聚合物任务。

但是，它的训练依赖构象预训练和生成任务，完整复现成本较高。因此更适合作为高水平竞争模型，而不一定是第一个实现的 Baseline。

PolyConFM 官方代码、训练脚本与预训练权重说明 ↗

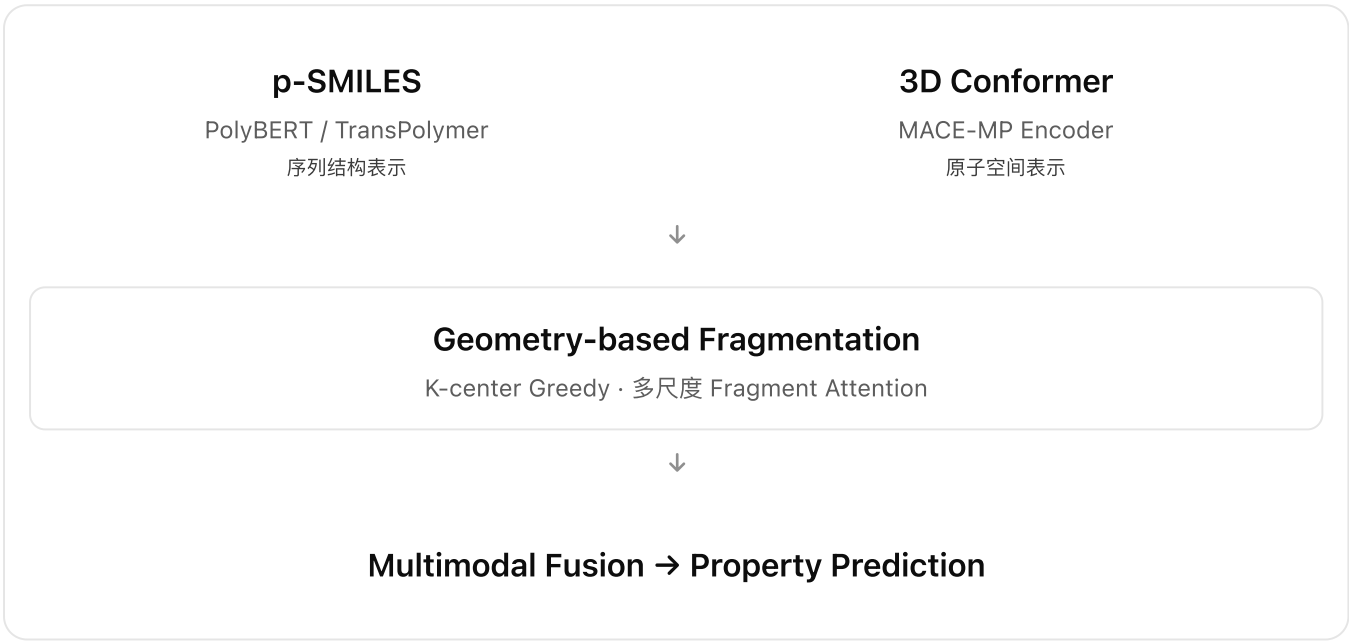
三、最新相关工作：2026 年 11 月的几何多尺度聚合物模型

2026 年 11 月 5 日发布，ACS Omega 已接收

Towards Multiscale Molecular Representation Learning through Geometry-Based Fragmentation for Polymer Property Prediction

这篇论文与你现在的模型设计非常接近，甚至可能是最需要重点比较的工作。 arxiv.cnocta... +1

它主要采用如下架构：



论文利用不同空间半径构建多尺度片段，使用 MACE-MP 作为预训练三维编码器，并将其与 p-SMILES 表示融合。

它在多个预测性质上报告了改善，但增益依赖具体性质。例如，电离能 E_i 没有显示明确的预测改善，部分其他性质的差别也处于结果波动范围内。 arxiv.cnocta... +1

与你的方法最关键的区别是：

维度	这篇 2026 年方法	你的计划
多尺度依据	几何距离分片	化学官能团、重复单元
原子编码	预训练 MACE-MP	3D GNN + Ewald MP
层级交互	Fragment Attention	Atom–Unit 交互及 FG 分支融合
空间范围	从 p-SMILES 生成 3D 结构，示例以单体结构为主	明确建模聚合物单链
长程作用	主要依赖几何编码器	显式增加长程消息传递

这意味着你的创新点不能仅仅表述为“首次使用多尺度三维聚合物表示”。需要重点强调**基于化学语义的层级构建、真实链级空间结构、非键相互作用与跨层信息交互**。

论文中的实现目前注明可向通讯作者申请，未提供直接可运行的公开仓库，因此它非常适合文献层面对比，但完整 Baseline 复现有一定障碍。 arxiv.cnoctave....

阅读 2026 年几何多尺度聚合物论文 ↗

四、我推荐你最终选择哪些 Baselines?

考虑到你计划在约几百到上万条聚合物样本上测试，并且后续还要研究不同 DP 和单链三维构象，我建议分成基础实验和扩展实验两组。

推荐的核心 Baseline 组合

模型	作用	具体要证明什么
PCP	2D 聚合物基线	新的 3D 表示是否优于已有聚合物图表示?
SchNet	基础 3D 模型	仅利用原子距离能达到什么性能?
PaiNN	等变 3D GNN	引入方向向量信息是否有优势?
SphereNet	高阶几何 GNN	距离、角度和二面角能否有效描述链构象?
Uni-Mol2	3D 预训练模型	大规模预训练的 Atom–Pair 表示是否更强?
PaiNN + Ewald MP	长程作用 Baseline	显式长程消息传递带来多少增益?
Proposed Model	你的新模型	化学多层级表征能否进一步改善性能?

其中 **PaiNN、SphereNet、Uni-Mol2 是我最推荐优先跑的三个 3D Baselines**，分别代表等变几何学习、高阶几何学习和三维预训练表示。

如果希望增加更强的聚合物专用竞争模型，再加入 PolyConFM。若算力和实验时间充足，可以进一步增加 MACE 及 EquiformerV3。

为什么尤其推荐 PaiNN + Ewald MP?

Ewald MP 原论文已公开将该模块集成至 SchNet、DimeNet++、PaiNN、GemNet 等模型的实现。 GitHub +1

因此，你可以使用同一个 PaiNN Backbone，建立一组很清晰的比较：

控制变量实验设计

A	PaiNN	基础等变 3D 表征
B	PaiNN + Ewald MP	检验长程消息传递
C	PaiNN + Ewald MP + FG	检验官能团表示
D	PaiNN + Ewald MP + FG + Unit + Fusion	你的完整方法

这个设计有一个优点：能够明确区分模型性能提高来自**长程交互**，还是来自**化学多层级表示**。对于论文创新性论证，比简单地增加大量不同架构更有说服力。

需要提醒，Ewald MP 原论文主要评估的是原子能量预测，迁移到聚合物性质预测后是否有优势，仍然需要实验证明。

五、不同数据集上应该使用哪些 3D Baselines?

数据集	主要性质	我建议优先跑的模型
OMersBench	Rg、Cp、Cv、密度等	SchNet、PaiNN、SphereNet、PaiNN+Ewald
VIPEA	IP、EA	PaiNN、Uni-Mol2、MACE-based Encoder
PolyMetriX	Tg	PaiNN、SphereNet、Uni-Mol2
polyVERSE	IP、EA	PaiNN、预训练 Uni-Mol2、PCP

需要注意一个重要问题：

这些数据集并非都直接提供与你模型输入一致的完整聚合物单链 3D 坐标。
PolymerBenchmark2026 公开整理的数据主要使用 PSMILES、wPSMILES 和分子特征表示；OMersBench 的源 JSONL 还包含 DP、链数和原子数等模拟元数据。 GitHub +1

因此真正开始实验之前，需要确认坐标从哪里获得，以及它是否代表性质标签对应的真实分子结构。

例如，如果 Rg 标签是从一个包含多条聚合物链的 MD 模拟体系中得到的，那么只给模型输入一条任意生成的单链构象，并不能保证输入与标签的物理对象一致。

另外，比较模型时应统一数据划分、构象生成方法、DP、优化策略和评估指标。不能把一篇论文在自己数据集上报告的 RMSE，直接与另一篇论文的 RMSE 比较。

六、开源代码与论文入口

模型	官方资源
SchNet / PaiNN	SchNetPack ↗
SphereNet	DIG 3D Graph ↗
Uni-Mol2	Uni-Mol2 ↗
PolyConFM	PolyConFM ↗
MACE	MACE ↗
EquiformerV3	EquiformerV3 ↗
Ewald MP	EwaldMP ↗
OpenPoly Baseline 实现	OpenPoly Benchmark ↗

七、我的最终建议

如果你的目标是发表一篇关于 **Hierarchical 3D Polymer Representation Learning** 的方法论文，我建议分两步：

第一步：用 4 个现成模型建立可靠基线。 优先完成 PCP、PaiNN、SphereNet、Uni-Mol2，并在相同聚合物数据及相同训练划分上对比。

第二步：集中证明自己的创新。 以 PaiNN 为基础加入 Ewald MP，再分别加入 FG、Repeat Unit、Inter-level 和 Fusion，完成逐模块消融。最后与 PolyConFM 等较强聚合物专用方法对比。

有一点尤其值得注意：**近期已有几何分片多尺度模型，所以你需要证明的不仅是多层级架构有用，更是化学定义的官能团层级、链级结构和长程空间交互比通用几何分片带来了什么独特价值。**

这会是新模型能否形成明确研究贡献的关键。

你说：

所以我第一步应该先分析baseline模型结果，同时写自己模型的代码，在OMersBench上训练，而后在其他数据技上再测试?

ChatGPT 说：

是的，你理解的研究路线基本正确。 我建议采用 **“Baseline 分析 → 新模型开发 → OMersBench 验证 → 其他数据集验证 → 消融与泛化分析”** 的路线。

不过，有一个重要调整：**在正式开发 3D 模型之前，需要先确认 OMersBench 的三维结构能否与性质标签正确对应。** 否则即使模型代码写好了，也可能无法进行有效训练。

一、推荐的整体研究路线

01 **Baseline 分析与数据检查**

当前阶段

整理已有四模型结果，检查 SMILES、3D 坐标、DP、性质标签

↓

02 **搭建基础 3D 模型**

先实现 PaiNN 或其他 3D GNN，跑通数据、训练和评估

↓

03 **开发自己的多层级 3D 模型**

依次加入 Ewald MP、官能团、Repeat Unit 和跨层交互

↓

04 **OMersBench 上完整对比**

比较新模型与 2D/3D Baselines，完成 Scaling 和消融实验

↓

05 **其他数据集验证**

VIPEA、PolyMetriX、polyVERSE：验证不同性质与数据规模

↓

06 **泛化、可解释性与论文结果**

分析不同官能团、构象、DP、数据量对预测性能的影响

二、现阶段应该并行做的三件事

工作	具体任务	预期产出
A. Baseline 分析	整理 RDKit-RF、polyBERT、PCP、PPG 在各数据集上的 RMSE、Scaling 变化和标准差	Baseline 结果分析表与可视化
B. 数据预处理	检查 OMersBench 的 SMILES、原子坐标、原子归属、DP、标签及 Train/Val/Test 划分	能输入 3D GNN 的 Dataset

C. 模型代码开发	编写 Atom、FG、Unit、Ewald MP、Fusion 模块	初始可训练代码框架

建议让 A、B、C 并行进行，但**先完成 B 的最小可行性检查，再开展大规模训练**。

尤其要确认：

- 数据集是否真正提供原子级 3D 坐标，而不仅仅是 MD 模拟参数。
- 每个性质标签对应单链、多个构象还是多链模拟体系。
- 如果某些性质（例如 Rg）可以直接由输入坐标计算，需要避免产生目标泄漏或没有实际预测价值的任务。
- DP 不固定时，模型如何进行 Batch、节点归属和全局 Readout。

三、OMersBench 上不建议一开始就运行全部任务

我建议先选择 2–3 个任务建立训练闭环。

顺序	性质	选择原因
1	Density	用于初步验证空间结构信息，但需注意密度定义与模拟条件
2	Rg	与链构象直接相关，适合测试几何表示，但必须检查标签泄漏
3	Cp	补充热学性质，考察对结构以外因素的预测能力

代码跑通后，再扩展到 OMersBench 的其余任务。

同时建立以下消融实验：

模型版本	作用
M0：基础 3D GNN	作为 3D Baseline
M1：3D GNN + Ewald MP	验证长程交互
M2：M1 + Atom–Unit Interaction	验证重复单元层级
M3：M2 + FG Representation	验证官能团信息
M4：M3 + Hierarchical Fusion	你的完整模型

这样才能明确模型精度提升究竟来自哪个模块，而不是把所有设计一次性加入后难以解释。

四、后续如何使用其他数据集?

这里有一个特别重要的区别：**在 OMersBench 上训练好的性质预测模型，不能直接拿去预测 VIPEA 的 IP、EA 或 PolyMetriX 的 Tg。**

因为它们的预测目标不同。

你可以采用两种路线：

实验方式	方法	能证明什么
独立监督训练（优先）	在 OMersBench、VIPEA、PolyMetriX 等数据集上分别训练并测试所有模型	新架构对不同性质的适用性
预训练 + 微调（进阶）	先在较大的结构数据上预训练编码器，再针对 IP、EA、Tg 更换预测头并微调	预训练表示的迁移能力和小样本优势

我建议先做第一种，再考虑第二种。

而且不同数据集的数据处理、三维构象生成方法及模型对比协议都需要尽量统一。

五、最后应该形成怎样的论文实验体系?

实验部分	研究问题
Experiment 1：Overall Performance	你的模型是否优于传统 2D/3D Baselines?
Experiment 2：Scaling Analysis	不同训练数据规模下，新模型是否仍有优势?
Experiment 3：Ablation Study	Ewald、FG、Unit 和 Fusion 分别贡献多少?
Experiment 4：Cross-dataset Evaluation	模型是否适用于不同来源、不同性质的数据?
Experiment 5：DP & Conformation Sensitivity	模型对聚合度及构象变化是否敏感?
Experiment 6：Chemical Interpretability	官能团、刚柔连接和空间作用如何影响性质?

最终建议：你现在不需要把主要精力放在重新运行所有四个 2D Baselines 上。 先把作者已有结果作为参考，重点做好 OMersBench 的 3D 输入检查，并尽快训练出一个基础 PaiNN 模型。

一旦基础 3D GNN 能够稳定训练、评估，并与已有 Baseline 结果合理对齐，再逐步加入 Ewald MP 和多层级模块。这将是整个研究最关键的第一个技术里程碑。

你说：

Towards Multiscale Molecular Representation Learning through Geometry-Based Fragmentation for Polymer Property Prediction 介绍方法设计，有没有好的insights

思考了 1m 36s >

ChatGPT 说：

论文精读：Geometry-Based Fragmentation for Polymer Property Prediction

Makoto Takamoto et al. · 2026 年 11 月 5 日 · ACS Omega 已接收

论文：Towards Multiscale Molecular Representation Learning through Geometry-Based Fragmentation for Polymer Property Prediction ↗

这篇论文与你正在设计的多层级 3D 聚合物表征模型高度相关，但两者的研究重点存在重要区别。

论文的核心创新是：**不依赖预定义化学规则，而是利用三维坐标自动把分子划分为不同空间尺度的 Fragment，再通过 Attention 融合这些尺度的信息。**

它想解决的是如何构建通用、可调节分辨率的分子表示，而不是专门设计一个理解聚合物链、官能团作用和重复单元相互关系的模型。

我认为对你最有价值的 Insights 有三个：

1. **化学层级与空间尺度不应完全等同。** 官能团是化学定义的结构单元，而空间邻域可能包含来自不同官能团、甚至不同重复单元的原子。
2. **多层级的重点不是提取更多 Embedding，而是如何让不同层级交换信息。** 这篇论文的尺度聚合机制提供了参考，也留下了进一步改进的空间。
3. **真正值得探索的是空间相互作用与化学结构的联合表示。** 你已经计划加入的 FG–FG Pair、Atom–Unit Interaction 和 Ewald MP，可以围绕这个问题建立更明确的研究假设。

一、论文整体方法架构



它的架构可以概括为：

$$\boxed{\text{SMILES Representation} + \text{3D Representation} + \text{Multiscale Fragments}} \longrightarrow \hat{y}$$

论文使用预训练的 MACE-MP 提取 3D 原子特征，并在下游训练时冻结其参数，而不是重新训练整个原子势模型。 arxiv.org +1

二、核心创新 1：基于 K-Center Greedy 的几何分片

这是论文最主要的算法创新。

1. 为什么不直接按照官能团划分?

传统方法（例如 BRICS）通过化学规则决定哪些键可以断开，再形成 Fragment。

论文作者认为有两个问题：

- 某些未知或复杂结构可能不适合现有规则。
- 很难系统地控制 Fragment 的空间尺寸，也不方便直接构建多个空间尺度。

因此，作者提出：**仅根据原子三维坐标和距离阈值决定 Fragment 的划分。**

2. K-Center Greedy 如何工作?

假设有一个分子，包含 N 个原子，每个原子的三维坐标是：

$$X = \{x_1, x_2, \ldots, x_N\}, \quad x_i \in \mathbb{R}^3$$

首先选择一个原子作为聚类中心。随后反复寻找距离现有中心集合最远的原子：

$$c_{t+1} = \arg\max_i \min_{c \in C_t} \|x_i - x_c\|_2$$

直到所有原子与最近中心的距离都小于 r_{pool}。

之后使用 r_{cutoff} 构建 Fragment。

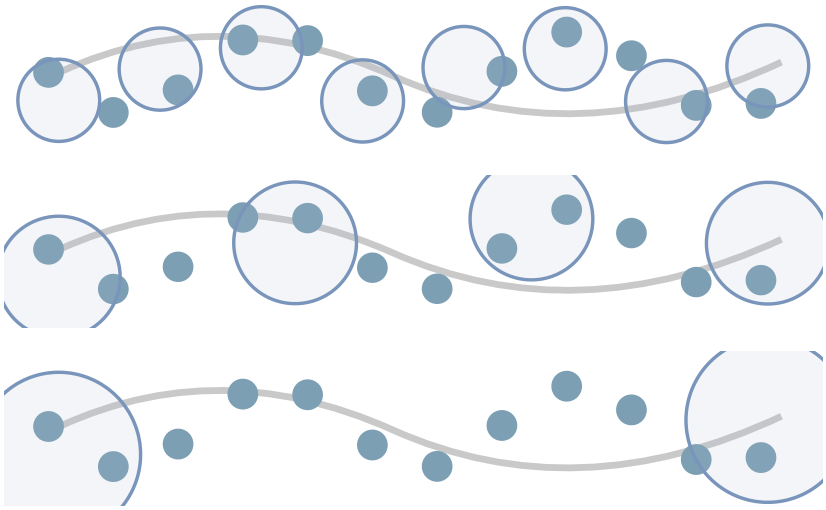
论文采用：

$$r_{\text{cutoff}} = \frac{r_{\text{pool}}}{2}$$

依据原文采用的邻域定义，有效的原子间截断距离是 $2r_{\text{cutoff}}$。若一个原子落入多个 Fragment，则分配给最近的中心；未被覆盖的原子成为单独 Fragment。这样最终得到互不重叠、覆盖所有原子的分组。 arxiv.org

3. 如何实现多尺度?

论文设置三个空间尺度：



概念示意：尺度增大时通常需要更少中心，Fragment 覆盖的空间范围也增大。图中的分片数量并非论文真实数据。

Insight 1： 对你的模型，可以借鉴 K-Center Greedy 做长链空间邻域筛选，而不是直接用它替代官能团提取。

例如，DP=120 的聚合物可能包含上千个原子。如果计算全部 Atom Pair，代价接近 $O(N^2)$。可以在空间上先选代表性原子或关键官能团，再筛选重要的相互作用对。

这能降低计算成本，但需要保留化学上重要的接触，例如氢键、偶极相互作用和远距离链折叠接触，避免几何筛选误删关键作用。

三、核心创新 2：Multiscale Fragment Attention

论文没有简单地对所有 Fragment 求平均，而是在不同空间尺度上使用独立的 Self-Attention。

其处理流程是：

$$\text{Atomic Embedding} \rightarrow \text{Fragment Features} \rightarrow \text{Self-Attention} \rightarrow \text{Pooling} \rightarrow h_{\text{scale}}$$

对于每个空间尺度，得到一个表征 Token。论文还保留全局原子表示分支，最后融合多个尺度的表示，并使用 1D Global Depthwise Convolution 进一步聚合。

这意味着什么?

假设模型预测聚合物的某个性质：

- 小尺度可能学习局部原子环境。
- 中尺度可能学习官能团附近的结构。
- 大尺度可能学习较长片段的局部拓扑。

但必须注意：**几何尺度并不严格等于化学层级。**

例如，两个处于空间上很近、但并不共价相连的原子，可能被划分到同一个 Fragment。

这对于捕捉空间接触很有利，却不一定能够准确区分氢键、柔性连接和真正的化学官能团。

Insight 2：你的 FG 层级应明确保留化学意义

我建议你区分两种关系：

关系	判断依据	物理意义
FG–FG Covalent Edge	化学键连接	刚性片段、柔性连接、链拓扑
FG–FG Spatial Pair	三维距离与空间几何	氢键、偶极作用、空间接触等

这是一个非常有价值的设计差异。

以两个羰基官能团为例，它们在化学拓扑上可能相距很远，但由于链折叠，在三维空间中变得接近。

如果只使用普通图消息传递，模型可能需要很多层才能交换信息；但使用 FG Spatial Pair，就可以直接表示它们的空间关系。

你可以定义：

$$e^{3D}_{FG_i,FG_j} = \mathrm{MLP}\left(d_{ij}, d^{\min}_{ij}, \Delta s_{ij}, \phi_{ij}, t_{ij}\right)$$

其中 d_{ij} 是官能团中心距离，$d^{\min}_{ij}$ 是最短原子间距离，Δs_{ij} 表示链上的序列间隔，ϕ_{ij} 是适用时的相对取向，而 t_{ij} 是接触或相互作用类别。

这是针对你模型提出的设计建议，**不是论文原始公式**。

四、核心创新 3：Multimodal Fusion

论文将三个信息来源一起输入融合模块：

1. 聚合物 p-SMILES 的预训练表示。
2. MACE-MP 提取的原子三维表示。
3. 多尺度几何 Fragment 表示。

使用 Cross-Attention、残差连接、LayerNorm 和 Feed Forward 进行模态融合，再经过 Decoder 输出性质。

这比单纯拼接向量更灵活，因为不同表示之间可以通过 Attention 进行信息选择。

但它与您目前计划的 Atom–Unit 交互仍有重要差别：**论文的 Cross-Attention 主要用于模态融合，而你的 Atom–Unit 交互发生在分层编码过程中。**

五、实验结果：它真的证明几何分片有效吗?

这是我认为最需要仔细看的一部分。

论文使用 Polymer Genome / TransPolymer 的七个性质预测任务，主要包括链带隙、体相带隙、电子亲和能、电离能、结晶倾向、介电常数和折射率。并不是在 OMersBench 上进行实验。 arxiv.org

选取论文 Table 1 的 TransPolymer 相关结果：

性质	预训练 TransPolymer	TP + MACE + 3D 融合	RMSE 改善
Chain bandgap	0.44	0.42	4.5%
Bulk bandgap	0.53	0.45	15.1%
Crystallization tendency	17.5	16.6	5.1%
Ionization energy	0.39	0.38	2.6%

结果来自论文 Table 1。最后一列按均值计算，未代表统计显著性。

但论文的消融实验 Table 2 给出了一个更重要的发现：

加入 Fragment Branch 后，预测精度并不总是提高。

例如，在 PolyBERT + MACE 组合中：

- Chain bandgap：有 Fragment 时 RMSE 为 0.42；去掉 Fragment 后为 0.41。
- Crystallization tendency：有 Fragment 为 17.1；去掉 Fragment 为 17.5。
- 折射率：有 Fragment 为 0.085；去掉 Fragment 为 0.081。

作者也指出，多个分支的性能差异通常处于标准差范围内，因此尚不能得出“几何分片总能带来明显提升”的结论。 arxiv.org

Insight 3：多尺度表示不是越多越好，关键是额外尺度是否提供真正独立且与任务相关的信息。

这也支持你之前提出的担忧：Atom、FG、Unit 是否会产生信息冗余?

我的看法是，真正应该强调的是不同层级所引入的**不同归纳偏置**，而不是单纯增加网络分支。

六、这篇论文目前存在什么不足?

结合原文结果，我认为有四个值得进一步研究的地方。

局限	论文当前设计	可以进一步探索的方向
化学语义不明确	以几何半径定义 Fragment	显式官能团与化学键类型
聚合物链信息有限	示例和分片主要围绕 p-SMILES 对应的单体结构	完整单链、DP、序列、链折叠
跨尺度交互较浅	不同尺度分别编码后聚合	Atom–Unit 双向消息传递与 FG 交互
构象代表性有限	每次输入单个生成构象	多构象集合、MD 构象采样

论文作者还明确承认：虽然为每条 p-SMILES 生成多个构象，但每次模型输入只有一个构象，并没有同时建模完整构象集合。 arxiv.org

尤其是第二点非常重要。

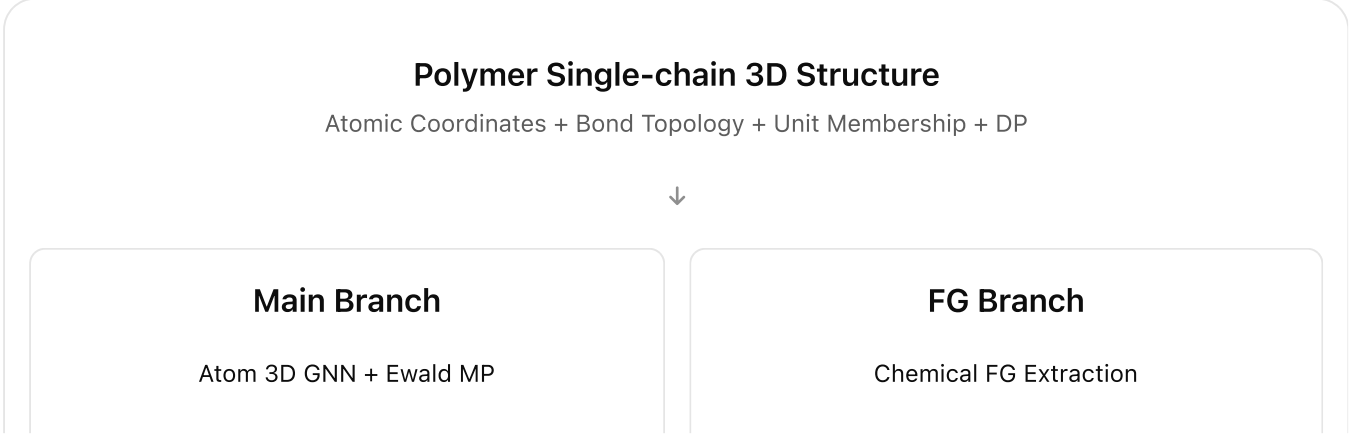
单体的三维结构与完整聚合物链的三维结构是两个不同的建模对象。

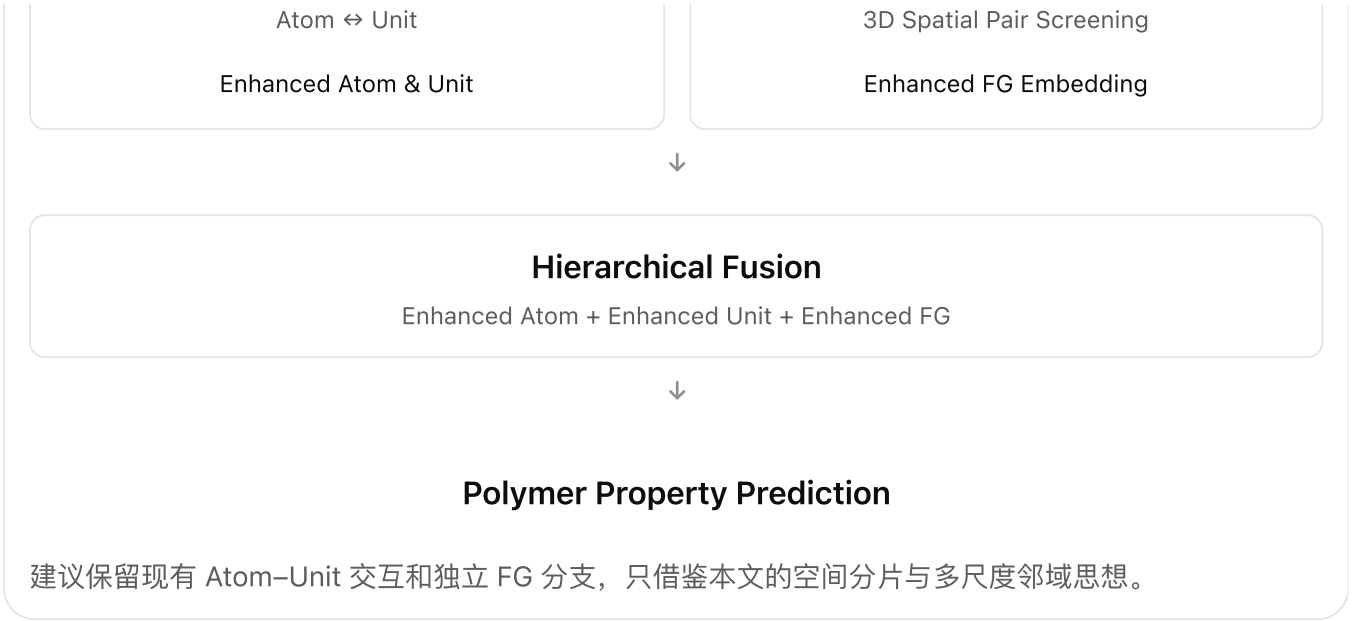
仅凭单体的一个构象，无法完整描述链折叠、重复单元间空间接触、构象分布和链长效应。

对于你的研究，这可能是比“再增加一个层级”更有价值的方向。

七、对你现有模型架构，我建议这样调整重点

你目前计划的框架，不必改成论文的 K-Center 分片结构。我更建议保留化学定义的层级，同时吸收几何尺度筛选思想。





建议保留现有 Atom–Unit 交互和独立 FG 分支，只借鉴本文的空间分片与多尺度邻域思想。

最值得做的新增实验：Chemical vs Geometric Fragmentation

我建议将它作为一个专门的 Ablation Study：

实验	FG / Fragment 构建方法	用途
A	无 FG 层级	基础 3D Backbone
B	K-Center Geometry Fragment	几何分片基线
C	Chemical Functional Group	化学语义分片
D	Chemical FG + 3D Spatial Pair	化学与空间作用联合
E	D + Atom–Unit + Ewald MP	完整模型

保持 Backbone、数据划分、训练预算尽量一致。

这样的比较能够回答一个很有价值的问题：

在聚合物性质预测中，基于真实化学结构定义的官能团表示，是否比仅通过空间几何聚类形成的 Fragment 更有效？进一步加入非键空间作用后，能否获得额外增益？

你还可以使用两个更深入的实验来加强结论：一是研究不同 DP 和构象对模型性能的影响；二是比较空间邻近但化学上不相连的 FG Pair 与普通共价连接 FG Edge 的贡献。

八、最终的 Research Insights

我将这篇论文带来的启发按研究价值排序：

1 **Chemical–Geometric Dual Representation**

化学定义决定“是什么官能团”，三维信息决定“它与谁发生空间接触”。这是最值得深入研究的交叉点。

2 **Polymer Chain-Aware Representation**

相比只分析单体结构，更明确地学习聚合度、链序列、链折叠和重复单元之间的作用，有望体现聚合物与普通小分子的本质区别。

3 **Interaction-Aware Hierarchical Learning**

不只是 Atom、FG、Unit 三个 Embedding 的聚合，而是让层级之间通过明确的物理关系进行信息交换。

我的结论

这篇论文最大的贡献是 **Geometry-based Fragmentation 与多尺度表示构建**，但在聚合物链专用建模、化学官能团语义、长程相互作用和跨层消息交互方面仍有进一步研究空间。

对于你正在设计的模型，我不建议直接照搬 K-Center 分片来代替官能团层级。更有价值的做法是：

保留 Atom–Unit 主干和 FG 独立分支，用 K-Center/空间邻域策略筛选重要的三维作用对，再通过明确的化学与物理特征完成跨层表征。

这样你的模型与这篇论文形成了清晰的差异：

- 它侧重 **Geometry-defined Multiscale Fragments**。
- 你的方法可以侧重 **Chemistry-informed, Interaction-aware Hierarchical 3D Polymer Representation**。

不过，这些是值得检验的研究假设，并非已经被证实的优势。论文作者也在 Discussion 中明确提出，结合几何分片和化学规则是未来值得探索的方向。 arxiv.org

最后一个实际问题：论文目前注明实现代码可向通讯作者申请，尚不是可直接下载并完整复现的公开实现。因此，实验上可以先用自己实现的 K-Center Fragment Baseline 做公平比较，再视情况获取作者原始代码。 arxiv.org

你说：

Geometry-based Fragmentation 意思是不是按照拓扑结构化学规则划分片段，而是按照3d 空间中的距离划分（选中关键原子，围绕其按照一定半斤展开来划分？

ChatGPT 说：

对的，你的理解基本完全正确！ 这篇论文的 Geometry-based Fragmentation **不是按照拓扑结构或预定义化学规则划分片段，而是根据原子在三维空间中的距离进行划分。**

具体来说，就是你理解的：

选择代表性原子作为中心 → 以该原子为中心，按照设定的空间半径寻找邻近原子 → 将这些原子划分为一个 Fragment。

但有两个细节需要注意。

1. 如何选择中心原子?

不是根据官能团重要性来选择，而是使用 **K-Center Greedy（最远点贪心算法）**：

1. 首先选择一个重原子作为初始中心。
2. 找到距离当前所有中心最远的重原子，作为新中心。
3. 重复选取，直到每个重原子与最近中心的距离都小于指定阈值 r_{pool}。
4. 围绕这些中心划分 Fragment。

因此，中心原子不一定是羰基碳、氧或氮等化学上重要的原子，而是由空间分布决定的。

2. 如何根据半径划分 Fragment?

论文使用两个参数：

- r_{pool}：控制中心原子的空间分布和数量。
- r_{cutoff}：控制原子邻域的大小。

论文中设置：

$$r_{\text{cutoff}} = \frac{r_{\text{pool}}}{2}$$

根据其邻域定义，实际判断两个原子是否处于同一中心邻域的距离阈值是：

$$d(i,c) \leq 2r_{\text{cutoff}} = r_{\text{pool}}$$

如果某个原子同时落在多个中心邻域内，就分配给距离最近的中心；没有被覆盖的原子单独形成 Fragment。 arxiv.org

3. 与化学官能团划分最大的区别

比较维度	Chemical Fragmentation	Geometry-based Fragmentation
划分依据	化学键、官能团规则	3D 欧氏距离
是否考虑化学键	是	划分过程不依赖
是否需要 3D 坐标	不一定	必须
片段化学意义	通常明确	不一定明确
是否能将不成键的原子归为同一片段	通常不会	**可以**
是否可能将同一官能团拆开	取决于规则	**可以**

例如，聚合物链发生折叠后，两个在拓扑结构上距离很远的原子，可能在三维空间中非常接近。

Geometry-based Fragmentation 就有可能将它们划分到同一个 Fragment，即使它们之间没有共价键。

4. 对你的模型有什么启发?

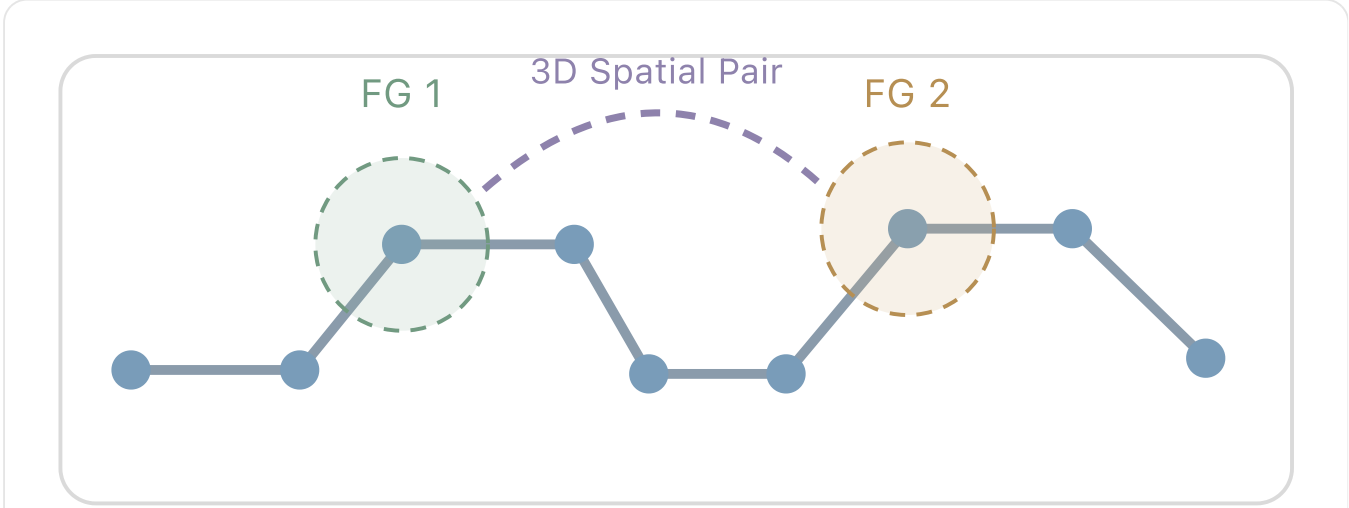
这一点特别值得注意：

Geometry-based Fragmentation 生成的是空间邻域，不一定是真正的化学官能团。

而你计划设计的 FG 模块可以同时保留两个概念：

- **FG Node：** 使用化学规则提取官能团，保持其完整的化学定义。
- **FG Spatial Pair：** 根据 3D 距离与相对取向，构建不同官能团之间的空间相互作用。

例如：



概念示意：绿色和黄色为化学定义的两个官能团，紫色虚线表示由三维位置确定的非共价空间关系。

这样就不会像纯几何分片那样，可能把一个官能团拆开，同时还能捕捉链折叠产生的空间接触。

所以可以用一句话总结两种思想的区别：

- 论文的方法：**空间上靠近的原子 → 组成一个 Fragment。**
- 你的方法：**化学上属于同一官能团的原子 → 组成 FG Node；空间上靠近的不同 FG → 建立 FG Spatial Pair。**

我更建议你保留后一种设计，因为它能更清楚地区分**化学结构信息**和**三维空间相互作用信息**。

你说：

空间上靠近的不同 FG → 建立 FG Spatial Pair。 中FG 指的是化学规则划分的FG 还是空间临近划分的FG?

ChatGPT 说：

这里的 **FG 指的是按照化学规则划分的 Functional Group（官能团）**，而不是通过三维空间距离划分得到的 Fragment。

你目前的模型设计应该明确区分两个概念：

概念	划分依据	作用
FG Node	化学拓扑和官能团识别规则（如 Ertl 算法）	表征官能团自身的化学性质
FG Spatial Pair	两个化学 FG 在三维空间中的相对位置	表征官能团之间的空间相互作用
Geometry-based Fragment	原子三维坐标、空间距离阈值	将空间邻近的原子聚合为几何片段

具体举例

假设聚合物单链中存在两个羰基官能团：

- FG_1：位于 Repeat Unit 3，通过化学规则识别。
- FG_2：位于 Repeat Unit 15，同样通过化学规则识别。

虽然两个官能团在聚合物链的拓扑结构上相隔很远，但链折叠后，它们可能在三维空间中靠近。

你的模型可以建立：

$$FG_1 \xleftrightarrow[\text{3D Spatial Pair}]{} FG_2$$

这个 Pair 可以包含：

$$e_{ij}^{FG} = [d_{\text{centroid}}, d_{\min}, \Delta\text{Unit}, \text{Orientation}, \text{Interaction Features}]$$

其中：

- d_{centroid}：两个官能团的几何中心距离。
- $d_{\min}$：两个官能团所属原子之间的最短距离。
- ΔUnit：两个官能团所属重复单元的序列间隔。
- Orientation：两个官能团的相对取向（针对具有明确方向的官能团）。
- Interaction Features：氢键可能性、偶极相互作用特征等。

注意，Interaction Features 可以是根据几何和化学规则计算的**潜在相互作用特征**，不能简单将空间靠近等同于实际发生了某种相互作用。

那 Geometry-based Fragmentation 对你的模型还有什么作用?

我更建议将论文中的几何方法用于 **FG Spatial Pair 的候选筛选**，而不是替代 FG Node。

也就是说：



这里还有一个设计细节：如果希望表征刚性与柔性连接，**FG Covalent Edge** 和 **FG Spatial Pair** 最好分开定义。

- **FG Covalent Edge**：反映官能团之间的化学连接关系、刚柔连接和链拓扑。
- **FG Spatial Pair**：反映三维空间邻近关系，包括不直接成键的官能团。

二者可以作为 FG 图中的不同边类型，也可以分别使用拓扑图与 Pair 矩阵进行编码。

最终建议：你的 FG Node 始终保持化学定义，3D 信息只用来构建 FG 之间的 Spatial Pair。 这样既保留官能团的化学可解释性，又能捕捉聚合物链折叠产生的非局部空间相互作用。

你说：

空间上靠近的原子 → 组成一个 Fragment。 这个暂时可以不考虑吗

ChatGPT 说：

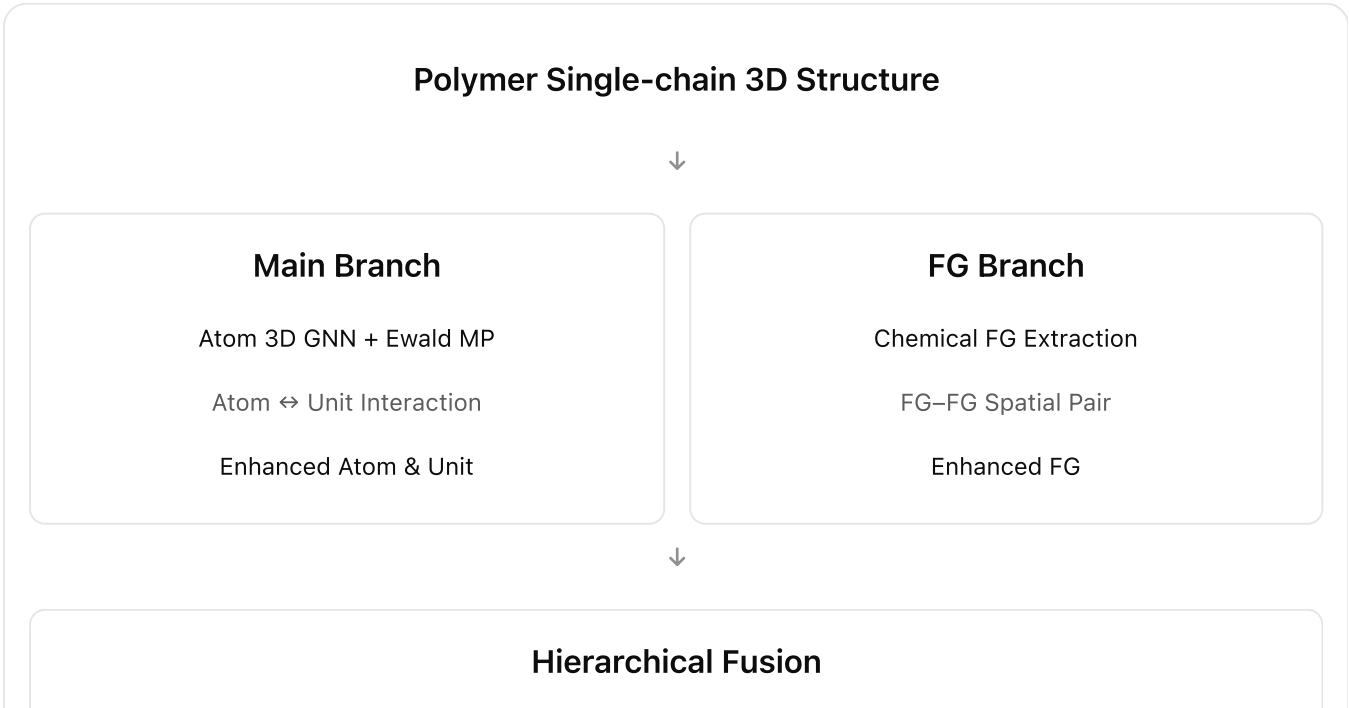
可以，而且我建议你现阶段暂时不考虑 Geometry-based Fragmentation（基于空间距离的原子分片）。

因为你目前的模型已经包含三个明确的表征层级：

1. **Atom Level（原子级）**：3D GNN + Ewald MP，学习局部几何和长程空间相互作用。
2. **Functional Group Level（官能团级）**：通过化学规则提取 FG Node，再根据三维空间关系建立 FG Spatial Pair。
3. **Repeat Unit Level（重复单元级）**：学习聚合物重复单元及其连接和空间关系。

再加入 Geometry-based Fragmentation，相当于增加第四种结构划分方式，可能带来额外复杂度和信息冗余。

目前建议保留的模型架构



Enhanced Atom + Enhanced Unit + Enhanced FG

↓

Property Prediction

为什么现在不需要加入几何分片?

考虑维度	目前的设计	是否需要 Geometry Fragment
原子局部空间环境	3D GNN	暂不需要
长程空间相互作用	Ewald MP	暂不需要
化学官能团语义	Chemical FG Node	暂不需要
FG 之间的空间接触	FG Spatial Pair	暂不需要
聚合物重复结构	Atom–Unit Interaction	暂不需要
大规模原子计算优化	空间邻居筛选、稀疏 Pair	可作为后续优化方向

需要强调，Ewald MP 与 FG Spatial Pair 并不能保证捕捉全部空间作用；这里的"不需要"指的是**当前没有必要增加一个新的分片层级**，而不是这些方法在功能上完全等价。

我建议的开发顺序

先固定目前三个层级，按下面顺序开发和实验：

$$
\begin{aligned}
&M_0 : \text{3D GNN} \\
&M_1 : \text{3D GNN} + \text{Ewald MP} \\
&M_2 : M_1 + \text{Atom–Unit Interaction} \\
&M_3 : M_2 + \text{Chemical FG} + \text{Spatial Pair} \\
&M_4 : M_3 + \text{Hierarchical Fusion}
\end{aligned}
$$

其中，FG 分支可先独立编码，再与增强后的 Atom、Unit 表示融合，符合你当前的架构设计。

这样你可以明确评估：

- Ewald MP 是否有效改善长程信息传递?
- Atom–Unit Interaction 是否能学习聚合物的重复结构?
- Chemical FG + Spatial Pair 是否提供额外化学信息?
- 最后的 Fusion 是否真正利用了三个层级的互补信息?

结论：现阶段聚焦 Atom、FG、Repeat Unit 三个层级就足够了。 Geometry-based Fragmentation 可以保留为后续的扩展实验或对照方法，不必现在加入主架构。

你目前更值得优先解决的是 **FG Spatial Pair 如何构建、Atom–Unit 如何双向交互，以及最终如何融合三个增强后的表示**。这三项才是当前模型设计的核心。