你说：

目前做可解释性有哪些经典or sota的方法，我想做官能团影响性能之间的趋势或者程度，帮我调研相关论文或者方法

思考了 4m 23s >

ChatGPT 说：

聚合物官能团–性能关系的可解释性方法调研

研究范围：经典 XAI 方法、2024–2026 年相关进展、分子图与聚合物表征、3D 官能团相互作用

针对你目前设计的 **Atom–Functional Group–Repeat Unit 分层聚合物表征模型（3D-HAPIN）**，我认为可解释性不应该只停留在“哪些原子或官能团重要”，而应该进一步回答：

1. **贡献程度（Importance）：** 羰基、醚基、腈基等官能团对目标性能的影响有多大?
2. **影响方向（Direction）：** 某类官能团通常提高还是降低某种性能?
3. **变化趋势（Trend）：** 官能团含量、数量、空间分布变化时，性能如何变化？是否存在非线性或阈值?
4. **协同效应（Interaction）：** 两个官能团组合后，是否产生单独官能团无法解释的性能变化?
5. **空间机制（3D Mechanism）：** 官能团之间的距离、取向、氢键或偶极相互作用，是否影响性能?
6. **结构反事实（Counterfactual）：** 如果把一个酯基换成醚基，其他条件尽量保持不变，模型预测会如何改变?

这六类问题需要不同的解释方法，并非一个 SHAP 就能全部解决。

一、目前主流可解释性方法对比

方法	经典/较新	贡献大小	影响方向	趋势	官能团交互
SHAP / Group SHAP	经典	◎	◎	○	○
Integrated Gradients (IG)	经典	◎	◎	△	△
PDP / ALE	经典	○	◎	◎	○
GNNExplainer	经典	◎	△	×	△
PGExplainer	经典	◎	△	×	△
SubgraphX	经典	◎	○	×	◎
Shapley Interaction	经典理论，持续应用	◎	◎	○	◎
Counterfactual Explanation	持续发展	◎	◎	◎	○

Fragment-level Interpretable GNN	近年研究热点	◎	◎	○	◎
3D interaction attribution	研究拓展方向	◎	◎	◎	◎

◎ 非常适合；○ 可以实现；△ 需要额外设计；× 不直接支持。此表是针对你的研究目标所做的方法适用性评价，不是论文 benchmark 排名。

初步推荐：

- **SHAP + ALE**：回答官能团贡献的大小、正负方向和非线性趋势。
- **Group Shapley / SubgraphX**：解释完整官能团及官能团组合，而非零散原子。
- **Functional Group Pair Attribution**：直接研究空间相互作用对性能的贡献。
- **Chemically Valid Counterfactuals**：检验结构修改前后性能的预测变化。

需要特别区分：**模型归因不等于真实化学因果关系。** SHAP 或注意力可以描述模型使用了哪些结构信息，但不能单独证明某个官能团必然导致某种性能变化。这也是近年来分子可解释性研究的重要问题。 PMC +1

二、最值得精读的近期论文（2025–2026）

以下是我检索到的、与聚合物官能团可解释性最接近的研究。其中既有直接面向聚合物的论文，也有方法上值得迁移的分子 GNN 工作。

1. FragNet: A Graph Neural Network for Molecular Property Prediction with Four Levels of Interpretability

重点精读

JACS, 2026 · DOI: 10.1021/jacs.5c22620

核心是把分子拆解为 Atom、Bond、Fragment、Fragment Connection 四个层面，不仅分析片段的重要性，还分析片段连接和片段对预测值的正负贡献。

与你的模型最直接的联系： 可以借鉴其 Fragment Contribution 设计，将你的 FG 和 FG Pair 变为可独立量化的解释对象。

期刊论文 ↗ · GitHub 代码 ↗

2. Multimodal Modeling for Polymer Property Prediction and Decoupling of Structure–Property Relationship — GeoALBEF

Chem & Bio Engineering, 2025 · DOI: 10.1021/cbe.5c00057

直接针对聚合物。将 Polymer Graph 和 SMILES 文本结合，采用 Attention 与 Functional Group Averaging Strategy (FGAS)，对官能团进行重要性可视化，并引入强化学习辅助分析结构–性能关系。

最值得借鉴： 如何从多个聚合物样本中汇总官能团贡献，得到全局规律，而不仅解释单个样本。

论文链接 ↗

3. A hierarchical interaction message net for accurate molecular property prediction — HimNet

Communications Chemistry, 2026 · DOI: 10.1038/s42004-026-01922-x

采用 Atom–Motif–Molecule 分层架构，通过 Hierarchical Interaction Message Passing 和 Explainable Attention Interaction 显式建模 Motif–Motif、Atom–Motif 之间的信息交互。

最值得借鉴： 官能团之间的协同作用和跨层交互。其局限在于主要使用 2D 分子图，不能直接解释依赖聚合物链构象的真实 3D 空间相互作用。

论文链接 ↗ · GitHub 代码 ↗

4. RISE: Radius of Influence based Subgraph Extraction for 3D Molecular Graph Explanation

ICML, 2025

针对 3D Geometric GNN 设计解释方法，考虑三维邻域和 cutoff 产生的大量空间边，通过局部作用半径寻找对预测重要的子图。

最值得借鉴： 你的 3D 聚合物包含大量非键 Atom Pair 和 FG Pair，RISE 的空间局部化思想可用于筛选真正有解释价值的相互作用区域。

ICML 原论文 ↗

5. Functional Groups Are All You Need for Chemically Interpretable Molecular Property Prediction — FGR

Journal of Chemical Information and Modeling, 2026 · DOI: 10.1021/acs.jcim.5c02769

直接将官能团作为化学表征单位，结合人工定义的官能团与从分子数据中挖掘的结构模式，通过预训练获得较低维度的分子表示。

最值得借鉴： 官能团不是预测完成后才提取的解释单元，而是从表征学习阶段就被显式引入。

论文链接 ↗

6. Explainable Graph Neural Networks in Chemistry: Combining Attribution and Uncertainty Quantification

Journal of Chemical Information and Modeling, 2025 · DOI: 10.1021/acs.jcim.5c01003

系统比较分子 GNN 的归因方法，发现 Feature Ablation 和 Shapley Value Sampling 能有效识别与预测相关的分子子结构，并将归因分析扩展到预测不确定性。

最值得借鉴： 官能团贡献值需要与解释的可靠性一同报告，尤其是在数据稀疏的聚合物体系中。

论文链接 ↗

7. Fragment-Level Graph Encoding for Interpretable Molecular Property Prediction

arXiv 预印本 · 2026-10-21

将原子图直接转为片段图，然后在片段节点上实施解释。论文报告这种表示方式可以在多个任务中保留接近原子图的预测表现，并指出事后把原子贡献相加并不总能得到稳定的片段级解释。

最值得借鉴： 你现在已经把 FG 显式设计成节点，理论上比最后简单累加 Atom Attention 更适合做稳定的官能团归因。该论文仍为预印本，其结论需要进一步验证。

预印本 ↗ · 代码 ↗

这些论文中，**FragNet、GeoALBEF、HimNet、RISE** 最值得先读。它们分别对应官能团贡献、聚合物全局统计、跨层协同作用以及 3D 空间解释四个关键问题。 PubMed +6

特别注意，FragNet 中的 Fragment Connection 不完全等同于你想建立的、基于真实三维构象的 FG–FG 空间接触网络；借鉴其分层和归因思想时，需要重新定义空间边及其物理含义。

三、经典方法的核心原理与公式

1. SHAP / Group SHAP：量化官能团贡献程度

SHAP 源自 Shapley Value，最经典的论文是 Lundberg 和 Lee 的 *A Unified Approach to Interpreting Model Predictions*（NeurIPS 2017）。 NIPS Papers

其核心思想是：比较某个特征在不同特征组合中加入前后，模型输出发生多大变化。

假设聚合物含有 K 个可解释官能团，官能团 g 的 Shapley Value：

$$\phi_g = \sum_{S \subseteq F \setminus \{g\}} \frac{|S|!(K-|S|-1)!}{K!}[v(S \cup \{g\}) - v(S)]$$

其中 $v(S)$ 表示保留官能团集合 S 时，根据选定背景分布或干预规则定义的模型输出。

对于你的任务，SHAP 可以产生两类结果：

- $|\phi_g|$：官能团影响预测结果的程度。
- ϕ_g 的正负：官能团相对于解释基准提高或降低了模型预测值。

例如，如果目标是 Tg，$\phi_{\text{carbonyl}} > 0$ 仅表示在该解释基准下，羰基对预测 Tg 有正向贡献，并不等价于添加羰基一定会提高 Tg。

还可以对同类官能团在不同聚合物中的贡献做统计：

$$I_t = \frac{1}{N_t}\sum_{g\in\mathcal{D}_t}|\phi_g|, \qquad D_t = \frac{1}{N_t}\sum_{g\in\mathcal{D}_t}\phi_g$$

其中 I_t 表示某类官能团的平均重要程度，D_t 表示平均方向。实际统计时还要考虑每条链的官能团数量、DP、分子量及样本频率，避免长链因为节点多而得到更高分数。

对于 3D-HAPIN：推荐以完整官能团作为一个 attribution group，而不是把每个原子独立解释后简单相加。

2. Integrated Gradients：适合对深度模型进行快速归因

IG 是 Sundararajan 等人在 ICML 2017 提出的方法。其原理是沿着基准输入到真实输入的路径，对输出梯度进行积分。 Proceedings of...

$$\mathrm{IG}_i(x) = (x_i - x_i')\int_0^1 \frac{\partial f(x' + \alpha(x - x'))}{\partial x_i}\, d\alpha$$

你可以把 IG 作用在模型内部的 FG Embedding 或 FG Pair Embedding 上，以分析哪部分表示对预测结果敏感。

优势是计算开销相对较低，能处理大量样本。局限是依赖基准选择，而且在离散官能团、非物理插值与跨层耦合场景下，梯度归因不一定具有直接的化学解释。

3. ALE：研究官能团数量和性能之间的非线性趋势

如果你最想研究的是：

“随着酯基比例增加，聚合物 Tg 或溶解性是否持续增加？是否出现一个最佳范围？”

那么 **ALE（Accumulated Local Effects）** 非常值得采用。

它通过样本所在的局部条件分布估计特征变化的平均影响，相比传统 PDP，更适合处理存在较强相关性的描述符。经典论文是 Apley 与 Zhu，2020。 econpapers.re...

对于连续特征 z，其形式为：

$$\mathrm{ALE}(z) = \int_{z_0}^{z} \mathbb{E}\left[\frac{\partial \hat{f}}{\partial z}\,\middle|\, Z = z'\right] dz' - C$$

这里的 z 可以是官能团密度、极性描述符或空间接触比例。官能团数量属于离散变量，可以使用有限差分版本的 ALE。

官能团含量与预测性能的关系（示意）

示例为假设性趋势，不是实验或文献中的实测数据。

这种曲线能辅助识别单调区间、非线性和潜在最优区域，但不能单凭曲线证明化学因果关系。

对于原始 3D GNN，官能团密度通常不是可以直接独立修改的输入。实际操作可以通过一个验证过保真度的代理模型进行 ALE，或者构造真实有效的聚合物组成变化系列，直接计算原模型响应。

4. SubgraphX：官能团组合的重要性

SubgraphX 是 ICML 2021 的代表性方法，通过 Monte Carlo Tree Search 寻找重要子图，并用近似 Shapley Value 评价子图贡献。 Proceedings of...

与 GNNExplainer 相比，其重要优势是解释单元可以是一个完整子图。

对你的模型来说，SubgraphX 的搜索空间可以由原子子图改为官能团子图，从而研究完整官能团及其组合。

不过，长链聚合物的候选子图数量庞大，因此需要先通过官能团类型、空间邻域和重要性预筛选降低搜索成本。

5. Counterfactual：把可解释性变成材料设计建议

反事实解释直接回答："如果某个官能团被另一种官能团替代，模型预测会如何变化？"

基本形式为：

$$\Delta y_{\mathrm{CF}} = f(G_{\mathrm{modified}}) - f(G_{\mathrm{original}})$$

例如，在相同主链类型、相近 DP、相同测试条件下，将部分侧基从 A 类型替换为 B 类型，观察预测溶解性、Tg 或氧化稳定性指标的变化。

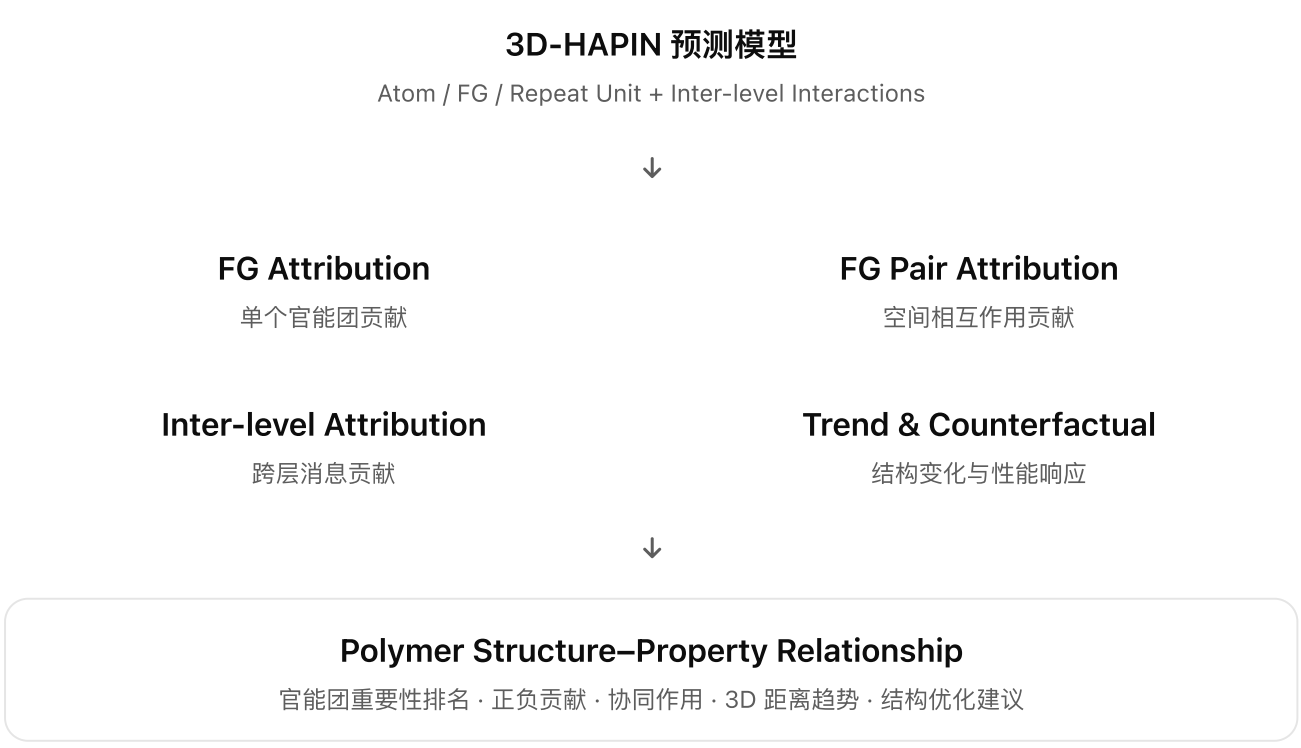
重要的是，修改后的结构必须满足化学价态、聚合反应可实现性与合理构象等约束，而不能随意删除图节点。

参考文献：*Model agnostic generation of counterfactual explanations for molecules*, Chemical Science, 2022。 pubs.rsc.org

四、结合你的 3D-HAPIN，如何设计官能团可解释性?

我建议将可解释性设计为一个独立模块，并且与目前的三层表征结构对应，而不是在模型训练完成后简单画 Attention 热力图。

推荐的解释框架



A. 官能团本身对性能的贡献

设模型预测输出为：

$$\hat{y} = f(G_A, G_{FG}, G_U, G_{\text{inter}})$$

可先采用 FG-level Feature Ablation：

$$\Delta_g = \hat{y}(G) - \hat{y}(G \setminus g)$$

这里的 $G \setminus g$ 是依据明确规则屏蔽官能团信息后的输入，并不代表实际合成中删除官能团。

在你的分层模型里，同一个官能团的信息可能同时存在于 Atom Branch、FG Branch 及 Cross-level Message 中。因此必须特别注意：

对官能团进行完整归因时，要保证屏蔽操作在相关分支之间保持一致，否则可能因为其他分支仍保留相同信息而低估其贡献。

还要区分两种解释：屏蔽 FG Embedding 得到的是某一表征通道的重要性；用有效化学结构替换整个 FG 得到的是结构变化的预测效应。两者不能混为一谈。

B. 官能团之间的协同效应

这是我认为你的模型最有研究价值的解释方向之一。

对于官能团 g, h，可以用二阶消融差分：

$$\begin{aligned} I_{g,h} = f(G) - f(G \setminus g) \\ - f(G \setminus h) + f(G \setminus \{g, h\}) \end{aligned}$$

它衡量两个官能团联合存在时，对模型输出是否具有非加性贡献。

不过，二阶差分依赖于屏蔽方案。若希望减少基准组合带来的偏差，可以进一步引入 **Shapley Interaction Values**，在多种官能团组合背景下估算交互。

对于你的 3D 模型，还应该把两种概念区分开：

- FG–FG 协同效应：两个化学片段共同存在产生的非加性预测贡献。
- FG–FG 空间相互作用：两个片段的三维接触、距离、取向等几何信息对预测结果的作用。

前者不一定来源于真实空间接触，后者也不一定意味着物理上存在协同稳定作用。

C. 3D 官能团 Pair 的空间贡献

假设你已构建 FG Pair Edge：

$$e_{gh} = [d_{gh}, \theta_{gh}, \text{contact features}, \ldots]$$

可以对单条空间边进行屏蔽：

$$A_{gh}^{3D} = f(G) - f(G_{\setminus e_{gh}})$$

然后在多个样本、多个构象中汇总归因，研究：

$$\mathbb{E}[A_{gh}^{3D} \mid d_{gh} = r]$$

即：**某类官能团之间的空间距离变化时，该接触关系对预测值的平均贡献如何变化。**

这里要注意空间接触网络的定义。两个官能团靠得近，只能说明存在几何接近，不一定能证明氢键或静电作用。氢键识别应引入供受体类型、距离和角度；其他相互作用也需要适当的几何或物理判据。

而且你的模型可能具有 3D 等变/不变性质，因此解释时优先使用距离、角度、接触图等旋转不变信息，不建议直接将原始 xyz 坐标梯度作为最终物理解释。

五、如何验证这些解释是可靠的?

近期文献越来越重视 Attribution Fidelity，而不是仅展示看起来符合化学直觉的热力图。GraphFramEx（2022）提出了系统性评估框架，强调不同解释方法在必要性和充分性之间存在权衡。 Proceedings of...

验证维度	建议测试
Faithfulness	屏蔽高贡献官能团或空间边，观察预测变化是否显著大于随机屏蔽
Stability	同一聚合物在不同随机种子、微小构象扰动下，解释排名是否稳定
Consistency	IG、Group SHAP、Ablation 等不同方法的解释是否大体一致
Chemical Validity	结构修改是否满足化学约束；空间相互作用是否符合几何判据
Generalization	在未见过的单体组合或聚合物家族中，解释趋势是否仍成立
External Validation	与独立 DFT/MD、已有文献规律或实验结果交叉验证

另外，需要谨慎使用 Attention。*Attention is not Explanation* 指出，Attention 权重并不能自动等价于特征对输出的真实贡献；因此可以用 Attention 进行探索性可视化，但关键结论最好使用 Attribution 和扰动实验验证。 ACL Anthology

六、推荐的落地研究顺序

第一阶段：先建立可复现的可解释性 Baseline

在训练完成的 3D-HAPIN 上，分别实施 IG、Feature Ablation 和 Group Shapley，得到官能团及官能团 Pair 的贡献排名。先不要大幅改动原模型。

第二阶段：做全局官能团–性能趋势分析

以官能团类型、密度、占比为解释维度，使用 ALE、SHAP Dependence 或受约束的组成变化分析。汇总各类 FG 的平均贡献、置信区间和变化趋势。

第三阶段：扩展到 3D FG–FG Interaction Explanation

引入 FG Pair Attribution、Shapley Interaction 和不同距离区间统计，研究官能团组合及空间相互作用是否产生额外预测贡献。

第四阶段：结构修改及外部验证

使用有效官能团替换、受约束结构生成以及 DFT/MD 或实验结果验证，判断模型解释能否转化为可执行的聚合物设计规律。

对于你的电池聚合物研究，初期建议先选择 **Tg、溶解性、电子结构相关氧化指标** 等相对明确的目标分别建立解释体系。粘结性和界面稳定性受到聚合物、溶剂、固态电解质、加工工艺等多个因素影响，不能只凭孤立聚合物的官能团结构推出器件层面的性能规律。

实际实现可使用 Captum ↗ 的 IG、Feature Ablation、Shapley Value Sampling，以及 PyTorch Geometric Explain ↗ 的图解释接口。它们可以承担经典基线；分层一致性屏蔽和真实化学结构替换通常仍需要你定制实现。 Model Inter… +2

七、最终研究判断

从目前检索到的工作来看，普通 Atom-level Attention 和 Functional Group Importance 已经有较多研究，例如 GeoALBEF、FragNet、FGR；HimNet 进一步强调了分层官能团交互，RISE 则专门关注 3D 图解释。

因此，**如果你的目标是形成有方法学创新的论文，可把研究重点放在“3D 官能团空间交互的定量解释”和“跨层信息一致性的官能团归因”上。**

一个可以探索的方法方向是：

Hierarchical Functional Group Attribution for Interpretable 3D Polymer Representation Learning

核心不是再提出一种普通的节点重要性算法，而是尝试建立：

$$\text{FG Contribution} + \text{3D FG-Pair Interaction} + \text{Cross-Level Attribution} \rightarrow \text{Struct}$$

如果能在不同聚合物组成、DP 和三维构象下，稳定识别哪些官能团及其空间交互对性能预测具有正向或负向贡献，并通过可信的结构修改和外部计算结果验证，那么这个方向会比单纯使用 SHAP 画贡献热力图更有研究价值。

但应把它看作一个**值得验证的创新假设**，而不是已确认尚无相关工作的空白；尤其需要与 FragNet、GeoALBEF、HimNet、RISE 及近期片段级归因方法进行直接比较。